

神经网络优化算法： 从算法复杂度到 AdamW、Muon 与 PolarGrad 融合随机优化理论、自适应方法、与矩阵结构优化器

基于 Qi Deng & 苏炜杰等讲义整理

2026 年 7 月 8 日

本文档的定位

这是一个**学术级讲义**，融合：

- **随机优化理论** (SAA、SA/SGD、Mirror Descent、方差缩减) ——理解算法复杂度的数学语言
- **深度学习优化器** (Adam/AdamW、Shampoo、SOAP、Muon、PolarGrad) ——实践中的算法设计
- **数学基础补充** (谱分解、SVD、极分解、矩阵范数、Newton-Schulz、浓度不等式) ——让你能读懂论文

阅读建议：

- 如果你只关心「AdamW vs Muon 用哪个」，先读 §6–§9
- 如果你想知道「为什么 Muon 有效」，请读 §10 (最陡下降统一视角) 和 §11 (矩阵函数)
- 如果你想做理论科研，§2–§5 (复杂度分析) 是必修的

为什么矩阵结构对优化器设计至关重要？


神经网络参数天然**是矩阵**（权重层 $W \in \mathbb{R}^{m \times n}$ ）或**张量**（卷积核）。

向量视角（Adam 的做法）

- 将 W 展平为 $\text{vec}(W) \in \mathbb{R}^{mn}$
- 逐坐标独立地估计二阶矩
- 忽略 m 个行与 n 个列之间的结构
- 预条件器是对角阵： $P = \text{diag}(v_t)^{-1/2}$

矩阵视角（Muon/Shampoo 的做法）

- 保持 W 的矩阵结构
- 分别处理行空间与列空间
- 利用梯度矩阵 G_t 的 SVD/极分解
- 预条件器利用 Kronecker 结构或谱正交化



Adam, AdaGrad

Shampoo, Muon, SOAP

随机优化问题的两种范式

问题设定： $\min_{x \in \mathcal{X}} f(x) = \mathbb{E}_{\xi}[F(x, \xi)]$, 其中 ξ 是随机变量。

范式一：样本平均近似 (SAA)

- 一次性采样 N 个 ξ_i , 构造 $\hat{f}_N(x) = \frac{1}{N} \sum_{i=1}^N F(x, \xi_i)$
- 用确定性优化方法求解 $\min_x \hat{f}_N(x)$
- **核心问题：** N 取多大才能保证 $\hat{f}_N$ 的解 ε -接近 f 的真解？

范式二：随机近似 (SA / SGD)

- 每步在线采样 ξ_t , 获得随机梯度 $g_t = \nabla_x F(x_t, \xi_t)$
- 迭代更新: $x_{t+1} = x_t - \eta_t g_t$
- **核心问题：** 需要多少步 T 才能收敛？步长 η_t 如何选？

SAA 的样本复杂度

核心结论：对有限域 $|\mathcal{X}| < +\infty$ ，若每个 $F(\cdot, \xi)$ 的波动是 sub-Gaussian（宽度 σ ），则：

定理 (SAA 样本复杂度)

对任意 $0 < \hat{\varepsilon} < \varepsilon$ 和置信度 $1 - \delta$ ，若样本量

$$N \geq \frac{2\sigma^2}{(\varepsilon - \hat{\varepsilon})^2} \ln \frac{|\mathcal{X}|}{\delta},$$

则 $\Pr(\hat{\mathcal{S}}_N^{\hat{\varepsilon}} \subseteq \mathcal{S}^\varepsilon) \geq 1 - \delta$ ，即 SAA 的近似解集以高概率包含在真实问题的近似解集中。

证明工具链：

Chebyshev $\rightarrow$ MGF bound $\rightarrow$ Hoeffding 不等式

对每个 $x \in \mathcal{X} \setminus \mathcal{S}^\varepsilon$ ，联合界给出上述结果。

对连续域：需引入覆盖数（covering number），复杂度变为 $\mathcal{O}\left(\frac{\sigma^2}{(\varepsilon - \hat{\varepsilon})^2} \left[d \ln \frac{LD}{\varepsilon - \hat{\varepsilon}} + \ln \frac{1}{\delta}\right]\right)$ 。

Sub-Gaussian 随机变量与浓度不等式 (知识补充)

定义 (Sub-Gaussian 随机变量)

称零均值随机变量 Y 是 σ -sub-Gaussian, 若其矩母函数满足:

$$\mathbb{E}[e^{tY}] \leq \exp\left(\frac{\sigma^2 t^2}{2}\right), \quad \forall t \in \mathbb{R}.$$

常见 Sub-Gaussian 分布:

- $Y \sim \mathcal{N}(0, \sigma^2)$: 高斯 (宽度 σ)
- $Y \in [a, b]$ 有界: Hoeffding 引理给出宽度 $(b - a)/2$
- Bernoulli(p): 宽度受控

定理 (Hoeffding 不等式)

若 $Y_1, \dots, Y_N$ 是独立 σ -sub-Gaussian 随机变量, 则

$$\Pr\left(\frac{1}{N} \sum_{i=1}^N Y_i \geq t\right) \leq \exp\left(-\frac{Nt^2}{2\sigma^2}\right).$$

随机梯度下降的收敛保证

对光滑凸函数 f , 取 SGD 步长 $\eta_t = \frac{D}{\sigma\sqrt{T}}$ (常数) 或 $\eta_t = \frac{1}{L+t}$ (递减), Polyak 平均 $\bar{x}_T = \frac{1}{T} \sum_t x_t$ 满足:

$$\mathbb{E}[f(\bar{x}_T)] - f(x^*) \leq \frac{D^2}{2\eta T} + \frac{\eta\sigma^2}{2} = \mathcal{O}\left(\frac{D\sigma}{\sqrt{T}}\right).$$

与 GD 对比:

方法	每步开销	收敛速度
GD (全梯度)	$\mathcal{O}(n)$	$\mathcal{O}(1/T)$ (凸)、 $\mathcal{O}(e^{-T/\kappa})$ (强凸)
SGD (随机)	$\mathcal{O}(1)$	$\mathcal{O}(1/\sqrt{T})$ (凸)、 $\mathcal{O}(1/T)$ (强凸 + 递减步长)

关键的方差项: $\frac{\eta\sigma^2}{2}$ 不随 T 消失。这就是为什么**方差缩减** (variance reduction) 和**自适应步长** (adaptive methods) 是随机优化的两大主题。

深度学习优化的特殊挑战

- ❶ **非凸性**: 损失曲面有大量局部极小和鞍点
- ❷ **高维性**: 参数量 10^6 – 10^{12}
- ❸ **病态性**: 不同参数方向的曲率差异极大 ($\kappa \gg 1$)
- ❹ **随机噪声**: mini-batch引入方差
- ❺ **梯度消失/爆炸**: 深层网络梯度传播问题
- ❻ **过拟合**: 模型记忆训练数据
- ❼ **超参数敏感**: 学习率、batch size需精细调节
- ❽ **计算约束**: GPU内存、通信带宽

这些挑战直接驱动了优化器设计的演进:

病态性 + 高维性 $\rightarrow$ 预条件方法 随机噪声 $\rightarrow$ EMA/动量 计算约束 $\rightarrow$ 内存高效的近似

Weight Decay 与 L2 正则化的关键区别

L2 正则化修改目标函数:

$$\mathcal{L}_{L2}(w) = \mathcal{L}(w) + \frac{\lambda}{2} \|w\|^2, \quad g_t^{L2} = \nabla \mathcal{L}(w_t) + \lambda w_t.$$

在 SGD 中等价于 weight decay: $w_{t+1} = (1 - \eta\lambda)w_t - \eta\nabla\mathcal{L}(w_t)$ 。

但在 Adam 中不等价! 因为自适应缩放 $\frac{1}{\sqrt{\hat{v}_t}}$ 会逐坐标扭曲正则化项:

$$\Delta w_t = -\eta \frac{\nabla \mathcal{L}(w_t) + \lambda w_t}{\sqrt{\hat{v}_t} + \varepsilon} \neq (1 - \eta\lambda)w_t - \eta \frac{\nabla \mathcal{L}(w_t)}{\sqrt{\hat{v}_t} + \varepsilon}.$$

对梯度大的坐标, $\sqrt{\hat{v}_t}$ 大, 正则化被削弱; 对梯度小的坐标, 反而加强。

AdamW 解耦方案:

$$w_{t+1} = (1 - \eta\lambda)w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}$$

Weight decay 独立于自适应更新, 两个机制不互相干扰。

Gradient Clipping

梯度裁剪防止梯度爆炸 (尤其 RNN/Transformer 训练中):

按值裁剪 (Value Clipping):

$$g_i = \begin{cases} c & \text{if } g_i > c \\ -c & \text{if } g_i < -c \\ g_i & \text{otherwise} \end{cases}$$

按范数裁剪 (Norm Clipping):

$$g \leftarrow \begin{cases} g & \text{if } \|g\| \leq v \\ v \cdot \frac{g}{\|g\|} & \text{otherwise} \end{cases}$$

为什么有效? SGD 在光滑假设下需要 $\eta \leq 2/L$, 但深度学习中的 L 可能非常大且不均匀。梯度裁剪相当于人为限制了有效 L , 使更大的学习率成为可能。

Adam 的完整推导回顾

Adam 维护两个 EMA:

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t && \text{(一阶矩: 方向平滑)} \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^{\odot 2} && \text{(二阶矩: 逐坐标方差)} \end{aligned}$$

偏差修正 (关键但常被忽略的推导):

$$\mathbb{E}[m_t] = (1 - \beta_1) \sum_{k=1}^t \beta_1^{t-k} \mathbb{E}[g_k] = (1 - \beta_1^t) \mu \implies \hat{m}_t = \frac{m_t}{1 - \beta_1^t}.$$

同理 $\hat{v}_t = v_t / (1 - \beta_2^t)$ 。修正后 $\mathbb{E}[\hat{m}_t] = \mu$, 消除了冷启动偏差。

更新:

$$w_{t+1} = w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}, \quad \text{逐坐标操作: } \frac{\hat{m}_{t,i}}{\sqrt{\hat{v}_{t,i}} + \varepsilon}.$$

预条件视角: $w_{t+1} = w_t - \eta P_t \hat{m}_t$, 其中 $P_t = \text{diag}(\hat{v}_t + \varepsilon^2)^{-1/2}$ 是对角矩阵。

Adam 的 reinterpretation: Gauss-Newton 联系

关键洞察: Adam 的 $\sqrt{v_t}$ 可以看作 Gauss-Newton 矩阵对角元的近似。

对于损失 $\ell(f(x; w), y)$, 广义 Gauss-Newton (GGN) 矩阵为:

$$G(w) = J(w)^\top H_\ell(w) J(w),$$

其中 $J(w) = \frac{\partial f}{\partial w}$ 是网络输出的 Jacobian, H_ℓ 是损失关于输出的 Hessian。

GGN 是 Hessian 的正定近似 (忽略残差项), 其对角元恰好是:

$$[G(w)]_{ii} = \sum_j \left(\frac{\partial f_j}{\partial w_i} \right)^2 \cdot [H_\ell]_{jj}.$$

在特定条件下, v_t 的 EMA 近似于 $\mathbb{E}[g_t^{\odot 2}]$, 而这正是 Fisher 信息矩阵 (GGN 的期望) 的对角元。

所以 Adam 本质上在用对角 Gauss-Newton 做预条件——它比「对角 Hessian」更准确地捕捉了深度网络的几何。

Adam 收敛理论中的陷阱

原始证明的问题 (Reddi et al., 2018): Adam 的收敛需要有效学习率 $\eta_t = \eta/\sqrt{\hat{v}_t}$ 基本非增, 但原始 Adam 中 v_t 可能下降 (β_2 使旧信息衰减), 导致 η_t 在某些坐标上增大, 破坏收敛。

修正: AMSGrad

$$\hat{v}_t = \max(\hat{v}_{t-1}, v_t), \quad w_{t+1} = w_t - \frac{\eta}{\sqrt{t}} \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}.$$

在线凸优化视角下 Adam 的 regret: 在线预条件次梯度法的 regret bound (抽象形式):

$$\text{Regret}_T \leq \frac{1}{2\eta} \sum_{t=1}^T (\|\Delta_t\|_{H_t}^2 - \|\Delta_{t+1}\|_{H_t}^2) + \frac{\eta}{2} \sum_{t=1}^T g_t^\top H_t^{-1} g_t.$$

取 $H_t = \text{diag}(\sum_{s \leq t} g_s^{\odot 2})^{1/2}$ 即恢复 AdaGrad 的 regret bound; 取对角 EMA 近似则对应 Adam。