

第一周：梯度下降与随机梯度下降的理论基石

学习目标：深入理解梯度下降的收敛理论，掌握下降引理的推导，了解条件数如何决定收敛速度。

建议搭配 *Bubeck (2015) §3* 和 *Nesterov (2018) §1* 阅读。

基本设定与记号

优化问题

我们考虑无约束连续优化问题：

$$\min_{\theta \in \mathbb{R}^d} f(\theta), \quad (1)$$

其中 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 是目标函数（在机器学习中通常为损失函数）。

定义 1.1 (梯度). 函数 f 在点 θ 处的**梯度** (gradient) $\nabla f(\theta) \in \mathbb{R}^d$ 是 f 在该处的方向导数的最陡上升方向：

$$\nabla f(\theta) = \left[\frac{\partial f}{\partial \theta_1}(\theta), \dots, \frac{\partial f}{\partial \theta_d}(\theta) \right]^\top. \quad (2)$$

梯度的每一个分量是 f 关于对应坐标的偏导数。

定义 1.2 (Hessian 矩阵). 若 f 二阶可微，则其 **Hessian 矩阵** $\nabla^2 f(\theta) \in \mathbb{R}^{d \times d}$ 由所有二阶偏导数构成：

$$[\nabla^2 f(\theta)]_{ij} = \frac{\partial^2 f}{\partial \theta_i \partial \theta_j}(\theta). \quad (3)$$

由 Schwarz 定理（混合偏导数的对称性），若 f 二阶连续可微，则 $\nabla^2 f(\theta)$ 是对称矩阵。

二次函数是理解的钥匙

在优化理论中，二次函数

$$f(\theta) = \frac{1}{2} \theta^\top A \theta + b^\top \theta + c, \quad A \in \mathbb{R}^{d \times d}, A \succ 0, \quad (4)$$

是最重要的分析工具。原因有三：

- (1) 光滑函数的 Taylor 展开在局部近似为二次函数（这是所有二阶分析的基础）；
- (2) 许多收敛性结论的「最坏情形」由某个二次函数达到；

(3) 二次函数的梯度 $\nabla f(\theta) = A\theta + b$ 和 Hessian $\nabla^2 f(\theta) = A$ 结构清晰，便于计算。

对二次函数 $f(\theta) = \frac{1}{2}\theta^\top A\theta$ (令 $b = 0, c = 0$ 不失一般性，因为平移不影响优化动态)，梯度下降的迭代为：

$$\theta_{t+1} = \theta_t - \eta A \theta_t = (I - \eta A) \theta_t. \quad (5)$$

迭代 T 步后： $\theta_T = (I - \eta A)^T \theta_0$ 。因此收敛速度完全由 $I - \eta A$ 的谱半径决定。

光滑性与凸性：两个基本假设

L -光滑性 (Smoothness)

光滑性（又称 Lipschitz 连续梯度）限制了函数梯度变化的剧烈程度。

定义 2.1 (L -光滑). 函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 称为 L -光滑 (L -smooth)，如果存在常数 $L > 0$ ，使得对任意 $\theta, \theta' \in \mathbb{R}^d$ ，有

$$\|\nabla f(\theta) - \nabla f(\theta')\| \leq L \|\theta - \theta'\|. \quad (6)$$

定理 2.1 (光滑性的三个等价刻画). 设 f 为连续可微函数。以下三个命题等价：

(i) f 满足(6) (梯度 L -Lipschitz 连续)。

(ii) 对任意 $\theta, \theta' \in \mathbb{R}^d$,

$$f(\theta') \leq f(\theta) + \langle \nabla f(\theta), \theta' - \theta \rangle + \frac{L}{2} \|\theta' - \theta\|^2. \quad (7)$$

(iii) 对任意 $\theta, \theta' \in \mathbb{R}^d$,

$$\langle \nabla f(\theta') - \nabla f(\theta), \theta' - \theta \rangle \leq L \|\theta' - \theta\|^2. \quad (8)$$

若 f 二阶可微，则以上所有命题等价于 $\nabla^2 f(\theta) \preceq LI$ (对所有 θ)，即 Hessian 的最大特征值不超过 L 。

证明 ((i) $\Rightarrow$ (ii) 的证明). 这是下降引理的核心推导。设 $\theta, \theta' \in \mathbb{R}^d$ 任意。考虑连接 θ 和 θ' 的线段，对函数 $h(t) = f(\theta + t(\theta' - \theta))$ ($t \in [0, 1]$) 应用微积分基本定理：

$$\begin{aligned} f(\theta') - f(\theta) &= h(1) - h(0) = \int_0^1 h'(t) dt \\ &= \int_0^1 \langle \nabla f(\theta + t(\theta' - \theta)), \theta' - \theta \rangle dt. \end{aligned} \quad (9)$$

从被积函数中加减 $\nabla f(\theta)$:

$$\begin{aligned} f(\theta') - f(\theta) &= \int_0^1 \langle \nabla f(\theta), \theta' - \theta \rangle dt + \int_0^1 \langle \nabla f(\theta + t(\theta' - \theta)) - \nabla f(\theta), \theta' - \theta \rangle dt \\ &= \langle \nabla f(\theta), \theta' - \theta \rangle + \int_0^1 \langle \nabla f(\theta + t(\theta' - \theta)) - \nabla f(\theta), \theta' - \theta \rangle dt. \end{aligned} \quad (10)$$

对积分内的内积应用 *Cauchy-Schwarz* 不等式, 然后利用 (i) 的假设:

$$\begin{aligned} \langle \nabla f(\theta + t(\theta' - \theta)) - \nabla f(\theta), \theta' - \theta \rangle &\leq \|\nabla f(\theta + t(\theta' - \theta)) - \nabla f(\theta)\| \cdot \|\theta' - \theta\| \\ &\leq L \|t(\theta' - \theta)\| \cdot \|\theta' - \theta\| \\ &= Lt \|\theta' - \theta\|^2. \end{aligned} \quad (11)$$

代回积分:

$$f(\theta') - f(\theta) \leq \langle \nabla f(\theta), \theta' - \theta \rangle + \int_0^1 Lt \|\theta' - \theta\|^2 dt = \langle \nabla f(\theta), \theta' - \theta \rangle + \frac{L}{2} \|\theta' - \theta\|^2. \quad (12)$$

这正是(7)。□

证明 ((ii) $\Rightarrow$ (iii) 的简要思路). 写出两个对称的不等式:

$$\begin{aligned} f(\theta') &\leq f(\theta) + \langle \nabla f(\theta), \theta' - \theta \rangle + \frac{L}{2} \|\theta' - \theta\|^2, \\ f(\theta) &\leq f(\theta') + \langle \nabla f(\theta'), \theta - \theta' \rangle + \frac{L}{2} \|\theta - \theta'\|^2. \end{aligned}$$

将两式相加, 左边得到 $f(\theta') + f(\theta)$, 右边合并后即得到 (iii)。

证明 (二阶情形的等价性). 若 f 二阶可微, 对任意 θ 和方向 v , 构造辅助函数 $\phi(t) = f(\theta + tv)$. 则 $\phi''(t) = v^\top \nabla^2 f(\theta + tv) v$. 由 L -光滑性,

$$|\phi'(s) - \phi'(t)| = \left| \int_s^t \phi''(\tau) d\tau \right| \leq L|s - t| \cdot \|v\|^2. \quad (13)$$

取极限可得 $v^\top \nabla^2 f(\theta) v \leq L \|v\|^2$, 即 $\nabla^2 f(\theta) \preceq LI$ 。

μ -强凸性 (Strong Convexity)

定义 2.2 (μ -强凸). 函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 称为 μ -强凸 (μ -strongly convex), 如果存在 $\mu > 0$, 使得对任意 $\theta, \theta' \in \mathbb{R}^d$, 有

$$f(\theta') \geq f(\theta) + \langle \nabla f(\theta), \theta' - \theta \rangle + \frac{\mu}{2} \|\theta' - \theta\|^2. \quad (14)$$

直观理解: 将 f 的下界从线性函数提升为二次函数。在任意点处, f 位于一个曲率为 μ 的抛物面之上。

定理 2.2 (强凸性的等价刻画). 设 f 为连续可微函数。以下命题等价：

(i) f 是 μ -强凸的。

(ii) 对任意 $\theta, \theta' \in \mathbb{R}^d$,

$$\langle \nabla f(\theta') - \nabla f(\theta), \theta' - \theta \rangle \geq \mu \|\theta' - \theta\|^2. \quad (15)$$

(iii) f 满足 Polyak–Łojasiewicz (PL) 不等式的一个强化版本。

若 f 二阶可微，则以上等价于 $\nabla^2 f(\theta) \succeq \mu I$ (对所有 θ)，即 Hessian 的最小特征值至少为 μ 。

证明 (强凸函数梯度单调性的证明). 从(14) 写出对称不等式并相加：

$$\begin{aligned} f(\theta') &\geq f(\theta) + \langle \nabla f(\theta), \theta' - \theta \rangle + \frac{\mu}{2} \|\theta' - \theta\|^2, \\ f(\theta) &\geq f(\theta') + \langle \nabla f(\theta'), \theta - \theta' \rangle + \frac{\mu}{2} \|\theta - \theta'\|^2. \end{aligned}$$

两式相加：

$$\cancel{f(\theta')} + \cancel{f(\theta)} \geq \cancel{f(\theta)} + \cancel{f(\theta')} + \langle \nabla f(\theta) - \nabla f(\theta'), \theta' - \theta \rangle + \mu \|\theta' - \theta\|^2. \quad (16)$$

整理得到(15)。□

条件数 (Condition Number)


定义 2.3 (条件数). 设 f 是 μ -强凸且 L -光滑的函数。其条件数定义为：

$$\kappa := \frac{L}{\mu} \geq 1. \quad (17)$$

对于二次函数 $f(\theta) = \frac{1}{2} \theta^\top A \theta$ ($A \succ 0$):

- $L = \lambda_{\max}(A)$ (最大特征值)
- $\mu = \lambda_{\min}(A)$ (最小特征值)
- $\kappa = \lambda_{\max}/\lambda_{\min}$

几何意义: 条件数描述了函数在不同方向上曲率的差异。 κ 很大意味着存在一个「窄谷」——一个方向非常陡峭而另一个方向非常平缓。下图展示 $\kappa = 10$ 的二次函数的等高线图：



$\kappa = 10$: 长轴/短轴比 $= \sqrt{10} \approx 3.16$

为什么条件数重要？梯度下降的收敛速度表达式为 $(1 - 1/\kappa)^T$ 或类似的缩减因子。当 $\kappa = 100$ 时，要缩小误差到 ε 需要 $\mathcal{O}(\kappa \log(1/\varepsilon))$ 次迭代—— κ 直接乘以迭代次数。这就是为什么病态问题（ κ 大）是优化中的核心挑战。

梯度下降的收敛分析

下降引理与基本不等式

引理 3.1 (下降引理, 又称 Descent Lemma). 设 f 为 L -光滑函数。取步长 $\eta > 0$, 则梯度下降迭代 $\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t)$ 满足:


$$f(\theta_{t+1}) \leq f(\theta_t) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\theta_t)\|^2. \quad (18)$$

证明. 在光滑性不等式(7) 中代入 $\theta = \theta_t$ 和 $\theta' = \theta_{t+1} = \theta_t - \eta \nabla f(\theta_t)$:

$$\begin{aligned} f(\theta_{t+1}) &\leq f(\theta_t) + \langle \nabla f(\theta_t), \theta_{t+1} - \theta_t \rangle + \frac{L}{2} \|\theta_{t+1} - \theta_t\|^2 \\ &= f(\theta_t) + \langle \nabla f(\theta_t), -\eta \nabla f(\theta_t) \rangle + \frac{L}{2} \|\eta \nabla f(\theta_t)\|^2 \\ &= f(\theta_t) - \eta \|\nabla f(\theta_t)\|^2 + \frac{L\eta^2}{2} \|\nabla f(\theta_t)\|^2 \\ &= f(\theta_t) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\theta_t)\|^2. \end{aligned} \quad (19)$$

□

关键观察：要使函数值下降，需要括号内的量大于 0，即 $\eta < 2/L$ 。最速下降在 $\eta = 1/L$ 处达到，此时每步至少下降 $\frac{1}{2L} \|\nabla f(\theta_t)\|^2$ 。



凸情形下的收敛率

定理 3.2 (GD 在凸且光滑条件下的次线性收敛). 设 f 为 L -光滑且 convex 函数。设 $\theta^* \in \arg \min f$ (假设存在)。取固定步长 $\eta = 1/L$ ，则经过 T 步梯度下降后：

$$f(\theta_T) - f(\theta^*) \leq \frac{L \|\theta_0 - \theta^*\|^2}{2T}. \quad (20)$$

即收敛率为 $\mathcal{O}(1/T)$ 。

证明。 由下降引理 (取 $\eta = 1/L$):

$$f(\theta_{t+1}) \leq f(\theta_t) - \frac{1}{2L} \|\nabla f(\theta_t)\|^2. \quad (1)$$

由凸性， $f(\theta^*) \geq f(\theta_t) + \langle \nabla f(\theta_t), \theta^* - \theta_t \rangle$ ，因此：

$$f(\theta_t) - f(\theta^*) \leq \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle. \quad (2)$$

现在考虑距离平方的演化：

$$\begin{aligned} \|\theta_{t+1} - \theta^*\|^2 &= \left\| \theta_t - \frac{1}{L} \nabla f(\theta_t) - \theta^* \right\|^2 \\ &= \|\theta_t - \theta^*\|^2 - \frac{2}{L} \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle + \frac{1}{L^2} \|\nabla f(\theta_t)\|^2. \end{aligned} \quad (21)$$

用 (2) 替换内积项：

$$\|\theta_{t+1} - \theta^*\|^2 \leq \|\theta_t - \theta^*\|^2 - \frac{2}{L} [f(\theta_t) - f(\theta^*)] + \frac{1}{L^2} \|\nabla f(\theta_t)\|^2. \quad (22)$$

从 (1) 解出 $\frac{1}{L^2} \|\nabla f(\theta_t)\|^2 \leq \frac{2}{L} [f(\theta_t) - f(\theta_{t+1})]$ ，代入：

$$\|\theta_{t+1} - \theta^*\|^2 \leq \|\theta_t - \theta^*\|^2 - \frac{2}{L} [f(\theta_t) - f(\theta^*)] + \frac{2}{L} [f(\theta_t) - f(\theta_{t+1})]. \quad (23)$$

即：

$$\frac{2}{L}[f(\theta_t) - f(\theta^*)] \leq \|\theta_t - \theta^*\|^2 - \|\theta_{t+1} - \theta^*\|^2 + \frac{2}{L}[f(\theta_t) - f(\theta_{t+1})]. \quad (24)$$

对 $t = 0, 1, \dots, T-1$ 累加。右边第一项为 *telescoping sum* (望远镜和)：

$$\frac{2}{L} \sum_{t=0}^{T-1} [f(\theta_t) - f(\theta^*)] \leq \|\theta_0 - \theta^*\|^2 - \|\theta_T - \theta^*\|^2 + \frac{2}{L}[f(\theta_0) - f(\theta_T)]. \quad (25)$$

由于 $\|\theta_T - \theta^*\|^2 \geq 0$ 且 $f(\theta_T) \geq f(\theta^*)$ ，可得：

$$\frac{2}{L} \sum_{t=0}^{T-1} [f(\theta_t) - f(\theta^*)] \leq \|\theta_0 - \theta^*\|^2 + \frac{2}{L}[f(\theta_0) - f(\theta^*)]. \quad (26)$$

由下降引理， $f(\theta_t)$ 是非增的，所以 $\sum_{t=0}^{T-1} [f(\theta_t) - f(\theta^*)] \geq T[f(\theta_T) - f(\theta^*)]$ 。更简洁的版本是使用加权平均 $\bar{\theta}_T = \frac{1}{T} \sum_{t=0}^{T-1} \theta_t$ ：由 *Jensen* 不等式， $f(\bar{\theta}_T) \leq \frac{1}{T} \sum_{t=0}^{T-1} f(\theta_t)$ ，从而：

$$f(\bar{\theta}_T) - f(\theta^*) \leq \frac{L}{2T} \|\theta_0 - \theta^*\|^2. \quad (27)$$

由 $f(\theta_T) \leq f(\bar{\theta}_T)$ ($f(\theta_t)$ 单调下降，但更准确地说，输出最后迭代 θ_T 的 *bound* 可以用类似技巧得到同样的 $\mathcal{O}(1/T)$ 渐近速率)。

强凸情形下的线性收敛

定理 3.3 (GD 在强凸且光滑条件下的线性收敛). 设 f 为 μ -强凸且 L -光滑。取固定步长 $\eta = 2/(\mu + L)$ ，则：

$$\|\theta_T - \theta^*\|^2 \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^{2T} \|\theta_0 - \theta^*\|^2. \quad (28)$$

其中 $\kappa = L/\mu$ 。当 $\eta = 1/L$ 时 (更保守的步长)：

$$f(\theta_T) - f(\theta^*) \leq \left(1 - \frac{\mu}{L} \right)^T [f(\theta_0) - f(\theta^*)]. \quad (29)$$

证明 ($\eta = 1/L$ 情形的证明). 展开距离平方：

$$\begin{aligned} \|\theta_{t+1} - \theta^*\|^2 &= \|\theta_t - \eta \nabla f(\theta_t) - \theta^*\|^2 \\ &= \|\theta_t - \theta^*\|^2 - 2\eta \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle + \eta^2 \|\nabla f(\theta_t)\|^2. \end{aligned} \quad (30)$$

使用强凸性和光滑性的 *co-coercivity* 不等式 (这是光滑强凸函数的核心不等式)：

$$\langle \nabla f(\theta) - \nabla f(\theta^*), \theta - \theta^* \rangle \geq \frac{\mu L}{\mu + L} \|\theta - \theta^*\|^2 + \frac{1}{\mu + L} \|\nabla f(\theta) - \nabla f(\theta^*)\|^2. \quad (31)$$

由于 $\nabla f(\theta^*) = 0$ (最优性条件)，上式化为：

$$\langle \nabla f(\theta_t), \theta_t - \theta^* \rangle \geq \frac{\mu L}{\mu + L} \|\theta_t - \theta^*\|^2 + \frac{1}{\mu + L} \|\nabla f(\theta_t)\|^2. \quad (32)$$

取 $\eta = 1/L$ ，代入距离平方展开式：

$$\begin{aligned}
 \|\theta_{t+1} - \theta^*\|^2 &\leq \|\theta_t - \theta^*\|^2 - \frac{2}{L} \left[\frac{\mu L}{\mu + L} \|\theta_t - \theta^*\|^2 + \frac{1}{\mu + L} \|\nabla f(\theta_t)\|^2 \right] + \frac{1}{L^2} \|\nabla f(\theta_t)\|^2 \\
 &= \left(1 - \frac{2\mu}{\mu + L} \right) \|\theta_t - \theta^*\|^2 + \underbrace{\left(\frac{1}{L^2} - \frac{2}{L(\mu + L)} \right)}_{<0} \|\nabla f(\theta_t)\|^2 \\
 &\leq \left(1 - \frac{2\mu}{\mu + L} \right) \|\theta_t - \theta^*\|^2.
 \end{aligned} \tag{33}$$

注意 $1 - \frac{2\mu}{\mu + L} = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1} < 1$ 。递推 T 步即得(28)。

对函数值的 bound (29)，由光滑性和强凸性可证 $f(\theta_T) - f(\theta^*) \leq \frac{L}{2} \|\theta_T - \theta^*\|^2$ 和 $\|\theta_0 - \theta^*\|^2 \leq \frac{2}{\mu} [f(\theta_0) - f(\theta^*)]$ ，联合即可得到。

小结：GD 的收敛速度

函数类	步长	收敛速度
L -光滑 + 凸	$\eta = 1/L$	$\mathcal{O}(1/T)$ （次线性）
μ -强凸 + L -光滑	$\eta = 1/L$	$\mathcal{O}((1 - 1/\kappa)^T)$ （线性）
μ -强凸 + L -光滑	$\eta = \frac{2}{\mu + L}$	$\mathcal{O}\left(\left(\frac{\kappa - 1}{\kappa + 1}\right)^{2T}\right)$ （最优线性）

达到 ε 精度所需的迭代次数：

- 凸情形： $T = \mathcal{O}(1/\varepsilon)$
- 强凸情形： $T = \mathcal{O}(\kappa \log(1/\varepsilon))$ —— 条件数 κ 直接乘在迭代数上！

这就是为什么病态问题（大 κ ）是优化中的核心瓶颈，也是为什么我们要发明预条件方法和自适应方法——它们试图通过改变几何来减小有效条件数。

随机梯度下降 (SGD)

从 GD 到 SGD：噪声的引入

在机器学习中，目标函数通常是一个有限和（或期望）：

$$f(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(\theta; z_i) \quad \text{或} \quad f(\theta) = \mathbb{E}_{z \sim \mathcal{D}}[\ell(\theta; z)]. \tag{34}$$

计算 $\nabla f(\theta)$ 需要遍历整个数据集（梯度下降），在大数据集上开销巨大。随机梯度下降（SGD）在每步采样子集 $\mathcal{B}_t$ ，构造随机梯度：

$$g_t = \frac{1}{|\mathcal{B}_t|} \sum_{i \in \mathcal{B}_t} \nabla_{\theta} \ell(\theta_t; z_i). \tag{35}$$

SGD 的统计假设

我们对随机梯度做以下标准假设：

定义 4.1 (SGD 的标准假设). (A1) **无偏性**: $\mathbb{E}[g_t | \theta_t] = \nabla f(\theta_t)$ 。

(A2) **有界方差**: 存在 $\sigma > 0$, 使得 $\mathbb{E}[\|g_t - \nabla f(\theta_t)\|^2 | \theta_t] \leq \sigma^2$ 。

(A3) (可选) **有界二阶矩**: $\mathbb{E}[\|g_t\|^2 | \theta_t] \leq G^2$ 。(注意: 这蕴含 $\|\nabla f(\theta_t)\|^2 \leq G^2$)

我们定义随机梯度噪声 $\xi_t = g_t - \nabla f(\theta_t)$ 。则 $\mathbb{E}[\xi_t | \theta_t] = 0$, $\mathbb{E}[\|\xi_t\|^2 | \theta_t] \leq \sigma^2$ 。噪声的方差 σ^2 在 SGD 的分析中扮演核心角色——它是 SGD 收敛率比 GD 慢一个 $\sqrt{T}$ 因子的根本原因。

SGD 在凸情形下的收敛分析

定理 4.1 (SGD 在凸光滑条件下的收敛率). 设 f 为 L -光滑且 convex 函数。取 SGD 步长 $\eta_t = \eta = \frac{\|\theta_0 - \theta^*\|}{\sigma\sqrt{T}}$ (常数步长), 或 $\eta_t = \frac{1}{L+t}$ (递减步长)。令 $\bar{\theta}_T = \frac{1}{T} \sum_{t=1}^T \theta_t$ (Polyak 平均), 则:

$$\mathbb{E}[f(\bar{\theta}_T)] - f(\theta^*) \leq \frac{\|\theta_0 - \theta^*\|^2}{2\eta T} + \frac{\eta\sigma^2}{2}. \quad (36)$$

当取 $\eta = \frac{D}{\sigma\sqrt{T}}$ (其中 $D = \|\theta_0 - \theta^*\|$) 时:

$$\mathbb{E}[f(\bar{\theta}_T)] - f(\theta^*) \leq \frac{D\sigma}{\sqrt{T}} = \mathcal{O}(1/\sqrt{T}). \quad (37)$$

证明. 与 GD 证明相似, 展开距离平方:

$$\begin{aligned} \|\theta_{t+1} - \theta^*\|^2 &= \|\theta_t - \eta g_t - \theta^*\|^2 \\ &= \|\theta_t - \theta^*\|^2 - 2\eta \langle g_t, \theta_t - \theta^* \rangle + \eta^2 \|g_t\|^2. \end{aligned} \quad (38)$$

取条件期望 $\mathbb{E}[\cdot | \theta_t]$:

$$\begin{aligned} \mathbb{E}[\|\theta_{t+1} - \theta^*\|^2 | \theta_t] &= \|\theta_t - \theta^*\|^2 - 2\eta \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle + \eta^2 \mathbb{E}[\|g_t\|^2 | \theta_t] \\ &\leq \|\theta_t - \theta^*\|^2 - 2\eta \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle + \eta^2 \|\nabla f(\theta_t)\|^2 + \eta^2 \sigma^2, \end{aligned} \quad (39)$$

其中最后一步使用了 $\mathbb{E}[\|g_t\|^2] = \|\nabla f(\theta_t)\|^2 + \mathbb{E}[\|\xi_t\|^2] \leq \|\nabla f(\theta_t)\|^2 + \sigma^2$ 。

由凸性: $f(\theta_t) - f(\theta^*) \leq \langle \nabla f(\theta_t), \theta_t - \theta^* \rangle$, 代入:

$$\mathbb{E}[\|\theta_{t+1} - \theta^*\|^2 | \theta_t] \leq \|\theta_t - \theta^*\|^2 - 2\eta[f(\theta_t) - f(\theta^*)] + \eta^2 \|\nabla f(\theta_t)\|^2 + \eta^2 \sigma^2. \quad (40)$$

由下降引理: $\|\nabla f(\theta_t)\|^2 \leq 2L[f(\theta_t) - f(\theta_{t+1})] + L^2\eta^2 \|g_t\|^2$ (需要仔细处理)。一个更简洁的途径是利用 $\eta \leq 1/L$ 的条件 (或使用递减步长来回避这个约束)。


取全期望, 移项, 对 $t = 1, \dots, T$ 累加, 获得:

$$2\eta \sum_{t=1}^T \mathbb{E}[f(\theta_t) - f(\theta^*)] \leq \|\theta_0 - \theta^*\|^2 + \eta^2 \sigma^2 T + \eta^2 \sum_{t=1}^T \mathbb{E}[\|\nabla f(\theta_t)\|^2]. \quad (41)$$

若取 $\eta \leq 1/L$, 则 $\eta^2 \|\nabla f(\theta_t)\|^2 \leq \eta[f(\theta_t) - f(\theta_{t+1})]$ 可被吸收。最终得到(36)。□

GD vs SGD 的收敛率对比：

- GD: $f(\theta_T) - f^* = \mathcal{O}(1/T)$, 每步需计算全体梯度 (n 个样本)。
- SGD: $f(\bar{\theta}_T) - f^* = \mathcal{O}(1/\sqrt{T})$, 每步只需计算 $|\mathcal{B}|$ 个样本的梯度。
- 在总计算量 (样本访问数) 度量下: SGD 有时比 GD 更优 (尤其是 n 很大时)。

**强凸情形下的 SGD**

定理 4.2 (SGD 在强凸光滑条件下的收敛率 (简略版)). 设 f 为 μ -强凸且 L -光滑。取 SGD 步长 $\eta_t = \frac{2}{\mu(t+1)}$ (递减步长), 则:

$$\mathbb{E}[f(\theta_T)] - f(\theta^*) \leq \frac{2L\sigma^2}{\mu^2 T} = \mathcal{O}(1/T). \quad (42)$$

注意: 强凸 + 递减步长下, SGD 的渐近速率恢复为 $\mathcal{O}(1/T)$ (而非凸情形下的 $1/\sqrt{T}$), 但仍达不到 GD 在强凸下的线性速率 $\mathcal{O}(e^{-T/\kappa})$ 。

直观解释: 强凸性提供了一个朝向最优点的「拉力」, 抵消了噪声带来的扩散效应。

Momentum 与 Nesterov 加速梯度**Polyak 重球法 (Heavy Ball / Momentum)**

Momentum 方法在更新中引入「惯性」:

$$\begin{aligned} d_t &= \beta d_{t-1} + \nabla f(\theta_t), \\ \theta_{t+1} &= \theta_t - \eta d_t, \end{aligned} \quad (43)$$

其中 $\beta \in [0, 1)$ 是动量系数 (典型值 $\beta = 0.9$)。

将其展开以看清结构：

$$d_t = \nabla f(\theta_t) + \beta \nabla f(\theta_{t-1}) + \beta^2 \nabla f(\theta_{t-2}) + \dots \quad (44)$$

即 d_t 是历史梯度的指数加权和（EMA）。

为什么 momentum 有帮助？ 考虑二次函数 $f(\theta) = \frac{1}{2} \theta^\top A \theta$ 。Momentum 的迭代在特征基下解耦为 d 个独立的一维过程，每个由以下二阶递推描述：

$$\theta_{t+1} = \theta_t - \eta \sum_{k=0}^t \beta^{t-k} \lambda \theta_k. \quad (45)$$

通过分析这个递推的特征值，可证明 momentum 在 condition number κ 下的收敛率为 $\mathcal{O}\left(\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^T\right)$ ，相比 GD 的 $\mathcal{O}\left(\left(\frac{\kappa-1}{\kappa+1}\right)^T\right)$ ，将 κ 替换为 $\sqrt{\kappa}$ ——这是一个显著的加速。

Nesterov 加速梯度 (NAG)

Nesterov 的变体使用「前瞻」梯度：

$$\begin{aligned} d_t &= \beta d_{t-1} + \nabla f(\theta_t - \eta \beta d_{t-1}), \\ \theta_{t+1} &= \theta_t - \eta d_t. \end{aligned} \quad (46)$$

与标准 Momentum 的唯一区别是：梯度在「前瞻点」 $\theta_t - \eta \beta d_{t-1}$ 处计算（而非当前点 θ_t ）。这个看似微小的变化使 Nesterov 方法成为凸光滑函数上的**最优一阶方法**（oracle 下界匹配）：

定理 5.1 (Nesterov 1983, 2004). 对 L -光滑凸函数，NAG 取适当参数后满足：

$$f(\theta_T) - f^* \leq \frac{2L \|\theta_0 - \theta^*\|^2}{T^2} = \mathcal{O}(1/T^2). \quad (47)$$

对 μ -强凸 L -光滑函数：

$$f(\theta_T) - f^* = \mathcal{O}\left(\left(1 - \frac{1}{\sqrt{\kappa}}\right)^T\right). \quad (48)$$

这些速率与一阶 oracle 下界匹配——因此 Nesterov 方法是**最优**的。

方法	凸情形	强凸情形
GD	$\mathcal{O}(1/T)$	$\mathcal{O}((1 - 1/\kappa)^T)$
Momentum	$\mathcal{O}(1/T)$	$\mathcal{O}((1 - 1/\sqrt{\kappa})^T)$
Nesterov	$\mathcal{O}(1/T^2)$	$\mathcal{O}((1 - 1/\sqrt{\kappa})^T)$

关键教训：Momentum/Nesterov 通过利用历史梯度信息构建了更好的「方向估计」 d_t 。这些方法的加速效果来源于梯度序列中**低频分量**的放大——对应于优化过程中持续的下降方向（特征空间的慢方向）。

学习率调度

为什么需要调度？

单纯 SGD 在大规模深度学习中需要精心调整学习率。原因：

- (1) 初始阶段：太大的 η 导致发散（超越光滑性约束 $\eta < 2/L$ ）；太小的 η 导致进展缓慢。
- (2) 收敛阶段：固定 η 使 SGD 在最优解附近以方差 $\eta\sigma^2$ 震荡，无法精确收敛。
- (3) 因此需要 $\eta_t \rightarrow 0$ 。

常用调度策略

- (1) **Warmup**（线性增长）：

$$\eta_t = \eta_{\max} \cdot \frac{t}{T_{\text{warmup}}}, \quad t \leq T_{\text{warmup}}. \quad (49)$$

动机：训练初期，模型参数是随机的，梯度噪声很大。逐步增大步长防止「爆炸」。

- (2) **Cosine Decay**：

$$\eta_t = \eta_{\min} + \frac{\eta_{\max} - \eta_{\min}}{2} \left(1 + \cos \left(\frac{\pi t}{T} \right) \right). \quad (50)$$

- (3) **Step Decay**：每 k epoch 将 η 乘上衰减因子 $\gamma \in (0, 1)$ 。

- (4) **多项式衰减**： $\eta_t = \eta_0(1 - t/T)^p$ 。

理论练习

练习 1：下降引理的逐行推导

用积分形式的 Taylor 公式验证下降引理。即证明：若 $\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$ ，则

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2. \quad (51)$$

提示：

$$f(y) - f(x) = \int_0^1 \langle \nabla f(x + t(y - x)), y - x \rangle dt = \langle \nabla f(x), y - x \rangle + \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt \quad (52)$$

然后用 Cauchy-Schwarz 和光滑性假设界住积分中的每一项。

练习 2：GD 在二次函数上的精确收敛因子

考虑 $f(\theta) = \frac{1}{2}\theta^\top A\theta$, $A = \text{diag}(\lambda_1, \dots, \lambda_d)$ ($\lambda_i > 0$)。写出 GD 在第 i 个坐标上的递推，并证明 $|\theta_{T,i}| = |1 - \eta\lambda_i|^T |\theta_{0,i}|$ 。给出最优步长 η 使 $\max_i |1 - \eta\lambda_i|$ (即谱半径) 最小化，并证明该步长下收敛因子为 $(\kappa - 1)/(\kappa + 1)$ ，其中 $\kappa = \max_i \lambda_i / \min_i \lambda_i$ 。

练习 3：条件数与梯度的几何

对 $f(\theta) = \frac{1}{2}\theta^\top Q \text{diag}(1, \kappa) Q^\top \theta$ (Q 为正交旋转矩阵)，分别在 $Q = I$ (坐标对齐) 和 Q 为任意旋转两种情况下，画出 GD 的前 10 步轨迹。解释：为什么旋转不影响 GD 的收敛 (GD 是旋转不变的)，但会影响对角预条件方法 (如 Adam) 的表现？

提示：GD 的更新 $\theta_{t+1} = \theta_t - \eta A \theta_t$ 在坐标变换 $y = Q^\top \theta$ 下变为 $y_{t+1} = y_t - \eta \text{diag}(1, \kappa) y_t$ 。GD 的 dynamic 在旋转下等价，因为预条件器是 I (它是坐标不变的)。

练习 4：SGD 方差的实验测量

在二维二次函数 $f(\theta) = \frac{1}{2}\theta^\top A\theta$ 上，向梯度添加独立高斯噪声 $\mathcal{N}(0, \sigma^2 I)$ 来模拟随机梯度。固定步长 η ，运行 SGD 1000 步后记录最终误差 $f(\theta_T) - f^*$ 。绘制「最终误差 vs η 」的曲线，注明最优步长的位置，并验证：最终误差的下界为 $\eta\sigma^2/2$ (不随 T 消失的部分)。

练习 5：Gradient Descent + Momentum 的特征分析

考虑一维二次函数 $f(\theta) = \frac{\lambda}{2}\theta^2$ ($\lambda > 0$)。将 GD + Momentum 写为状态空间方程：

$$\begin{pmatrix} \theta_{t+1} \\ d_{t+1} \end{pmatrix} = \begin{pmatrix} 1 & -\eta \\ \beta\lambda & \beta - \eta\lambda \end{pmatrix} \begin{pmatrix} \theta_t \\ d_t \end{pmatrix}. \quad (53)$$

计算该系统矩阵的特征值，找出使谱半径最小的 η 和 β 。证明最佳收敛因子与 GD 的对比是 $\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ vs $\frac{\kappa-1}{\kappa+1}$ (对多维推广的结果)。

工程练习

工程任务 1：实现并可视化 GD

用 NumPy 或 PyTorch 实现以下实验：

- (1) 定义二次函数 $f(\theta) = \frac{1}{2}\theta^\top A\theta$ ，其中 $A = \text{diag}(1, 100)$ ($\kappa = 100$)。
- (2) 以不同步长 $\eta \in \{0.01, 0.1, 0.5, 1.0, 1.5, 1.9, 2.1\} \times (1/\lambda_{\max})$ 运行 GD。
- (3) 绘制不同 η 下 $f(\theta_t)$ vs 迭代次数的 semilogy 图。

(4) 验证： $\eta \geq 2/L$ 时发散； $\eta = 1/L$ 时稳定下降。

(5) 在等高线图上绘出 GD 的前 20 步轨迹。

工程任务 2：SGD 的噪声与方差

(1) 在任务 1 的二次函数上实现 SGD（梯度添加高斯噪声 $\mathcal{N}(0, \sigma^2 I)$ ）。

(2) 固定 $\eta = 1/L$ ，变化 $\sigma^2 \in \{0.1, 1, 10\}$ ，绘制 $f(\theta_t)$ 的轨迹（多次运行，绘均值和标准差带）。

(3) 画 $\log(f(\theta_T) - f^*)$ vs $\log T$ 的图，验证 SGD 的斜率约为 $-1/2$ （即 $\mathcal{O}(1/\sqrt{T})$ ），与 GD 的斜率 -1 （即 $\mathcal{O}(1/T)$ ）形成对比。

工程任务 3：Momentum 与 Nesterov 的加速效果

(1) 在 $\kappa = 1000$ 的二维二次函数上比较 GD、Momentum ($\beta = 0.9$)、Nesterov 的收敛。

(2) 在同一图上绘出三者的 $\log(f(\theta_t) - f^*)$ vs 迭代数曲线。

(3) 验证 Momentum/Nesterov 收敛所需的迭代数约为 GD 的 $1/\sqrt{\kappa}$ 因子。

(4) 在轨迹等高线图中观察 Momentum 的「过冲」现象（越过最优点后再折返）与 GD 的「之字形」轨迹。

工程任务 4：学习率调度对比

在非强凸函数（如 logistic regression loss）上比较：

- 固定步长 SGD
- SGD + warmup + cosine decay
- SGD + step decay

绘制 loss 曲线（semi-log），观察调度对收敛速度和最终精度的改善。

阅读清单 (Week 1)

- Bubeck (2015) — *Convex Optimization: Algorithms and Complexity*, §3.1–3.3. 光滑性的三种等价刻画、梯度下降的收敛分析。

- **Nesterov (2018)** — *Lectures on Convex Optimization*, §1.2, §2.1. 凸分析基础、梯度方法的 oracle 下界。
- **Boyd & Vandenberghe (2004)** — *Convex Optimization*, §9.2–9.3. 梯度下降、最陡下降、条件数的几何解释。
- **Garrigos & Gower (2023)** — *Handbook of Convergence Theorems for Gradient Descent*. 一份优秀的 GD/SGD 收敛定理速查手册。