

深度学习优化器：从 Adam 到 Muon 与 PolarGrad

高密度每日学习计划（8 周 · 每日 5–7 小时）

基于老师课件综合制定 · 每周 6 天学习 + 周日休息

教材参考：Bubeck (2015)、Nesterov (2018)、Boyd & Vandenberghe (2004)、张贤科《高等线性代数》、Golub & Van Loan《Matrix Computations》、Horn & Johnson《Matrix Analysis》

2026 年 7 月 10 日

总体说明

- 时间安排：**每周一至周六学习，周日休息。每天 5–7 小时（上午 2.5h + 下午 2.5h + 晚上 1–2h 复习）。
- 学习方式：**理论推导（上午）+ 工程实践（下午）+ 总结笔记（晚上）。
- 核心资料：**综合课件 `optimizer_lecture_v2.pdf`（13 页）+ 第一周讲义 `week1.pdf`（15 页）+ 线性代数补充 `linear_algebra_supplement.pdf`（19 页）。
- 三个递进层级：**Adam/AdamW（对角预条件）→ Shampoo（Kronecker 结构预条件）→ SOAP/Muon/PolarGrad（特征基 + 谱正交化 + 极分解）。
- 每周日：**回顾本周笔记、查漏补缺、整理代码仓库。

第 1 周：GD/SGD 的理论基石

学习目标：深入理解梯度下降收敛理论，掌握下降引理推导，理解条件数如何决定收敛速度。

周一：L-光滑性与下降引理

第 1 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 复习多变量微积分：梯度、Hessian、Taylor 展开
- ☐ [阅读] 阅读 Bubeck (2015) §3.1–3.2 ——光滑凸优化的基本设定
- ☐ [理论] 精读 week1.pdf §1–§2.1：基本记号、二次函数作为分析工具
- ☐ [理论] 手推 L -光滑性的三个等价刻画（梯度 Lipschitz $\Leftrightarrow$ 二次上界 $\Leftrightarrow$ co-coercivity）
- ☐ [理论] 完成 week1.pdf 练习 1：用积分形式 Taylor 公式逐行验证下降引理

第 1 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 搭建 Python 实验环境：安装 PyTorch、NumPy、Matplotlib
- ☐ [工程] 构造二维二次函数 $f(\theta) = \frac{1}{2}\theta^\top A\theta$, $A = \text{diag}(1, 100)$ ($\kappa = 100$)
- ☐ [工程] 实现最简 GD 优化器（for 循环 + 梯度更新）
- ☐ [工程] 验证： $\eta \geq 2/L$ 时发散； $\eta = 1/L$ 时稳定下降

第 1 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 手写下降引理完整证明（白纸默写，不看笔记）
- ☐ [笔记] 整理今天学到的 3 个等价刻画，画一张关系图

周二：强凸性与条件数

第 2 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 精读 week1.pdf §2.2–§2.3： μ -强凸性的定义与等价刻画
- ☐ [理论] 推导强凸函数的梯度单调性不等式 $\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \mu \|x - y\|^2$
- ☐ [理论] 深入理解条件数 $\kappa = L/\mu$ 的几何含义（最大/最小特征值比 $\rightarrow$ 椭球的长短轴比）

☐ [理论] 研读 week1.pdf 中条件数与「窄谷」的等高线图示

☐ [笔记] 手推：对 $f = \frac{1}{2}\theta^\top A\theta$ ，证明 $\kappa = \lambda_{\max}/\lambda_{\min}$

第 2 天 · 下午 (2.5h) ——工程实践

☐ [工程] 扩展实验：构造 $\kappa \in \{1, 5, 10, 50, 100, 500, 1000\}$ 的多个二次函数

☐ [工程] 对每个 κ 运行 GD ($\eta = 1/L$)，绘制 $\log(f(\theta_t) - f^*)$ vs 迭代数曲线

☐ [工程] 在等高线图上画出 GD 前 20 步轨迹，观察「之字形」现象

☐ [工程] 验证：收敛步数随 κ 线性增长

☐ [工程] 实现不同步长选择： $\eta = 1/L$ 、 $\eta = 2/(\mu + L)$ (最优)、 $\eta = 1/\mu$ ，对比收敛速度

第 2 天 · 晚上 (1h) ——复习总结

☐ [笔记] 用自己的话写出：为什么条件数是优化的核心挑战？预条件方法试图做什么？

☐ [笔记] 整理 GD 在凸/强凸下的收敛率对比表

周三：GD 完整收敛证明

第 3 天 · 上午 (2.5h) ——理论推导

☐ [理论] 精读 week1.pdf §3：下降引理到 GD 收敛的完整证明链

☐ [理论] 手推凸情形 GD 的 $\mathcal{O}(1/T)$ 收敛率 (telescoping sum 技巧)

☐ [理论] 手推强凸情形 GD 的线性收敛： $\|\theta_T - \theta^*\|^2 \leq \left(\frac{\kappa-1}{\kappa+1}\right)^{2T} \|\theta_0 - \theta^*\|^2$

☐ [理论] 理解 co-coercivity 不等式在证明中的关键作用

☐ [理论] 完成 week1.pdf 练习 2：二次函数上 GD 的精确收敛因子

第 3 天 · 下午 (2.5h) ——工程实践

☐ [工程] 完成 week1.pdf 工程任务 1：实现并可视化 GD

☐ [工程] 以 $\eta \in \{0.01, 0.1, 0.5, 1.0, 1.5, 1.9, 2.1\} \times (1/\lambda_{\max})$ 运行 GD

☐ [工程] 绘制不同 η 下 $f(\theta_t)$ vs 迭代次数的 semilogy 图

☐ [工程] 实现 Polyak 平均 $\bar{\theta}_T = \frac{1}{T} \sum_t \theta_t$ ，对比输出质量

第 3 天 · 晚上 (1h) ——复习总结

☐ [笔记] 默写 GD 在凸 + 光滑下的完整证明 (从下降引理到 $\mathcal{O}(1/T)$)

☐ [笔记] 整理 telescoping sum 和 Jensen 不等式的使用时机

周四：SGD 与随机近似的收敛理论

第 4 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 精读 week1.pdf §4: 从 GD 到 SGD, 噪声的引入
- ☐ [理论] 理解两个标准假设: 无偏性 $\mathbb{E}[g_t|\theta_t] = \nabla f(\theta_t)$ 和有界方差
- ☐ [理论] 手推 SGD 在凸光滑条件下的收敛界

$$\mathbb{E}[f(\bar{\theta}_T)] - f(\theta^*) \leq \frac{\|\theta_0 - \theta^*\|^2}{2\eta T} + \frac{\eta\sigma^2}{2}$$

- ☐ [理论] 理解方差项 $\frac{\eta\sigma^2}{2}$ 不随 T 消失——这是 SGD 的根本瓶颈
- ☐ [理论] 推导最优步长 $\eta = \frac{D}{\sigma\sqrt{T}}$, 得 $\mathcal{O}(1/\sqrt{T})$

第 4 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 实现 SGD (梯度添加高斯噪声 $\mathcal{N}(0, \sigma^2 I)$)
- ☐ [工程] 固定 $\eta = 1/L$, 变化 $\sigma^2 \in \{0.1, 1, 10\}$, 绘制轨迹 (多次运行 + 标准差带)
- ☐ [工程] 画 $\log(f(\theta_T) - f^*)$ vs $\log T$, 验证 SGD 斜率约 $-1/2$, GD 斜率约 -1
- ☐ [工程] 实现递减步长 $\eta_t = 1/(L+t)$ 和 $\eta_t = 1/\sqrt{t}$, 对比常数步长

第 4 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 对比 GD vs SGD: 收敛率、每步计算量、总样本复杂度
- ☐ [笔记] 完成 week1.pdf 练习 4: SGD 方差的实验测量

周五：Momentum、Nesterov 加速与学习率调度

第 5 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 精读 week1.pdf §5-§6: Momentum 和 Nesterov 加速梯度的完整分析
- ☐ [理论] 推导 Momentum 在特征基下解耦为 d 个独立的二阶递推
- ☐ [理论] 证明 Momentum 将 κ 替换为 $\sqrt{\kappa}$ ($\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ vs $\frac{\kappa-1}{\kappa+1}$)
- ☐ [理论] 理解 Nesterov 「前瞻梯度」的巧妙之处
- ☐ [理论] 完成 week1.pdf 练习 5: Momentum 状态空间特征分析
- ☐ [理论] 学习 warmup + cosine decay 的数学形式与动机

第 5 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现 Momentum ($\beta = 0.9$) 和 Nesterov 优化器
- ☐ [工程] 在 $\kappa = 1000$ 的二维二次函数上对比 GD、Momentum、Nesterov
- ☐ [工程] 绘制 $\log(f(\theta_t) - f^*)$ 对比曲线, 验证 Momentum/Nesterov 加速倍数
- ☐ [工程] 在等高线图中观察 Momentum 的「过冲」与 GD 的「之字形」
- ☐ [工程] 在非强凸函数 (logistic regression loss) 上比较 3 种学习率调度

第 5 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 整理 $\text{GD} \rightarrow \text{Momentum} \rightarrow \text{Nesterov}$ 的演化逻辑链
- ☐ [笔记] 绘制收敛率对比表: 凸情形 $\mathcal{O}(1/T)$ vs $\mathcal{O}(1/T^2)$, 强凸情形 κ vs $\sqrt{\kappa}$

周六: 综合实验 + 第 1 周收尾**第 6 天 · 上午 (2.5h) —— 综合理论复习**

- ☐ [理论] 精读 optimizer_lecture_v2.pdf §2-§4: 随机优化基础 (SAA、Sub-Gaussian、浓度不等式)
- ☐ [理论] 手推 Hoeffding 不等式从 Chernoff bound 出发的完整证明
- ☐ [理论] 对比 SAA 和 SA 两种范式的样本复杂度
- ☐ [理论] 理解 Sub-Gaussian 随机变量的定义与常见实例

第 6 天 · 下午 (3h) —— 综合工程实践

- ☐ [工程] 统一接口: 在单一文件中实现 GD / SGD / Momentum / Nesterov, API 对齐 torch.optim
- ☐ [工程] 实现完整的实验脚本: 支持切换函数 (凸/强凸/非凸)、优化器、参数配置
- ☐ [工程] 制作等高线轨迹图对比集 (一张图包含 4 种优化器在 $\kappa = 100$ 下的轨迹)
- ☐ [工程] 完成 week1.pdf 工程任务 3 (Momentum vs Nesterov) 和任务 4 (学习率调度对比)
- ☐ [笔记] 整理第 1 周所有代码到 week1_optimizers/ 文件夹

[完成] 第 1 周核心交付物: 下降引理手写证明 + GD/SGD 收敛率完整推导 + 4 种优化器实现 + 等高线轨迹对比图 + 条件数影响验证报告

第 2 周：Mirror Descent 与 AdaGrad 的 Regret 分析

学习目标：理解「选优化器就是选几何」的核心思想，掌握 AdaGrad 的 regret bound 推导，能阐明 Mirror Descent 如何通过改变 Bregman divergence 改变优化几何。

周一：Bregman Divergence 与 Mirror Descent 框架

第 7 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 学习 Bregman Divergence 的定义： $D_\psi(x, y) = \psi(x) - \psi(y) - \langle \nabla \psi(y), x - y \rangle$
- ☐ [理论] 证明 Bregman divergence 的非负性和非对称性
- ☐ [理论] 手推三点恒等式 (Bregman 的核心工具)： $D_\psi(z, x) - D_\psi(z, y) - D_\psi(y, x) = \langle \nabla \psi(y) - \nabla \psi(x), z - y \rangle$
- ☐ [理论] 理解 Mirror Descent 更新： $\theta_{t+1} = \arg \min_{\theta} \{ \eta \langle g_t, \theta \rangle + D_\psi(\theta, \theta_t) \}$
- ☐ [理论] 推导：取 $\psi(\theta) = \frac{1}{2} \|\theta\|_2^2 \rightarrow$ MD 退化为标准 GD
- ☐ [理论] 推导：取 $\psi(\theta) = \frac{1}{2} \theta^\top H \theta \rightarrow$ MD 退化为预条件 GD

第 7 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 实现 Mirror Descent 框架 (支持可插拔的 ψ 函数)
- ☐ [工程] 取 $\psi(\theta) = \frac{1}{2} \|\theta\|_2^2$ (对应 GD)，验证退化正确
- ☐ [工程] 取 $\psi(\theta) = \frac{1}{2} \theta^\top H \theta$ (对应预条件 GD)，验证方向等价于 Newton 步
- ☐ [工程] 可视化 Bregman divergence 在 1D 情况下的几何 (两个不同 ψ 的对比)

第 7 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 手写 MD 框架笔记：更新公式推导 + 退化为 GD/预条件 GD 的过程
- ☐ [笔记] 用自己的话解释「选优化器就是选几何」

周二：在线凸优化与 Regret 分析

第 8 天 · 上午 (2.5h) ——理论推导

- ☐ [理论] 学习在线凸优化 (OCO) 设定：每个时刻选择 θ_t ，观测损失 f_t ，目标是最小化 regret
- ☐ [理论] 理解 Regret 的定义： $R_T = \sum_{t=1}^T f_t(\theta_t) - \min_{\theta} \sum_{t=1}^T f_t(\theta)$
- ☐ [理论] 学习 Online Gradient Descent 的 regret bound 推导： $R_T \leq \frac{\|\theta_1 - \theta^*\|^2}{2\eta} + \frac{\eta}{2} \sum_t \|g_t\|^2$

- ☐ [理论] 理解步长 $\eta = \mathcal{O}(1/\sqrt{T})$ 给出 $\mathcal{O}(\sqrt{T})$ 的 regret 的推导逻辑
- ☐ [理论] 学习 FTRL (Follow-The-Regularized-Leader) 基本概念

第 8 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现 Online Gradient Descent 在简单在线回归问题上的实验
- ☐ [工程] 追踪并绘制累计 regret 随时间的变化曲线
- ☐ [工程] 对比不同步长选择 (固定 vs $\mathcal{O}(1/\sqrt{t})$) 的 regret 差异
- ☐ [工程] 实现 FTRL 的简化版并在同一问题上对比

第 8 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 整理 OGD regret bound 推导的完整骨架
- ☐ [笔记] 画出 OCO 设定的时间线示意图

周三: AdaGrad 的 Regret Bound (上)

第 9 天 · 上午 (2.5h) —— 理论推导

- ☐ [阅读] 精读 Duchi et al. (2011) AdaGrad 论文的 Theorem 1-3
- ☐ [理论] 理解 AdaGrad 的核心思想: 用梯度平方累积量逐坐标调整步长
- ☐ [理论] 推导对角 AdaGrad 的更新公式和 regret bound 骨架

$$R_T \leq \sqrt{2} D_\infty \sum_{i=1}^d \sqrt{\sum_{t=1}^T g_{t,i}^2}$$

- ☐ [理论] 理解为什么这个 bound 在稀疏梯度下远优于 SGD ($\sqrt{\#\text{nonzero}}$ 的差距)
- ☐ [理论] 研读在线预条件次梯度法的 regret bound 抽象形式 (课件 §5 末)

第 9 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现对角 AdaGrad: 维护 $s_{t,i} = \sum_{k \leq t} g_{k,i}^2$, 更新 $\theta_{t+1,i} = \theta_{t,i} - \eta g_{t,i} / \sqrt{s_{t,i} + \varepsilon}$
- ☐ [工程] 构造稀疏梯度场景: 每个样本只激活 5% 的坐标 (模拟 NLP 中稀有特征的场景)
- ☐ [工程] 在该场景上比较 SGD vs AdaGrad 的收敛速度
- ☐ [工程] 可视化每坐标的有效学习率 $\eta / \sqrt{s_{t,i}}$ 随时间的变化

第 9 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 写出 AdaGrad regret bound 推导的骨架 (关键步骤, 不要求每一步细节)
- ☐ [笔记] 分析: 为什么稀疏性下 AdaGrad 的优势巨大?

周四：AdaGrad 的 Regret Bound（下）与 RMSProp

第 10 天 · 上午（2.5h）——理论推导

- ☐ [理论] 完成 AdaGrad full-matrix 版本的 regret bound 推导阅读
- ☐ [理论] 理解 AdaGrad 的实际问题： s_t 单调递增 $\rightarrow$ 有效学习率持续下降 $\rightarrow$ 训练过早停止
- ☐ [理论] 学习 RMSProp 的解决方案： $s_t = \beta s_{t-1} + (1 - \beta) g_t^{\odot 2}$ （EMA 替代累加）
- ☐ [理论] 理解 EMA 的遗忘机制如何解决 AdaGrad 的「学习率消失」问题
- ☐ [理论] 对比 AdaGrad（凸优化理论完备）vs RMSProp（深度学习实践有效）

第 10 天 · 下午（2.5h）——工程实践

- ☐ [工程] 实现 RMSProp 优化器
- ☐ [工程] 在非稀疏连续优化问题上对比 AdaGrad vs RMSProp：观察 AdaGrad 过早停止
- ☐ [工程] 可视化 AdaGrad（持续下降）vs RMSProp（稳定）的有效学习率演化
- ☐ [工程] 复现 AdaGrad 在稀疏场景的优势 + RMSProp 在非稀疏场景的优势

第 10 天 · 晚上（1h）——复习总结

- ☐ [笔记] 制作 AdaGrad $\rightarrow$ RMSProp $\rightarrow$ Adam 的演化图（每个节点的动机和改进）

周五：集中复习 Mirror Descent 视角

第 11 天 · 上午（2.5h）——综合理论复习

- ☐ [理论] 重新推导 MD 框架下的 regret bound（用 Bregman divergence 替代欧氏距离）
- ☐ [理论] 理解：MD 的 regret bound 是 $\frac{1}{\eta} D_\psi(\theta^*, \theta_1) + \frac{\eta}{2} \sum_t \|g_t\|_*^2$
- ☐ [理论] 选取不同 $\psi \rightarrow$ 不同的 $D_\psi \rightarrow$ 不同的距离度量 $\rightarrow$ 不同的几何适应性
- ☐ [理论] 推导 ExpGrad（ ψ 取负熵 $\rightarrow$ 概率单纯形上的在线学习）
- ☐ [理论] 理解：为什么 ψ 的选择决定了优化器对数据几何的适应性

第 11 天 · 下午（2.5h）——综合工程实践

- ☐ [工程] 完善 Mirror Descent 实现，添加 ExpGrad（负熵 mirror map）
- ☐ [工程] 在概率单纯形约束的在线问题上对比 OGD vs ExpGrad

- ☐ [工程] 整理 AdaGrad / RMSProp 代码到统一接口
- ☐ [工程] 完成完整对比实验: SGD / Momentum / Nesterov / AdaGrad / RMSProp 在稀疏 + 稠密场景下

第 11 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 绘制 MD 框架全景图: $\psi \rightarrow D_\psi \rightarrow$ 更新规则 $\rightarrow$ 适应场景
- ☐ [笔记] 检查第 2 周所有推导是否完成, 查漏补缺

周六: 第 2 周收尾 + Adam 预习

第 12 天 · 上午 (2.5h) —— 收尾复习

- ☐ [理论] 完成第 2 周所有未完成的推导
- ☐ [理论] 预习 Adam 论文摘要和 introduction (了解 Adam = RMSProp + Momentum)
- ☐ [理论] 写出 AdaGrad $\rightarrow$ RMSProp $\rightarrow$ Adam 的递推公式对比

第 12 天 · 下午 (2.5h) —— 代码整理 + 预习实验

- ☐ [工程] 整理第 2 周所有代码到 week2_mirror_adagrad/ 文件夹
- ☐ [工程] 为所有 5 个优化器写统一接口的单元测试 (toy problem 上的预期行为)
- ☐ [工程] 预习: 用 PyTorch 的 `torch.optim.Adam` 在 MNIST 上跑一个 baseline

[完成] 第 2 周核心交付物: MD 框架完整笔记 + AdaGrad regret bound 推导骨架 + RMSProp/AdaGrad 实现 + 稀疏场景对比实验 + 5 种优化器统一接口

第 3 周：Adam / AdamW / AMSGrad

学习目标：彻底理解 Adam 的每个组件（EMA、偏差修正、对角缩放）及其理论陷阱。
能从实验中解释「Adam 为什么怕旋转」。

周一：Adam 完整推导

第 13 天 · 上午 (2.5h) —— 理论推导

☐ [阅读] 精读 Kingma & Ba (2014) Adam 论文全文（重点 Section 2-4）

☐ [理论] 手推 Adam 偏差修正的完整证明

$$\mathbb{E}[m_t] = (1 - \beta_1) \sum_{k=1}^t \beta_1^{t-k} \mathbb{E}[g_k] = (1 - \beta_1^t) \mu \implies \hat{m}_t = \frac{m_t}{1 - \beta_1^t}$$

☐ [理论] 同理验证 $\hat{v}_t = v_t / (1 - \beta_2^t)$ 的修正

☐ [理论] 理解 Adam 的预条件结构： $P_t = \text{diag}(\hat{v}_t + \epsilon^2)^{-1/2}$

☐ [理论] 写出 Adam 的完整更新公式并标注每个参数的角色

第 13 天 · 下午 (2.5h) —— 工程实践

☐ [工程] 从零实现 Adam（不使用框架，纯 NumPy/PyTorch 张量操作）

☐ [工程] 特别关注偏差修正的实现（冷启动行为）

☐ [工程] 在二维二次函数 $\kappa = 100$ 上运行 Adam，与 SGD/Momentum 对比轨迹

☐ [工程] 可视化 $m_t, v_t, \hat{m}_t, \hat{v}_t$ 在训练过程中的演化

第 13 天 · 晚上 (1h) —— 复习总结

☐ [笔记] 默写 Adam 算法框（伪代码级别）

☐ [笔记] 用自己的话解释：偏差修正为什么必要？去掉会怎样？

周二：Adam 的理论视角——Gauss-Newton 联系

第 14 天 · 上午 (2.5h) —— 理论推导

☐ [理论] 精读 optimizer_lecture_v2.pdf §5 末：Adam 与 Gauss-Newton 联系的深入分析

☐ [理论] 理解广义 Gauss-Newton (GGN) 矩阵： $G(w) = J(w)^\top H_\ell(w) J(w)$

☐ [理论] 推导 GGN 对角元与梯度平方的关系

- ☐ [理论] 理解核心洞察：Adam 本质上在用对角 **Gauss-Newton** 做预条件——比「对角 Hessian」更准确
- ☐ [理论] 理解 Fisher 信息矩阵 vs GGN vs 经验 Fisher ($\mathbb{E}[gg^\top]$) 的关系
- ☐ [理论] 阅读课件 §3–§4: Weight Decay、Gradient Clipping 的数学动机

第 14 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 在 MNIST 两层 MLP 上用 Adam 训练，记录并可视化每层权重的 v_t 分布
- ☐ [工程] 比较不同 β_2 值 (0.9, 0.99, 0.999, 0.9999) 对 v_t 演化速度的影响
- ☐ [工程] 实现 Gradient Clipping (value clipping 和 norm clipping)
- ☐ [工程] 在 RNN 玩具问题上测试 clipping 的效果

第 14 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 绘制 $\text{GGN} \rightarrow \text{Fisher} \rightarrow \mathbb{E}[g^2]$ 的关系图
- ☐ [笔记] 整理 Weight Decay 和 Gradient Clipping 的公式卡片

周三：AdamW ——Weight Decay 解耦

第 15 天 · 上午 (2.5h) ——理论推导

- ☐ [阅读] 精读 Loshchilov & Hutter (2017) AdamW 论文 (重点 Section 2)
- ☐ [理论] 手推 L2 正则 + Adam 的不等价性分析

$$\Delta w_t = -\eta \frac{\nabla \mathcal{L}(w_t) + \lambda w_t}{\sqrt{\hat{v}_t} + \varepsilon} \neq (1 - \eta\lambda)w_t - \eta \frac{\nabla \mathcal{L}(w_t)}{\sqrt{\hat{v}_t} + \varepsilon}$$

- ☐ [理论] 理解：对梯度大的坐标， $\sqrt{\hat{v}_t}$ 大，正则化被削弱；对梯度小的坐标反而加强
- ☐ [理论] 写出 AdamW 的解耦更新公式： $w_{t+1} = (1 - \eta\lambda)w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}$

第 15 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 实现 AdamW (在 Adam 基础上解耦 weight decay)
- ☐ [工程] 构造实验：L2-Adam vs AdamW 在相同 λ 下的 loss 和验证精度对比
- ☐ [工程] 可视化每个参数实际接收的正则化强度 $\eta\lambda/\sqrt{\hat{v}_{t,i}} + \varepsilon$ (L2) vs $\eta\lambda$ (AdamW)
- ☐ [工程] 在 MNIST 上验证 AdamW 的泛化优势

第 15 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 用自己的话解释：L2 正则和 Weight Decay 为什么在 Adam 中不等价而在 SGD 中等价？

周四：AMSGrad ——Adam 收敛理论的陷阱

第 16 天 · 上午 (2.5h) ——理论推导

- ☐ [阅读] 精读 Reddi et al. (2018) AMSGrad 论文 (重点 Adam 反例的构造)
- ☐ [理论] 理解 Adam 原始收敛证明的错误: 「有效学习率不单调」为什么可能破坏收敛
- ☐ [理论] 构造 Adam 发散的反例 (Reddi et al. 中的简单在线问题)
- ☐ [理论] 理解 AMSGrad 的修正: $\hat{v}_t = \max(\hat{v}_{t-1}, v_t)$ 确保单调性
- ☐ [理论] 对比 Adam vs AMSGrad 的 regret bound 差异

第 16 天 · 下午 (2.5h) ——工程实践

- ☐ [工程] 实现 AMSGrad (max 操作确保 $\hat{v}_t$ 非减)
- ☐ [工程] 在 Reddi 反例上测试: Adam (可能发散) vs AMSGrad (应稳定收敛)
- ☐ [工程] 在标准深度学习任务 (MNIST MLP) 上对比三者的实际表现
- ☐ [工程] 可视化 Adam 的 v_t 在反例中下降的坐标 (导致有效学习率上升的坐标)

第 16 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 整理 Adam / AdamW / AMSGrad 三者的公式差异和适用场景表

周五：Adam 旋转敏感性——核心实验日

第 17 天 · 上午 (2.5h) ——理论分析

- ☐ [理论] 精读 linear_algebra_supplement.pdf §8.3: 为什么 Adam 怕旋转
- ☐ [理论] 理解: 对角预条件不是坐标不变的 (coordinate-dependent)
- ☐ [理论] 推导: 对正交变换 $\tilde{\theta} = Q^\top \theta$, Adam 的预条件器变化不是简单的坐标变换
- ☐ [理论] 核心公式: $(Q^\top g_t)^{\odot 2} \neq Q^\top (g_t^{\odot 2})$
- ☐ [理论] 理解 Muon 的协变性对比: $\text{sgn}(Q_L^\top G Q_R) = Q_L^\top \text{sgn}(G) Q_R$

第 17 天 · 下午 (3h) ——旋转敏感性实验

- ☐ [工程] 构造旋转二次函数 $f(x) = \frac{1}{2} x^\top Q \text{diag}(1, \kappa) Q^\top x$
- ☐ [工程] 固定 $\kappa = 100$, 变化旋转角 $\theta \in \{0^\circ, 15^\circ, 30^\circ, 45^\circ, 60^\circ, 75^\circ, 90^\circ\}$

- ☐ [工程] 对每个 θ ，运行 Adam / SGD / Momentum 至收敛，记录步数
- ☐ [工程] 绘制「收敛步数 vs θ 」图，验证 SGD 不变而 Adam 敏感
- ☐ [工程] 单元测试： $\theta = 0^\circ$ （无旋转）且 $\kappa = 1000$ 时，验证 Adam 最差/最好坐标有效学习率比 $\approx \sqrt{1000}$
- ☐ [工程] 在等高线图上画出 Adam 在不同旋转角下的轨迹

第 17 天 · 晚上（1h）——复习总结

- ☐ [笔记] 写一段话解释「为什么 Adam 怕旋转而 SGD 不怕」（这是面试常见问题）

周六：第 3 周收尾 + Adam 综合实验报告

第 18 天 · 上午（2.5h）——理论回顾

- ☐ [理论] 回顾 Adam 的 Gauss-Newton 视角、AdamW 解耦、AMSGrad 修正
- ☐ [理论] 完成课件练习：Adam 在在线凸优化下的 regret bound 形式
- ☐ [理论] 阅读 Adam 的后续变体：Adamax、Nadam、RAdam（了解即可）

第 18 天 · 下午（2.5h）——实验整理

- ☐ [工程] 整理 Adam/AdamW/AMSGrad 实验代码
- ☐ [工程] 撰写 Adam 旋转敏感性实验报告（含图和分析）
- ☐ [工程] 整理代码到 `week3_adam/` 文件夹
- ☐ [工程] 预习：阅读 Shampoo 论文摘要，了解动机

[完成] 第 3 周核心交付物：Adam 偏差修正完整证明 + AdamW/AMSGrad 实现 + 旋转敏感性实验报告（含「步数 vs θ 」图）+ 有效学习率可视化 + Adam/AdamW/AMSGrad 对比表

第 4 周：矩阵分析与 Kronecker 积

学习目标：扎实掌握 Kronecker 积、矩阵函数、向量化等线性代数工具，为理解 Shampoo 做好准备。能不看笔记独立证明 Kronecker 积的 5 条核心性质。

周一：谱分解与矩阵函数

第 19 天 · 上午 (2.5h) —— 理论推导

- ☐ [理论] 精读 `linear_algebra_supplement.pdf` §1: 特征值与谱分解
- ☐ [理论] 完整手推实对称矩阵谱定理的证明 (特征值为实数 + 特征向量正交 + 正交对角化)
- ☐ [理论] 理解正定/半正定的等价刻画 (特征值、Cholesky、Sylvester 判据)
- ☐ [理论] 精读 §5: 矩阵函数的定义 $\phi(A) = Q\phi(\Lambda)Q^\top$
- ☐ [理论] 强调: $\phi(A)$ 不是逐元素函数! $\exp(A) \neq [e^{a_{ij}}]$
- ☐ [理论] 掌握常用矩阵函数: $A^{-1}, A^{-1/2}, A^{-1/4}, A^{1/4}$

第 19 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 用 NumPy/PyTorch 实现 `eigendecomposition` 并验证 $A = Q\Lambda Q^\top$
- ☐ [工程] 实现矩阵函数 $\phi(A)$ (通过特征分解)
- ☐ [工程] 验证 $\phi(A)$ vs 逐元素 ϕ 的差异 (构造 2×2 矩阵对比)
- ☐ [工程] 实现 $A^{-1/4}$ 并验证 $(A^{-1/4})^4 \approx A^{-1}$
- ☐ [工程] 实验: 不同 ε 对 $A + \varepsilon I$ 条件数的影响 ($\varepsilon \in \{10^{-6}, 10^{-4}, 10^{-2}, 1\}$)

第 19 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 默写谱定理的完整证明 (3 个部分)
- ☐ [笔记] 制作矩阵函数 vs 逐元素函数的对比表

周二：SVD 完整推导

第 20 天 · 上午 (2.5h) —— 理论推导

- ☐ [理论] 精读 `linear_algebra_supplement.pdf` §2: SVD 的构造性证明
- ☐ [理论] 手推: 利用 $G^\top G$ 的谱分解构造 SVD (完整证明)

- ☐ [理论] 理解 SVD 的几何含义：旋转 $\rightarrow$ 缩放 $\rightarrow$ 旋转
- ☐ [理论] 掌握 Eckart-Young 定理：截断 SVD 是最佳低秩近似
- ☐ [理论] 理解 Gram 矩阵的优化含义： $G_t G_t^\top$ vs $G_t^\top G_t$ 在 Shampoo 中的角色
- ☐ [理论] 完成线性代数补充练习 2：SVD 唯一性的条件

第 20 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现 SVD 并通过几何可视化：在 $\mathbb{R}^2$ 中画单位圆及其在 G 下的像（椭圆）
- ☐ [工程] 标注左右奇异向量的方向和奇异值数值
- ☐ [工程] 实现幂迭代法（power iteration）计算最大奇异值
- ☐ [工程] 验证 Eckart-Young：对随机矩阵做截断 SVD，计算近似误差 vs 理论下界
- ☐ [工程] 可视化梯度矩阵 G_t 的奇异值分布直方图（用 MNIST 训练的中间结果）

第 20 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 默写 SVD 的构造性证明
- ☐ [笔记] 整理 SVD vs 谱分解 vs 极分解的适用条件和公式对比

周三：三类矩阵范数 + 极分解

第 21 天 · 上午 (2.5h) —— 理论推导

- ☐ [理论] 精读 linear_algebra_supplement.pdf §3-§4：矩阵范数与极分解
- ☐ [理论] 掌握三类矩阵范数的定义和关系
 - Frobenius: $\|G\|_F = \sqrt{\sum \sigma_i^2}$
 - 谱范数: $\|G\|_{op} = \sigma_{\max}$
 - 核范数: $\|G\|_* = \sum \sigma_i$
- ☐ [理论] 证明关系不等式: $\|G\|_{op} \leq \|G\|_F \leq \sqrt{r} \|G\|_{op}$
- ☐ [理论] 手推谱范数与核范数的对偶性: $\sup_{\|X\|_{op} \leq 1} \langle G, X \rangle = \|G\|_*$
- ☐ [理论] 学习极分解 $G = UP$ (U 正交, $P \succeq 0$)，与 SVD 的关系: $U_{\text{polar}} = U_{\text{SVD}} V_{\text{SVD}}^\top$
- ☐ [理论] 注意易错点：SVD 的 U 和极分解的 U 是不同的矩阵！

第 21 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现三类矩阵范数的计算并验证关系不等式
- ☐ [工程] 实现极分解（通过 SVD: $U = U_{\text{SVD}} V_{\text{SVD}}^{\top}$, $P = V_{\text{SVD}} \Sigma V_{\text{SVD}}^{\top}$ ）
- ☐ [工程] 验证 $\|UV^{\top}\|_{\text{op}} = 1$ 且 $\langle G, UV^{\top} \rangle = \|G\|_*$ （对偶性的数值验证）
- ☐ [工程] 可视化：对 2×2 矩阵，画出其极分解的 U （旋转）和 P （拉伸）的几何效果

第 21 天 · 晚上（1h）——复习总结

- ☐ [笔记] 整理 SVD vs 极分解的辨析表（易错表格已在课件中，补充自己的理解）
- ☐ [笔记] 完成线性代数补充练习 3：对 2×2 矩阵直接验证核范数对偶性

周四：Kronecker 积——理论与证明

第 22 天 · 上午（2.5h）——理论推导

- ☐ [理论] 精读 linear_algebra_supplement.pdf §6: Kronecker 积完整版
- ☐ [理论] 学习 Kronecker 积定义: $A \otimes B = [a_{ij}B]_{ij}$
- ☐ [理论] 逐条手推并做笔记——5 条核心性质:
 1. 混合积: $(A \otimes B)(C \otimes D) = AC \otimes BD$
 2. 逆: $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$
 3. 幂函数: $(A \otimes B)^{\alpha} = A^{\alpha} \otimes B^{\alpha}$ （含完整谱分解证明）
 4. 向量化: $\text{vec}(AXB) = (B^{\top} \otimes A) \text{vec}(X)$
 5. 迹关系
- ☐ [理论] 理解性质 3 在 Shampoo 中的关键应用: $L^{-1/4} \otimes R^{-1/4} = (L^{1/2} \otimes R^{1/2})^{-1/4}$

第 22 天 · 下午（2.5h）——工程实践

- ☐ [工程] 用 NumPy 实现 Kronecker 积并逐一验证上述 5 条性质
- ☐ [工程] 验证 $\text{vec}(AXB) = (B^{\top} \otimes A) \text{vec}(X)$ （构造随机矩阵测试）
- ☐ [工程] 实现并验证 $(A \otimes B)^{\alpha} = A^{\alpha} \otimes B^{\alpha}$ （分别计算两边并比较）
- ☐ [工程] 完成线性代数补充练习 4：证明 $\text{rank}(A \otimes B) = \text{rank}(A) \cdot \text{rank}(B)$
- ☐ [工程] 实现 full-matrix AdaGrad 在小规模（ $d \leq 100$ ）问题上的运行，观察 H_t 的存储和计算开销

第 22 天 · 晚上（1h）——复习总结

- ☐ [笔记] 不看笔记，独立在白纸上证明 Kronecker 积的 5 条核心性质
- ☐ [笔记] 解释：为什么 full-matrix AdaGrad 在深度学习中不可行？（存储 $\mathcal{O}(d^2)$ + 矩阵根 $\mathcal{O}(d^3)$ ）

周五：Loewner 偏序与矩阵不等式 + Shampoo 理论基础

第 23 天 · 上午 (2.5h) —— 理论推导

- ☐ [理论] 精读 `linear_algebra_supplement.pdf` §7: Loewner 偏序
- ☐ [理论] 理解 $A \preceq B \iff B - A$ 正半定
- ☐ [理论] 掌握 3 条关键性质：保序、逆变、算子单调性 (Löwner-Heinz 定理)
- ☐ [理论] 手推 Shampoo 核心不等式

$$\frac{1}{r} g g^\top \preceq I_m \otimes (G^\top G), \quad \frac{1}{r} g g^\top \preceq (G G^\top) \otimes I_n$$

- ☐ [理论] 理解这个不等式在 regret bound 证明中的关键作用
- ☐ [理论] 完成线性代数补充练习 6: 对秩-1 矩阵 $G = uv^\top$ 直接验证 Shampoo 不等式

第 23 天 · 下午 (2.5h) —— 工程实践

- ☐ [工程] 实现 Loewner 序的数值验证 (检查 $A \preceq B$ 是否成立)
- ☐ [工程] 对随机梯度矩阵 G_t , 验证 Shampoo 的 Kronecker 不等式在数值上成立
- ☐ [工程] 完成线性代数补充工程练习 1-4 (SVD 幂迭代、矩阵根计算对比、SVD 几何可视化、NS 迭代)
- ☐ [工程] 整理所有线性代数实现到 `week4_linear_algebra/` 文件夹

第 23 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 完成线性代数补充的理论练习 5: Newton-Schulz 的收敛阶分析

周六：第 4 周收尾——线性代数知识地图

第 24 天 · 上午 (2.5h) —— 综合复习

- ☐ [理论] 回顾线性代数补充 §8: 从线性代数到优化器的知识地图
- ☐ [理论] 填写每个优化器依赖的线性代数工具表
- ☐ [理论] 重做第 4 周所有证明 (不看笔记)
- ☐ [理论] 精读 `optimizer_lecture_v2.pdf` §7 (Shampoo 章节) 作为预习

第 24 天 · 下午 (2.5h) —— 测试

- ☐ [工程] 自我测试: 随机抽取一条 Kronecker 性质, 在白板上手推证明

- ☐ [工程] 自我测试：默写 SVD 构造性证明的 3 个步骤
- ☐ [工程] 自我测试：解释 $\text{sgn}(G)$ 与极分解的关系
- ☐ [工程] 预习 Shampoo 算法伪代码，理解 $L^{-1/4}GR^{-1/4}$ 的结构

[完成] 第 4 周核心交付物：Kronecker 积 5 条性质完整证明 + SVD 构造性证明 + 极分解实现 + 矩阵函数验证代码 + 线性代数知识地图 + 所有线性代数练习

第 5 周：实现矩阵版 Shampoo

学习目标：理解 Shampoo 如何用 Kronecker 结构降低 full-matrix 预条件代价，亲手实现并实验。能画出 L_t, R_t 条件数变化图。

周一：Shampoo 理论深度研读

第 25 天 · 上午 (2.5h) —— 理论推导

- [阅读] 精读 Gupta et al. (2018) Shampoo 论文 (完整通读)
- [理论] 理解 full-matrix AdaGrad $\rightarrow$ Shampoo 的 Kronecker 近似推导链
 - 起点: $\text{vec}(W_{t+1}) = \text{vec}(W_t) - \eta(\sum g_s g_s^\top)^{-1/2} \text{vec}(G_t)$
 - Kronecker 近似: $\sum g_s g_s^\top \approx L^{1/2} \otimes R^{1/2}$
 - 因此: $H_t^{-1/2} \approx L^{-1/4} \otimes R^{-1/4}$
 - 利用向量化公式恢复矩阵形式: $W_{t+1} = W_t - \eta L^{-1/4} G R^{-1/4}$
- [理论] 掌握 $-1/4$ 指数的来源: 对 p 阶张量, 每个 mode 用 $A_{t,i}^{-1/(2p)}$
- [理论] 证明: 若 $G = U \Sigma V^\top$, 则 $GG^\top = U \Sigma^2 U^\top$, $G^\top G = V \Sigma^2 V^\top$ (左右因子的非零特征值相同)

第 25 天 · 下午 (2.5h) —— 理解实现细节

- [工程] 在纸上模拟 Shampoo 的一步更新 (小矩阵 2×3 , 手算验证)
- [工程] 画图: L_t 捕获行空间 (输出神经元间相关性)、 R_t 捕获列空间 (输入特征间相关性)
- [工程] 计算 Shampoo vs Adam vs full-matrix AdaGrad 的存储开销对比
- [工程] 写伪代码: Shampoo 的完整算法 (含 EMA 和 eigendecomposition 调度)

第 25 天 · 晚上 (1h) —— 复习总结

- [笔记] 默写 Shampoo 算法框, 标注每个步骤的维度和含义

周二：Shampoo 基础实现

第 26 天 · 上午 (2.5h) —— 编码实现

- [工程] 对单层线性网络 $f(W; x) = Wx$ ($W \in \mathbb{R}^{n \times m}$), 实现简化 Shampoo:
 - 维护 $L_t = \beta L_{t-1} + (1 - \beta) G_t G_t^\top$
 - 维护 $R_t = \beta R_{t-1} + (1 - \beta) G_t^\top G_t$

- 每 K 步用 `torch.linalg.eigh` 计算 $L_t^{-1/4}$ 和 $R_t^{-1/4}$
- 更新: $W_{t+1} = W_t - \eta L_t^{-1/4} G_t R_t^{-1/4}$

☐ [工程] 注意数值稳定性: $L_t + \varepsilon I$ 和 $R_t + \varepsilon I$ 确保正定性

第 26 天 · 下午 (2.5h) —— 调试与验证

- ☐ [工程] 在二次矩阵函数 $f(W) = \frac{1}{2} \|AW - W^*\|_F^2$ 上测试 (A 可控制条件数)
- ☐ [工程] 验证: 当 $A = I$ (条件数 = 1), Shampoo 不劣于 SGD
- ☐ [工程] 验证: 当 A 病态 (条件数很大), Shampoo 优于 Adam
- ☐ [工程] 数值稳定性监控: 每 K 步记录 $\lambda_{\min}$ 、 $\lambda_{\max}$ 、条件数、NaN 检测

第 26 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 整理 Shampoo 实现的注意事项 (damping、EMA 参数、eigh 频率)

周三: Shampoo 在 MNIST 上的实验

第 27 天 · 上午 (2h) —— 实验准备

- ☐ [工程] 搭建 MNIST 两层 MLP 实验环境 (统一数据加载、训练循环、评估流程)
- ☐ [工程] 实现 baseline: AdamW 在 MNIST MLP 上的训练
- ☐ [工程] 将 Shampoo 适配到两层 MLP (每层权重矩阵独立维护 L_t, R_t)

第 27 天 · 下午 (3h) —— 正式实验

- ☐ [工程] 在 MNIST 两层 MLP 上比较 AdamW vs Shampoo 的 loss 曲线和 test accuracy
- ☐ [工程] 记录 wall-clock time: Shampoo 每步比 Adam 慢多少? 总训练时间差多少?
- ☐ [工程] 可视化: 每层 L_t, R_t 的条件数随训练步数的变化
- ☐ [工程] 可视化: 不同参数的有效学习率 (Shampoo 的 $L^{-1/4}(\cdot)R^{-1/4}$ vs Adam 的 $1/\sqrt{\hat{v}}$)

第 27 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 分析实验结果: Shampoo 什么时候赢? 什么时候输? 为什么?

周四：消融实验（一）——基更新频率 K

第 28 天 · 上午（2.5h）——实验

- ☐ [工程] 消融实验：比较 $K \in \{1, 10, 50, 100, 200, 500\}$ 对 Shampoo 的影响
- ☐ [工程] 对每个 K ，记录：最终 loss、收敛所需步数、总 wall-clock time
- ☐ [工程] 绘制「loss vs 步数」和「loss vs wall-clock」的双维度对比图
- ☐ [工程] 观察： $K = 1$ （每步都做 eigh） $\rightarrow$ 计算极慢但收敛最快？还是过拟合噪声？

第 28 天 · 下午（2.5h）——消融实验（二）——Damping ε

- ☐ [工程] 消融实验：比较 $\varepsilon \in \{10^{-8}, 10^{-6}, 10^{-4}, 10^{-2}, 1\}$ 对稳定性的影响
- ☐ [工程] 记录：各 ε 下 L_t, R_t 的有效条件数 $\frac{\lambda_{\max} + \varepsilon}{\lambda_{\min} + \varepsilon}$
- ☐ [工程] 分析： ε 过大（预条件器退化为 I ）vs ε 过小（数值不稳定）的 trade-off
- ☐ [工程] 总结 Shampoo 的最优超参数配置

第 28 天 · 晚上（1h）——复习总结

- ☐ [笔记] 撰写消融实验笔记： K 和 ε 如何影响 loss 收敛和 wall-clock 的 trade-off

周五：Newton-Schulz 迭代替代 eigendecomposition

第 29 天 · 上午（2.5h）——理论学习 + 实现

- ☐ [理论] 学习 Newton-Schulz 迭代用于计算 $A^{-1/4}$ （课件 §11 + 线性代数补充 §5.4）
- ☐ [理论] 推导： $X_{k+1} = \frac{3}{2}X_k - \frac{1}{2}X_k^3 A$ 收敛到 $A^{-1/2}$
- ☐ [理论] 理解如何拓展到 $A^{-1/4}$ ：先算 $A^{-1/2}$ ，再算 $(A^{-1/2})^{1/2}$
- ☐ [工程] 在 Shampoo 中实现 Newton-Schulz 迭代替代 eigh

第 29 天 · 下午（2.5h）——对比实验

- ☐ [工程] 对比：eigendecomposition vs NS 迭代的精度（以 eigh 为 ground truth）
- ☐ [工程] 对比：eigendecomposition vs NS 迭代的 wall-clock time（在不同矩阵大小下）
- ☐ [工程] 决定在你的实验中使用哪种方法并说明理由

第 29 天 · 晚上（1h）——复习总结

- ☐ [笔记] 分析 NS 迭代的优劣：什么时候用 eigh？什么时候用 NS？

周六: Shampoo 实验报告 + 预习 SOAP

第 30 天 · 上午 (2.5h) —— 实验整理

- ☐ [工程] 整理所有 Shampoo 实验数据到统一表格
- ☐ [工程] 制作 Shampoo 实验综合报告: MNIST 对比 + K 消融 + ϵ 消融 + NS vs eigh
- ☐ [工程] 整理代码到 `week5_shampoo/` 文件夹

第 30 天 · 下午 (2.5h) —— 预习 SOAP

- ☐ [阅读] 阅读 Vyas et al. (2024) SOAP 论文的 Introduction 和 Algorithm 部分
- ☐ [理论] 理解 SOAP = Shampoo 的几何 + Adam 的 EMA 平滑
- ☐ [笔记] 写预习笔记: SOAP 和 Shampoo 的关键区别是什么?

[完成] 第 5 周核心交付物: Shampoo 完整实现 + MNIST 实验报告 + K 值消融实验 + ϵ 消融实验 + NS vs eigh 对比 + 条件数演化图

第 6 周：实现简化 SOAP + Muon 入门

学习目标：理解 SOAP 融合 Shampoo 几何与 Adam EMA 的机制，亲手实现并做消融实验。初步学习 Muon 的 Newton-Schulz 正交化原理。

周一：SOAP 理论深度研读

第 31 天 · 上午 (2.5h) —— 理论推导

- ☐ [阅读] 精读 Vyas et al. (2024) SOAP 论文全文
- ☐ [理论] 理解核心动机：Shampoo 给出好坐标系 (Q_L, Q_R) ，但缺乏 EMA 平滑；Adam 有 EMA 但只能对角预条件
- ☐ [理论] 掌握 SOAP 完整算法流程 (4 个步骤):
 1. 维护 L_t, R_t (Shampoo 因子)
 2. 每 K 步计算 Q_L, Q_R (特征基)
 3. 旋转梯度: $\tilde{G}_t = Q_L^\top G_t Q_R$
 4. 在 $\tilde{G}_t$ 上运行 Adam: $\tilde{m}_t, \tilde{v}_t$ 的 EMA
 5. 旋回: $\Delta W_t = Q_L \left(\frac{\hat{\tilde{m}}_t}{\sqrt{\hat{\tilde{v}}_t + \epsilon}} \right) Q_R^\top$
- ☐ [理论] 推导基变换状态迁移公式: $\tilde{m}^{\text{new}} = (Q_L^{\text{new}})^\top Q_L^{\text{old}} \tilde{m}^{\text{old}} (Q_R^{\text{old}})^\top Q_R^{\text{new}}$
- ☐ [理论] 理解: 不迁移状态 $\rightarrow$ 特征向量符号歧义 + 方向错位 $\rightarrow$ loss spike

第 31 天 · 下午 (2.5h) —— 理解实现细节

- ☐ [工程] 在纸上模拟 SOAP 的一步更新 (小矩阵 2×3 , 含基变换的状态迁移)
- ☐ [工程] 画图说明: 特征基 (Q_L, Q_R) 的物理含义? 基变换时 Adam 状态 $\tilde{m}, \tilde{v}$ 为什么需要变?
- ☐ [工程] 比较 Shampoo (用 $L^{-1/4}, R^{-1/4}$ 做特征值缩放) vs SOAP (在特征基内做 Adam) 的关键差异
- ☐ [工程] 写伪代码: SOAP 完整算法 (区分首次和后续基更新)

第 31 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 默写 SOAP 算法框 + 状态迁移公式

周二：SOAP 基础实现

第 32 天 · 上午（2.5h）——编码实现

- ☐ [工程] 在 Week 5 的 Shampoo 代码基础上，实现 SOAP：
 - 每 K 步计算 Q_L, Q_R (`torch.linalg.eigh`)
 - 每步计算 $\tilde{G}_t = Q_L^\top G_t Q_R$
 - 维护 $\tilde{m}_t, \tilde{v}_t$ (EMA, 逐元素)
 - 更新: $W_{t+1} = W_t - \eta Q_L \left(\frac{\tilde{m}_t}{\sqrt{\tilde{v}_t + \varepsilon}} \right) Q_R^\top$
- ☐ [工程] 实现基变换时的 Adam 状态迁移（不要重置 $\tilde{m}, \tilde{v}$ 为零！）

第 32 天 · 下午（2.5h）——调试

- ☐ [工程] 在旋转二次函数上测试 SOAP，验证对旋转不敏感（相比 Adam）
- ☐ [工程] 检查：状态迁移前后的 $\tilde{m}_t$ 是否保持一致性（量级不应突变）
- ☐ [工程] 对比：有状态迁移 vs 重置状态为 0 的 loss 曲线（应看到 spike）

第 32 天 · 晚上（1h）——复习总结

- ☐ [笔记] 记录实现中遇到的坑（特征向量符号、数值稳定性、迁移矩阵计算）

周三：SOAP vs Shampoo vs Adam 三者对比

第 33 天 · 上午（2h）——实验准备

- ☐ [工程] 搭建统一实验框架：同一训练循环中切换 Adam / Shampoo / SOAP
- ☐ [工程] 实现旋转二次函数实验: $f(W) = \frac{1}{2} \|AW - W^*\|_F^2$ (A 控制行/列条件数)

第 33 天 · 下午（3h）——正式实验

- ☐ [工程] 旋转二次函数实验：对比 Adam / Shampoo / SOAP 的收敛轨迹
- ☐ [工程] 变化 A 的条件数 $\kappa \in \{1, 10, 100, 1000\}$ ，记录三者的收敛步数
- ☐ [工程] 在两层 MLP（MNIST）上对比三者的 test accuracy 和收敛速度
- ☐ [工程] 绘制三者的 loss 曲线（同图对比）和 wall-clock vs accuracy 的 Pareto 图

第 33 天 · 晚上（1h）——复习总结

- ☐ [笔记] 分析：什么场景下 SOAP > Shampoo > Adam？反过来呢？

周四：SOAP 消融实验

第 34 天 · 上午 (2.5h) —— 消融实验

- ☐ [工程] 消融实验 1: 固定 $Q_L = I, Q_R = I$ (退化到 Adam) vs 正常 SOAP → 验证特征基的贡献
- ☐ [工程] 消融实验 2: 变化 $K \in \{10, 50, 100, 200, 500\}$ → 基更新频率的影响
- ☐ [工程] 消融实验 3: 「不做基变换」直接重置 $\tilde{m}, \tilde{v}$ 为零 vs 正确迁移 → 观察 loss spike
- ☐ [工程] 消融实验 4: 有无 EMA 预条件器 (β_L, β_R 取 1 即无 EMA) 的影响

第 34 天 · 下午 (2.5h) —— 实验结果分析

- ☐ [工程] 整理消融实验数据, 绘制对比图
- ☐ [工程] 分析每个组件的贡献: 特征基 (几何) + EMA (平滑) + 状态迁移 (一致性)
- ☐ [工程] 撰写 SOAP 实验报告: 包括实验设置、结果、分析

第 34 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 总结 SOAP 的设计智慧: 每个组件解决什么问题? 去掉会怎样?

周五：Muon 入门——Newton-Schulz 正交化

第 35 天 · 上午 (2.5h) —— 理论

- ☐ [阅读] 阅读 Jordan & Bernstein et al. (2024) Muon 论文
- ☐ [理论] 精读 optimizer_lecture_v2.pdf §9–§10: Muon 的完整推导
- ☐ [理论] 理解 Muon 的核心算法 (极简!):

$$B_t = \mu B_{t-1} + G_t (\text{动量累积}), \quad O_t = \text{NewtonSchulz}_5(B_t), \quad W_{t+1} = W_t - \eta O_t$$

- ☐ [理论] 理解惊人效果: 1.5B Transformer → 仅需 10 GPU-hours (1.35× 加速)
- ☐ [理论] 学习 Newton-Schulz 迭代的数学原理: 多项式 $\phi(x) = ax + bx^3 + cx^5$ 逼近 $\text{sgn}(x)$

第 35 天 · 下午 (2.5h) —— 实现

- ☐ [工程] 实现 Newton-Schulz 5 步迭代 (含归一化和转置步骤)
- ☐ [工程] 对随机 100×100 矩阵 M , 计算 $\text{sgn}(M) = UV^\top$ (SVD 为 ground truth)
- ☐ [工程] 记录 $\|X_k - \text{sgn}(M)\|_F$ 随 k 的变化 (1–10 次迭代), 验证收敛速度
- ☐ [工程] 实现简化 Muon 在二维矩阵分解 toy problem 上的运行
- ☐ [工程] 可视化更新矩阵的奇异值演化 (Muon 将它们全部置 1 → 均衡化)

第 35 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 理解 Muon 的设计哲学: 不依赖二阶矩, 只用动量 + 正交化 → 内存比 AdamW 更轻!

周六：第 6 周收尾 + 完整对比报告

第 36 天 · 上午 (2.5h) ——理论收尾

- ☐ [理论] 重读 SOAP 论文的实验部分，理解在多大模型规模下 SOAP > AdamW/Shampoo
- ☐ [理论] 阅读 Muon 论文的实验部分 (NanoGPT speedrunning 的配置)
- ☐ [笔记] 写一段话总结第 3-6 周的核心发现

第 36 天 · 下午 (2.5h) ——代码整理

- ☐ [工程] 整理 SOAP 和 Muon 代码到统一接口
- ☐ [工程] 制作第 3-6 周完整对比报告：Adam / AdamW / AMSGrad / Shampoo / SOAP / Muon
- ☐ [工程] 包含维度：收敛速度、内存开销、旋转敏感性、超参数敏感度

[完成] 第 6 周核心交付物：SOAP 完整实现 (含状态迁移) + 三者对比实验 + 4 项消融实验 + Muon 简化实现 + NS 迭代收敛验证 + 6 种优化器对比报告

第 7 周：系统文献阅读 + Muon/PolarGrad 深度 + 最陡下降统一视角

学习目标：建立完整的优化器知识地图，理解最陡下降统一视角，掌握 Muon 和 PolarGrad 的数学本质，制作优化器全景对比表。

周一：系统文献复习（一）——核心 6 篇论文

第 37 天 · 上午（3h）——深度复习

- ☐ [阅读] 重读 Kingma & Ba (2014) Adam ——关注 Theorem 4.1 (regret bound) 的证明结构
- ☐ [阅读] 重读 Loshchilov & Hutter (2017) AdamW ——关注 Section 2 的 L2 vs WD 对比实验数据
- ☐ [阅读] 重读 Reddi et al. (2018) AMSGrad ——关注 Adam 反例的数学构造
- ☐ [阅读] 重读 Duchi et al. (2011) AdaGrad ——关注 Theorem 1-5 的证明骨架
- ☐ [阅读] 重读 Gupta et al. (2018) Shampoo ——关注收敛定理的条件和证明策略
- ☐ [阅读] 重读 Vyas et al. (2024) SOAP ——关注消融实验的设计

第 37 天 · 下午（2.5h）——制作全景对比表

- ☐ [工程] 制作「优化器全景对比表」，包含以下 7 个维度：
 1. 预条件器 P_t 的数学形式
 2. 额外内存 (big-O, 假设参数总维度 d , 矩阵参数 $m \times n$)
 3. 每步计算复杂度 (前向 + 反向 + 优化器更新)
 4. 收敛保证所需的假设 (凸性、光滑性、有界方差……)
 5. 是否坐标不变 (rotation-invariant)
 6. 主要局限或陷阱
 7. 典型推荐场景
- ☐ [笔记] 覆盖: SGD / Momentum / Nesterov / AdaGrad / RMSProp / Adam / AdamW / AMSGrad / Shampoo / SOAP / Muon / PolarGrad

第 37 天 · 晚上（1h）——复习总结

- ☐ [笔记] 在 A3 大小的纸上手绘优化器全景图 (演化关系 + 核心创新 + 代价)

周二：Muon 深度——谱范数最陡下降

第 38 天 · 上午 (2.5h) ——理论

☐ [理论] 精读 optimizer_lecture_v2.pdf §10–§11：最陡下降统一视角

☐ [理论] 推导：不同范数下的最陡下降产生不同优化器

$$w_{t+1} = \arg \min_w \left\{ \langle g_t, w - w_t \rangle + \frac{1}{2\eta} \|w - w_t\|^2 \right\}$$

☐ [理论] 完成课件练习：证明 $\arg \min_{\|O\|_{op} \leq 1} \|O - G\|_F^2 = UV^\top$ （用 von Neumann 迹不等式）

☐ [理论] 理解核心结论：Muon = 在谱范数下的最陡下降方向

☐ [理论] 证明 $\text{sgn}(G)$ 是核范数的最小范数次梯度

第 38 天 · 下午 (2.5h) ——实验

☐ [工程] 完成课件工程练习 1：实现 Muon 简化版 + 可视化奇异值演化

☐ [工程] 完成课件工程练习 2：Adam vs Muon 旋转敏感性 ($f(W) = \frac{1}{2} \|AW - W^*\|_F^2$)

☐ [工程] 构造 A 的条件数变化实验，记录两者的收敛步数

☐ [工程] 在 MNIST 两层 MLP 上初步对比 AdamW vs Muon

第 38 天 · 晚上 (1h) ——复习总结

☐ [笔记] 自己写一段话解释「为什么 Muon 能加速训练」——准备向同行解释

周三：PolarGrad 深度——极分解统一框架

第 39 天 · 上午 (2.5h) ——理论

☐ [阅读] 阅读 Lau, Long & Su (2025) PolarGrad 论文

☐ [理论] 精读 optimizer_lecture_v2.pdf §12：苏炜杰的关键贡献

☐ [理论] 理解「曲率预条件 (Adam)」vs「梯度预条件 (Muon)」的精确区分

☐ [理论] 掌握 PolarGrad 更新： $W_{t+1} = W_t - \eta \cdot U_t \cdot \phi(P_t)$

– $\phi(P) = I \rightarrow$ 退化到 Muon

– $\phi(P) = P \rightarrow$ 退化到动量 SGD

– $\phi(P) = \|G\|_*/\sqrt{d} \cdot I \rightarrow$ PolarGrad 推荐配置

☐ [理论] 理解为什么 PolarGrad 宣称比 Muon 更完备（保留部分尺度信息）

第 39 天 · 下午 (2.5h) —— 实现

- ☐ [工程] 实现 PolarGrad 的简化版 (使用 SVD 做极分解)
- ☐ [工程] 在 toy problem 上对比 Muon vs PolarGrad 的轨迹差异
- ☐ [工程] 观察: $\phi(P)$ 的不同选择如何影响更新方向?
- ☐ [工程] 完成课件工程练习 3: NS 迭代收敛实验 (含收敛阶验证)

第 39 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 区分: 曲率预条件 vs 梯度预条件——各自的代表、优势、局限

周四: ASGO 与最新进展**第 40 天 · 上午 (2.5h) —— 理论**

- ☐ [理论] 精读 optimizer_lecture_v2.pdf §13: ASGO 单侧预条件器
- ☐ [理论] 理解 ASGO 的动机: 只用单侧预条件 (Λ_t^{-1}), 降低 Shampoo 的计算量
- ☐ [理论] 推导 ASGO 的收敛保证 (非光滑凸情形)
- ☐ [理论] 理解 ASGO 与 Muon 的关系: $\text{ASGO} : \text{Muon} = \text{AdaGrad} : \text{SignSGD}$
- ☐ [理论] 阅读 ASGO 在 GPT-2 (124M) 上的实验: 验证 loss 3.342 与 Muon 持平

第 40 天 · 下午 (2.5h) —— 文献拓展

- ☐ [阅读] 选读 2-3 篇扩展文献并做笔记:
 - Shazeer & Stern (2018) —Adafactor (低内存自适应学习率)
 - Martens (2020) —Natural Gradient Method 综述
 - Dauphin et al. (2024) —Cautious Adaptation via Randomized Smoothing
- ☐ [笔记] 每篇论文写一段总结: 核心贡献 + 与已学内容的关联

第 40 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 更新优化器全景图, 加入 Adafactor、ASGO、Natural Gradient

周五：统一实验框架 + 复现 Adam 反例

第 41 天 · 上午 (2.5h) ——代码整理

- ☐ [工程] 建立统一的优化器实验框架（类似 `torch.optim` 的 API 风格）
- ☐ [工程] 支持：切换函数（凸/强凸/非凸/旋转/矩阵）、切换优化器、统一日志和可视化
- ☐ [工程] 为每个优化器写单元测试（toy problem 上的预期行为验证）

第 41 天 · 下午 (2.5h) ——实验

- ☐ [工程] 复现 Adam 旋转敏感性的反例（Reddi et al. 中构造的简单在线问题）
- ☐ [工程] 验证：Adam 在反例上的 behavior（是否发散/震荡）vs AMSGrad 的稳定性
- ☐ [工程] 运行完整的一键对比实验：所有 7 种优化器在 3 种函数上的对比
- ☐ [工程] 生成对比图集（loss 曲线 + 轨迹图 + 有效学习率热力图）

第 41 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 检查：现在能否回答「每个优化器为什么被发明？解决了什么问题？付出了什么代价？」

周六：第 7 周收尾——知识体系整合

第 42 天 · 上午 (2.5h) ——全景图完善

- ☐ [理论] 完善你的「A3 优化器全景图」：
 - 演化箭头：哪个优化器是从哪个演化来的？解决了什么问题？
 - 理论工具链：每个优化器依赖了哪些数学工具？
 - 工程考量：内存、计算、数值稳定性的 practical guide
- ☐ [笔记] 确保能向同行清晰讲解从 SGD 到 PolarGrad 的完整故事线

第 42 天 · 下午 (2.5h) ——最终代码整理

- ☐ [工程] 将所有 7 周代码整理到统一的 GitHub 仓库结构中
- ☐ [工程] 编写仓库 README：包含安装说明、实验复现步骤、学习资源索引
- ☐ [工程] 为下周 Research Memo 确定研究方向（从老师提供的 6 个方向中选择 1-2 个）
- ☐ [工程] 初读选定方向的 2-3 篇相关论文

[完成] 第 7 周核心交付物：6 篇核心论文重读笔记 + 12 种优化器全景对比表（7 维度）
+ Muon 旋转敏感性实验 + PolarGrad 实现 + Adam 反例复现 + 统一实验框架 + A3 全景图

第 8 周：Research Memo ——找到你的研究问题

学习目标：综合前 7 周的理论实验积累，识别一个值得深入的研究方向，写一份正式的一页 Research Memo。

周一：研究方向探索

第 43 天 · 上午 (2.5h) ——方向调研

- ☐ [阅读] 精读老师提供的 6 个研究方向，选 2 个你最感兴趣的深入调研
- ☐ [阅读] 对每个方向搜索 3-5 篇相关论文 (Cited by 相关论文)
- ☐ [笔记] 写调研笔记：每个方向的现有方法、关键挑战、可能的突破口

第 43 天 · 下午 (2.5h) ——确定方向

- ☐ [工程] 基于前 7 周的实验经验，分析每个方向的可行性 (你有哪些代码可以复用?)
- ☐ [笔记] 确定 1 个主要研究方向，写下选择的理由
- ☐ [笔记] 列出你已有的优势 (实现了哪些优化器? 做了哪些实验?) 和需要补充的知识

第 43 天 · 晚上 (1h) ——复习总结

- ☐ [笔记] 写半页纸：你的研究问题的非正式描述 (像在对朋友解释)

周二：撰写 Problem + Assumptions

第 44 天 · 上午 (2.5h) ——写作

- ☐ [笔记] 撰写 Research Memo 的「Problem」部分：
 - 要解决什么具体问题?
 - 为什么重要? (引用实验数据支持)
 - 现有方法的不足是什么? (用你的对比实验结果!)
- ☐ [笔记] 撰写「Assumptions」部分：
 - 假设满足什么条件?
 - 这些假设在深度学习场景下合理吗?
 - 有没有可能放松的假设?

第 44 天 · 下午 (2.5h) ——完善

- ☐ [工程] 用你前 7 周的实验数据支持 Problem 陈述（例如 Adam 在旋转条件下慢 X 倍）
- ☐ [笔记] 与老师提供的 6 个方向中已有的工作进行差异化分析
- ☐ [笔记] 审阅：这部分能不能说服读者「这个问题值得解决」？

第 44 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 让其他人（或自己在第二天）读一遍 Problem + Assumptions，检查逻辑漏洞

周三：撰写 Algorithm + Theory

第 45 天 · 上午 (2.5h) —— 写作

- ☐ [笔记] 撰写「Algorithm」部分：
 - 提出什么新方法？
 - 写出核心更新公式（伪代码级别）
 - 与现有方法的公式对比（突出创新点）
- ☐ [笔记] 撰写「Theory」部分：
 - 计划证明什么？（收敛率？regret bound？复杂度降低？）
 - 证明的骨架是什么？（从哪些假设出发？用到哪些工具？）
 - 最困难的步骤可能在哪里？

第 45 天 · 下午 (2.5h) —— 验证

- ☐ [工程] 如果可能，在 toy problem 上快速验证算法的一个核心子步骤
- ☐ [笔记] 检查理论路线是否 feasible（不要 claim 了做不到的定理）
- ☐ [笔记] 确保公式正确（检查维度、符号一致性）

第 45 天 · 晚上 (1h) —— 复习总结

- ☐ [笔记] 审阅：Algorithm 的描述是否清晰到别人可以直接实现？

周四：撰写 Experiments + Risks

第 46 天 · 上午 (2.5h) —— 写作

☐ [笔记] 撰写「Experiments」部分：

- 最小可控实验是什么？(toy problem 上验证什么假设?)
- 中等规模验证？(MNIST MLP、CIFAR-10 CNN)
- 大到什么规模可以证明方法的有效性？(GPT-2 scale?)
- 需要对比哪些 baseline?

☐ [笔记] 撰写「Risks」部分：

- 什么可能失败？(数值不稳定？计算开销过大？理论 gap?)
- 每个风险的备选方案是什么？

第 46 天 · 下午 (2.5h) —— 完善

☐ [笔记] 整合所有部分，形成完整的一页 Research Memo 初稿 (800–1500 字)

☐ [笔记] 精炼语言：删掉不必要的词，确保每一句都在推动论证

☐ [笔记] 添加参考文献引用 (BibTeX 格式)

第 46 天 · 晚上 (1h) —— 复习总结

☐ [笔记] 自己朗读一遍 Research Memo，检查流畅度和论证连贯性

周五：修改完善

第 47 天 · 上午 (2.5h) —— 修改

☐ [笔记] 根据自我审阅修改 Research Memo

☐ [笔记] 重点检查：

- Problem 的紧迫性表达是否充分？
- Algorithm 的创新性是否清晰？
- Theory 的可行性是否合理？
- Experiments 的设计是否能回答核心问题？

☐ [笔记] 排版：确保一页纸能容纳所有内容 (调整字号、边距、图表大小)

第 47 天 · 下午 (2.5h) —— 最终检查

- ☐ [工程] 准备一个 3 分钟的 elevator pitch（口头演练）
- ☐ [笔记] 与老师的 8 周学习计划中的检验标准对照，确保满足
- ☐ [笔记] 最终排版 + 导出 PDF 版本

第 47 天 · 晚上（1h）——复习总结

- ☐ [笔记] 庆祝！你已经完成了 8 周高密度学习计划！

周六：最终答辩准备 + 课程总结

第 48 天 · 上午（2.5h）——答辩准备

- ☐ [笔记] 准备最终答辩/汇报材料（10–15 页 slides）：
 - 课程内容总览（3 页）
 - 你的核心实验发现（4 页）
 - Research Memo 内容（5 页）
 - 未来工作方向（2 页）
- ☐ [工程] 准备 demo（运行你的实验代码展示关键结果）

第 48 天 · 下午（2.5h）——课程总结

- ☐ [笔记] 整理整个 8 周课程的核心收获（知识、技能、研究能力）
- ☐ [工程] 整理最终代码仓库（README、文档、测试、实验脚本）
- ☐ [笔记] 写课程总结 + 未来学习路线（本课程之后的进阶方向）
- ☐ [笔记] 补充阅读清单：推荐论文和教材供后续深入

[完成] 第 8 周核心交付物：一页 Research Memo（Problem → Assumptions → Algorithm → Theory → Experiments → Risks）+ 答辩 slides + 最终代码仓库 + 课程总结

附录 A：核心论文阅读清单

论文	作者/年份	核心贡献
Adam	Kingma & Ba (2014)	EMA + 偏差修正 + 对角预条件
AdamW	Loshchilov & Hutter (2017)	Weight Decay 与自适应梯度解耦
AMSGrad	Reddi et al. (2018)	修复 Adam 收敛证明的错误
AdaGrad	Duchi, Hazan & Singer (2011)	逐坐标自适应步长 + Regret 分析
Shampoo	Gupta, Koren & Singer (2018)	Kronecker 结构化的矩阵预条件
SOAP	Vyas et al. (2024)	Shampoo 特征基 + Adam EMA
Muon	Jordan & Bernstein et al. (2024)	Newton-Schulz 谱正交化动量
PolarGrad	Lau, Long & Su (2025)	极分解统一框架
ASGO	Chen et al. (2025)	单侧预条件器

附录 B：教材参考

- **Bubeck (2015)** — *Convex Optimization: Algorithms and Complexity*. Foundations and Trends in ML. §3（光滑凸优化的梯度方法）。
- **Nesterov (2018)** — *Lectures on Convex Optimization*. Springer. §1.2, §2.1（凸分析基础、Oracle 下界）。
- **Boyd & Vandenberghe (2004)** — *Convex Optimization*. Cambridge. §9.2–9.3（梯度下降、最陡下降、条件数）。
- **Garrigos & Gower (2023)** — *Handbook of Convergence Theorems for Gradient Descent*（GD/SGD 收敛定理速查手册）。
- **张贤科**—《高等线性代数》，清华大学出版社（Jordan标准形、矩阵函数、广义逆）。
- **Golub & Van Loan (2013)** — *Matrix Computations*, 4th ed.（数值线性代数圣经）。
- **Horn & Johnson (2013)** — *Matrix Analysis*, 2nd ed.（矩阵范数、Loewner 序、矩阵函数）。
- **Higham (2008)** — *Functions of Matrices: Theory and Computation*, SIAM（Newton-Schulz 和极分解的数值算法）。

附录 C：每周日复习清单

1. 回顾本周所有手写证明（能否不看笔记独立推出来？）
2. 整理本周代码，确保每个实验可复现（运行 `python main.py` 即可）
3. 补充本周笔记中标记的「待深入」项
4. 将本周的核心发现写成一个 bullet-point 摘要（为第 8 周 Research Memo 储备素材）

5. 预习下周的课件章节（至少浏览一遍标题和公式）