

线性代数第 5–8 讲

思考题详解、证明补全与数学优化应用

基于何斯迈 2023 年课程讲义整理

本讲义逐页覆盖原讲义中的思考题、计算题与省略证明；同时补入正定矩阵的等价条件、Cholesky/ LDL^T 分解、Sylvester 判据，以及这些工具在最小二乘、梯度下降、牛顿法、预条件、动量法和马尔可夫迭代中的作用。

编译方式：XeLaTeX（Overleaf 选择 XeLaTeX）

使用说明

本文不是原讲义的逐字转录，而是“问题驱动的补全版”。每一章先整理概念链条，再给出原讲义题目和详细解答。标有“来源”的框对应原 PDF 页码；标有“易错点”的段落说明原讲义中需要增加条件或更严谨表述之处。

全文默认向量为列向量。实内积空间使用 $\langle x, y \rangle = x^T y$ ，复内积空间使用 $\langle x, y \rangle = x^H y$ 。除非特别说明，正定矩阵均指实对称正定矩阵（复数情形相应替换为 Hermitian 正定）。

原讲义	本书核心内容	主要优化连接
第 5 讲	生成、基、内积、Gram–Schmidt、QR、Cholesky	最小二乘、正交化、数值稳定性
第 6 讲	基的延拓、维数、正交补、子空间运算	投影、约束优化、零空间法
第 7 讲	特征值、特征多项式、Cayley–Hamilton、根子空间	二次优化、迭代稳定性、矩阵函数
第 8 讲	Jordan 标准形、矩阵幂、Perron–Frobenius、马尔可夫链	梯度/动量动力学、PageRank、长期平均
补充章	正定性完整等价链、Schur 补与预条件	Hessian、牛顿法、Shampoo/Adam 的坐标几何

目录

使用说明	ii
第一章 第 5 讲：线性空间、正交化、QR 与 Cholesky 分解	1
1.1 线性组合、子空间及其正交补	1
1.1.1 线性相关与齐次方程	1
1.1.2 子空间运算：先纠正一个常见记号混淆	2
1.2 基、维数与高斯消元取基	3
1.2.1 基等价于极大线性无关组	3
1.2.2 为何列初等变换不改变列空间	4
1.2.3 讲义例题：通过列消元求生成空间的一组基	5
1.3 正交基与正交投影	6
1.3.1 正交非零向量必线性无关	6
1.3.2 向一条直线投影：计算题与最优性证明	7
1.3.3 向子空间投影及一般最小二乘公式	8
1.4 Gram-Schmidt 正交化	9
1.4.1 算法及其两个不变量	9
1.4.2 课堂练习二：逐步求标准正交基	10
1.4.3 超平面标准正交基：避免不必要的完整消元	12
1.5 QR 与 LQ 分解	13
1.5.1 分解的严格表述与证明	13
1.5.2 QR 解方程与最小二乘：方阵和矩形必须区分	14
1.6 Cholesky 分解与正定性的等价条件	15
1.6.1 存在性、唯一性和递推公式	16
1.6.2 正定性的完整等价链与 Sylvester 判据	17
1.6.3 正定性在优化器中的直接作用	18
1.7 本讲逻辑总览与自检	19
第二章 第 6 讲：维数、子空间运算与坐标变换	21

2.1	基、坐标与基的生成	21
2.1.1	基为何就是一个坐标系	21
2.1.2	从生成集提取一组基	22
2.2	维数与矩阵的秩	24
2.2.1	超过维数的向量必然相关	24
2.2.2	维数定义不依赖基的选择	24
2.2.3	行秩等于列秩	26
2.3	空间的和、正交补、直和与商空间	27
2.3.1	子空间的和	27
2.3.2	正交分解与投影	28
2.3.3	基的扩张与直和判据	29
2.3.4	维数公式	30
2.3.5	商空间及其与正交补的关系	31
2.4	坐标变换、相似矩阵与优化器中的重参数化	33
2.4.1	同一向量在两组基下的坐标	33
2.4.2	同一线性变换在两组基下的矩阵	34
2.4.3	优化中的坐标选择、预条件与不变性	35
第三章	第 7 讲：特征值、特征向量与根子空间分解	37
3.1	换基、相似与商空间	37
3.1.1	商空间的构造与维数	38
3.2	特征值、特征空间与根子空间	39
3.3	课堂练习与思考题详解	41
3.4	相似不变量与 Cayley–Hamilton 定理	45
3.5	几何重数、代数重数与不同谱空间的独立性	47
3.6	互素多项式的核分解	48
3.7	根子空间分解定理	49
3.8	在数学优化器中的进一步应用	51
3.8.1	预条件梯度法：把广义特征值化成普通特征值	51
3.8.2	动量法：每个 Hessian 特征方向对应一个二阶系统	51
3.8.3	谱估计、步长选择与正则化	51
第四章	第 8 讲：约当标准形、矩阵幂与马尔可夫过程	53
4.1	根子空间与约当链	53
4.2	复数约当标准形及其构造	55
4.3	实约当标准形	57

4.4	约当块的幂与迭代稳定性	57
4.5	马尔可夫链与 Perron–Frobenius 理论	58
4.6	长期平均定理：完整而准确的版本	60
第五章	专题补充：正定矩阵的完整工具箱	62
5.1	定义与基本辨析	62
5.2	正定性的等价条件总表	62
5.3	Schur 补：递归正定判据	64
5.4	Cholesky 与 LDL^T 的计算公式	65
5.5	半正定矩阵、Gram 矩阵与最小二乘	65
5.6	正定性在优化中的直接含义	66
第六章	从线性代数到数学优化与优化器	67
6.1	最小二乘：QR、Cholesky 与 SVD 如何选择	67
6.2	投影、正交补与约束优化	68
6.3	谱、条件数与梯度下降	68
6.3.1	动量法与二阶状态矩阵	68
6.4	预条件、变量替换与坐标几何	69
6.4.1	Adam：对角预条件的优点与坐标依赖	69
6.4.2	Shampoo：Kronecker 因子与双侧白化	69
6.4.3	Muon 与极分解视角	70
6.5	马尔可夫矩阵在优化与学习中的两类应用	70
6.5.1	PageRank 的阻尼为何有效	70
6.5.2	去中心化优化中的混合矩阵	71
6.6	矩阵工具选择清单	71
第七章	原讲义问题覆盖索引与勘误	72
7.1	显式题目索引	72
7.2	省略证明与补全位置	73
7.3	原讲义中需要澄清或修正之处	74
7.4	最终自检清单	74
参考资料		75

第 1 章

第 5 讲：线性空间、正交化、QR 与 Cholesky 分解

本讲把“线性组合-基-正交投影-Gram-Schmidt-QR-Cholesky”串成一条完整的逻辑链。原讲义中的计算题均在本章逐步算完；原讲义只给结论或略去细节之处，则补上成立条件与证明。除特别说明外，本章在有限维实内积空间中讨论，向量均为列向量。

1.1 线性组合、子空间及其正交补

1.1.1 线性相关与齐次方程

给定向量 $v_1, \dots, v_m \in \mathbb{R}^n$ ，令

$$V = (v_1, \dots, v_m) \in \mathbb{R}^{n \times m}.$$

它们的线性组合是 $Vc = \sum_{i=1}^m c_i v_i$ ；所有线性组合构成

$$\text{span}\{v_1, \dots, v_m\} = \text{Range}(V).$$

来源：第 5 讲原讲义第 1 页

命题 1.1 (线性相关的矩阵判定). 向量组 $v_1, \dots, v_m$ 线性相关，当且仅当齐次方程 $Vc = 0$ 有非零解；它们线性无关，当且仅当 $\text{Ker } V = \{0\}$ ，也即 $\text{rank}(V) = m$ 。

证明. 按照定义，线性相关是指存在不全为零的系数 $c_1, \dots, c_m$ ，使 $\sum_i c_i v_i = 0$ 。把系数排成列向量 c ，该等式恰是 $Vc = 0$ 。因此“存在非平凡线性关系”与“零空间含非零向量”是同一件事。再由秩-零度公式

$$m = \text{rank}(V) + \text{nullity}(V)$$

可得 $\text{Ker } V = \{0\} \iff \text{rank}(V) = m$ 。

□

优化连接：搜索方向与低维参数化

许多优化算法并不在整个 $\mathbb{R}^n$ 中搜索，而只在 $\mathcal{K} = \text{span}\{p_1, \dots, p_m\}$ 中令 $x = x_0 + Pc$ 。若 P 的列相关，则不同的 c 会表示同一个点，约化问题的 Hessian $P^T H P$ 也会奇异；选取一组基能消除这种冗余。共轭梯度法、GMRES 和低秩适配方法所使用的 Krylov 子空间正是这一思想的实例。

1.1.2 子空间运算：先纠正一个常见记号混淆

两个子空间 $L_1, L_2 \subseteq \mathbb{R}^n$ 的交 $L_1 \cap L_2$ 仍是子空间；它们的和定义为

$$L_1 + L_2 := \{x + y : x \in L_1, y \in L_2\} = \text{span}(L_1 \cup L_2).$$

一般不能把 $L_1 + L_2$ 写成 $L_1 \cup L_2$ ：例如平面中两条不同的过原点直线之并对加法不封闭，因而不是子空间。只有 $L_1 \subseteq L_2$ 或 $L_2 \subseteq L_1$ 时， $L_1 \cup L_2$ 才是子空间。

对集合 $A \subseteq \mathbb{R}^n$ ，定义

$$A^\perp = \{x \in \mathbb{R}^n : x^T a = 0 \text{ 对所有 } a \in A\}.$$

不论 A 本身是否为子空间， $A^\perp$ 总是子空间，并且 $A^\perp = (\text{span } A)^\perp$ 。

来源：第 5 讲原讲义第 1 页

命题 1.2 (生成、交、和与正交补确为子空间). 对任意 $A \subseteq \mathbb{R}^n$ ， $\text{span } A$ 是包含 A 的最小子空间， $A^\perp$ 是子空间。若 L_1, L_2 是子空间，则 $L_1 \cap L_2$ 与 $L_1 + L_2$ 也都是子空间。

证明. $\text{span } A$ 中的元素是 A 中有限多个向量的线性组合。两个有限线性组合之和、一个线性组合的数乘仍是有限线性组合，且零向量由全零系数得到，故 $\text{span } A$ 是子空间。任何包含 A 的子空间都对线性组合封闭，因而必包含 $\text{span } A$ ，这证明了最小性。

若 $x, y \in A^\perp$ 、 $\alpha, \beta \in \mathbb{R}$ ，则对每个 $a \in A$ ，

$$(\alpha x + \beta y)^T a = \alpha x^T a + \beta y^T a = 0,$$

故 $A^\perp$ 对线性组合封闭。若 $x, y \in L_1 \cap L_2$ ，则任意 $\alpha x + \beta y$ 同时属于 L_1, L_2 ，所以交是子空间。若 $x = x_1 + x_2, y = y_1 + y_2 \in L_1 + L_2$ ，则

$$\alpha x + \beta y = (\alpha x_1 + \beta y_1) + (\alpha x_2 + \beta y_2) \in L_1 + L_2,$$

所以和也是子空间。□

来源：第 5 讲原讲义第 1 页

引理 1.3 (二重正交补). 在有限维空间 $\mathbb{R}^n$ 中，对任意集合 A ，

$$(A^\perp)^\perp = \text{span } A.$$

特别地，对任意子空间 L ，有 $(L^\perp)^\perp = L$ 。

证明. 先设 $L = \text{span } A$ 。显然每个 $x \in L$ 都与 $L^\perp = A^\perp$ 中的向量垂直, 故 $L \subseteq (A^\perp)^\perp$ 。

取 L 的一组标准正交基 $q_1, \dots, q_r$, 再把它扩充为 $\mathbb{R}^n$ 的标准正交基 $q_1, \dots, q_n$ 。于是

$$L^\perp = \text{span}\{q_{r+1}, \dots, q_n\}, \quad (L^\perp)^\perp = \text{span}\{q_1, \dots, q_r\} = L.$$

结合 $A^\perp = L^\perp$ 即得结论。 □

来源：第 5 讲原讲义第 1 页

定理 1.4 (和、交与正交补的 De Morgan 公式). 对 $\mathbb{R}^n$ 的子空间 L_1, L_2 ,

$$(L_1 + L_2)^\perp = L_1^\perp \cap L_2^\perp,$$

$$(L_1 \cap L_2)^\perp = L_1^\perp + L_2^\perp.$$

证明. 对第一式, 若 $z \in (L_1 + L_2)^\perp$, 分别令和中的另一个向量为零, 便得 $z \perp L_1$ 且 $z \perp L_2$, 所以 $z \in L_1^\perp \cap L_2^\perp$ 。反之, 若 z 同时垂直于 L_1, L_2 , 则对任意 $x \in L_1, y \in L_2$,

$$z^\top(x + y) = z^\top x + z^\top y = 0,$$

故 $z \in (L_1 + L_2)^\perp$ 。

把第一式用于 $L_1^\perp, L_2^\perp$, 并使用二重正交补, 得到

$$(L_1^\perp + L_2^\perp)^\perp = (L_1^\perp)^\perp \cap (L_2^\perp)^\perp = L_1 \cap L_2.$$

对等式两边再取正交补, 即 $L_1^\perp + L_2^\perp = (L_1 \cap L_2)^\perp$ 。 □

优化连接：等式约束的一阶条件

设线性约束为 $Cx = d$ 。可行方向组成 $\text{Ker } C$, 而

$$(\text{Ker } C)^\perp = \text{Range}(C^\top).$$

若 $x_\star$ 是可行的局部极小点, 则沿每个可行方向 $p \in \text{Ker } C$ 的方向导数为零, 即 $\nabla f(x_\star) \perp \text{Ker } C$ 。因此存在乘子 λ 使

$$\nabla f(x_\star) + C^\top \lambda = 0,$$

这正是线性等式约束的 KKT 驻点条件。

1.2 基、维数与高斯消元取基

1.2.1 基等价于极大线性无关组

来源：第 5 讲原讲义第 2 页

定理 1.5 (极大线性无关组判定). 设 $S = \{v_1, \dots, v_m\} \subseteq V$ 。以下两条等价:

1. S 是 V 的一组基;

2. S 线性无关，并且向其中加入任何 $v \in V \setminus S$ 后都会线性相关。

证明. 若 S 是基，则任意 $v \in V$ 均可写为 $v = \sum_i c_i v_i$ ，于是

$$v - \sum_{i=1}^m c_i v_i = 0$$

给出了 $S \cup \{v\}$ 的一个非平凡线性关系，所以不能再加入新向量而保持无关。

反过来，设 S 是极大线性无关组。若存在 $v \in V$ 不属于 $\text{span } S$ ，则 $S \cup \{v\}$ 仍线性无关：事实上，若 $tv + \sum_i c_i v_i = 0$ ，当 $t \neq 0$ 时可推出 $v \in \text{span } S$ ，矛盾；当 $t = 0$ 时， S 的线性无关性又推出所有 $c_i = 0$ 。这与极大性矛盾，故 $V = \text{span } S$ ，所以 S 是基。□

原讲义随后观察到“同一有限维空间的每一组基含有同样多的向量”。这不是定义，而需要交换论证。

来源：第 5 讲原讲义第 2-3 页

引理 1.6 (Steinitz 交换引理). 若 $v_1, \dots, v_n$ 张成 V ，而 $w_1, \dots, w_m$ 线性无关，则 $m \leq n$ 。因而同一有限维空间的任意两组基所含向量数相同，这个数定义为 $\dim V$ 。

证明. 因为 w_1 可由 $v_1, \dots, v_n$ 表示，表示式中至少有一个 v_j 的系数非零；解出该 v_j 后，可用 w_1 替换 v_j 而仍张成 V 。不妨重新编号，使 $w_1, v_2, \dots, v_n$ 张成 V 。

归纳地，假设 $w_1, \dots, w_{k-1}, v_k, \dots, v_n$ 张成 V 。把 w_k 用这些向量表示。某个 v_j ($j \geq k$) 的系数必须非零；否则 w_k 将是 $w_1, \dots, w_{k-1}$ 的线性组合，与 $w_1, \dots, w_m$ 线性无关矛盾。于是可再用 w_k 替换该 v_j 。该过程至多进行 n 次，所以 $m \leq n$ 。

若两组都是基，交换两组角色可同时得到 $m \leq n$ 与 $n \leq m$ ，故 $m = n$ 。□

1.2.2 为何列初等变换不改变列空间

来源：第 5 讲原讲义第 2-3 页

命题 1.7 (列变换保持列空间). 设 $A \in \mathbb{R}^{m \times n}$ ， $E \in \mathbb{R}^{n \times n}$ 可逆，则

$$\text{Range}(AE) = \text{Range}(A).$$

所以交换两列、把一列乘非零常数、把一列的倍数加到另一列，都不改变列向量张成的空间。

证明. 因为可逆映射 $c \mapsto Ec$ 把 $\mathbb{R}^n$ 双射到自身，

$$\text{Range}(AE) = \{AEc : c \in \mathbb{R}^n\} = \{Ay : y \in \mathbb{R}^n\} = \text{Range}(A).$$

每个列初等变换都等于右乘一个可逆的初等矩阵，所以结论成立。□

来源：第 5 讲原讲义第 3 页

思考题 1.8 (为何取基时可缩放一行, 而计算行列式时要特别小心?). 说明列乘或除以非零常数对“张成空间”和“行列式”分别有什么影响。

详细解答. 把第 j 列乘 $c \neq 0$ 相当于右乘 $E = \text{diag}(1, \dots, 1, c, 1, \dots, 1)$. 由上一命题, E 可逆, 所以列空间完全不变; 从几何上说, 向量 v_j 与 cv_j 张成同一条直线。

行列式则满足

$$\det(AE) = \det(A) \det(E) = c \det(A).$$

因此并非“计算行列式时不能缩放”, 而是缩放后必须把因子 c 记账; 若忽略它, 所得数值便不再是原矩阵的行列式。把一列的倍数加到另一列时 $\det E = 1$, 行列式才保持不变。□

来源: 第 5 讲原讲义第 2 页

引理 1.9 (非零对角元给出线性无关性). 若一个矩阵的前 k 列在某 k 行上组成上(或下)三角矩阵, 且其 k 个对角元均非零, 则这 k 列线性无关。对行向量也有完全类似的结论。

证明. 设所选 $k \times k$ 三角子矩阵为 T . 若前 k 列满足线性关系 $Ac = 0$, 取上述 k 行便有 $Tc = 0$. 三角矩阵的行列式是对角元之积, 故 $\det T \neq 0$, 从而 $c = 0$. 因此原来的 k 列线性无关。□

1.2.3 讲义例题: 通过列消元求生成空间的一组基

来源: 第 5 讲原讲义第 2-3 页

思考题 1.10. 在 $\mathbb{R}^4$ 中给定

$$S = \left\{ \begin{pmatrix} 1 \\ -2 \\ 2 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ -3 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 2 \\ -5 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 3 \\ -6 \\ -1 \\ 3 \end{pmatrix} \right\}.$$

求 $\text{span } S$ 的一组基, 并证明所得向量确实线性无关。

详细解答. 把四个向量作为列拼成

$$A = \begin{pmatrix} 1 & 1 & 2 & 3 \\ -2 & -3 & -5 & -6 \\ 2 & 0 & 2 & -1 \\ 1 & 2 & 3 & 3 \end{pmatrix}.$$

先做 $C_2 \leftarrow C_2 - C_1$, $C_3 \leftarrow C_3 - 2C_1$, $C_4 \leftarrow C_4 - 3C_1$, 得到

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ -2 & -1 & -1 & 0 \\ 2 & -2 & -2 & -7 \\ 1 & 1 & 1 & 0 \end{pmatrix}.$$

再做 $C_3 \leftarrow C_3 - C_2$ ，以及 $C_4 \leftarrow -\frac{1}{7}C_4$ ，得到

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ -2 & -1 & 0 & 0 \\ 2 & -2 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{pmatrix}.$$

因此列空间的一组候选基为

$$b_1 = \begin{pmatrix} 1 \\ -2 \\ 2 \\ 1 \end{pmatrix}, \quad b_2 = \begin{pmatrix} 0 \\ -1 \\ -2 \\ 1 \end{pmatrix}, \quad b_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}.$$

全部列变换均可逆，所以它们仍张成 $\text{span } S$ 。最后验证线性无关：若 $\alpha b_1 + \beta b_2 + \gamma b_3 = 0$ ，比较第一坐标得 $\alpha = 0$ ；再比较第二坐标得 $\beta = 0$ ；比较第三坐标得 $\gamma = 0$ 。等价地，前三行构成的三角子矩阵

$$\begin{pmatrix} 1 & 0 & 0 \\ -2 & -1 & 0 \\ 2 & -2 & 1 \end{pmatrix}$$

对角元均非零。故 $\{b_1, b_2, b_3\}$ 是所求基，且 $\dim \text{span } S = 3$ 。 □

易错点：列消元与行消元取基不要混用

行变换保持齐次方程的解空间以及矩阵的秩，但一般会改变原矩阵的列空间中的具体向量。若要从原始列中挑一组基，通常对 A 做行阶梯化，再取主元所在的原矩阵列；若像本题这样直接做列变换，得到的是同一列空间中的另一组基，不一定是原始列的子集。

1.3 正交基与正交投影

1.3.1 正交非零向量必线性无关

向量组 $v_1, \dots, v_m$ 称为正交组，是指 $v_i^T v_j = 0$ ($i \neq j$)；若还满足 $\|v_i\| = 1$ ，则称为标准正交组。由标准正交列组成的方阵 Q 满足 $Q^T Q = I$ ，因而 $Q^{-1} = Q^T$ ，称为正交矩阵。原讲义在实数情形使用了“单位 (Unitary) 正交基”的说法；更准确的名称是“标准正交基”。“酉 (unitary) 矩阵”通常留给复数情形的 $U^H U = I$ 。

来源：第 5 讲原讲义第 3 页

定理 1.11. 两两正交且均非零的向量 $v_1, \dots, v_m$ 线性无关。

证明. 设 $\sum_{i=1}^m c_i v_i = 0$ 。固定 k ，在等式左侧乘 v_k^T ，由两两正交性得

$$0 = v_k^T \sum_{i=1}^m c_i v_i = \sum_{i=1}^m c_i v_k^T v_i = c_k \|v_k\|^2.$$

因为 $v_k \neq 0$, 所以 $\|v_k\|^2 > 0$, 进而 $c_k = 0$. 对每个 k 都成立, 故全部系数为零。原讲义公式中求和上限偶有写成 n , 这里应统一为向量个数 m . $\square$

来源：第 5 讲原讲义第 8 页

命题 1.12 (正交矩阵的基本性质). 若 $Q \in \mathbb{R}^{n \times n}$ 正交, 则

$$\det Q \in \{1, -1\}, \quad \|Qx\| = \|x\|, \quad (Qx)^\top(Qy) = x^\top y.$$

证明. 由 $Q^\top Q = I$ 取行列式, $(\det Q)^2 = \det(Q^\top) \det Q = 1$, 故 $\det Q = \pm 1$. 此外

$$\|Qx\|^2 = x^\top Q^\top Q x = x^\top x, \quad (Qx)^\top(Qy) = x^\top Q^\top Q y = x^\top y.$$

因此正交变换保持长度、夹角和距离. $\square$

1.3.2 向一条直线投影：计算题与最优性证明

对 $v \neq 0$, u 在直线 $\text{span}\{v\}$ 上的正交投影为

$$\text{proj}_v(u) = \frac{u^\top v}{v^\top v} v.$$

令 $w = u - \text{proj}_v(u)$, 则

$$v^\top w = v^\top u - \frac{u^\top v}{v^\top v} v^\top v = 0,$$

所以 u 被分解为一个平行于 v 的分量和一个垂直于 v 的分量。

来源：第 5 讲原讲义第 4-5 页

思考题 1.13 (课堂练习一). 设

$$u = \begin{pmatrix} 2 \\ -1 \\ 1 \end{pmatrix}, \quad v = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

求 u 在 v 方向上的投影以及与 v 垂直的剩余分量, 并验证正交性。

详细解答. 先算内积

$$u^\top v = 2 - 2 + 2 = 2, \quad v^\top v = 1 + 4 + 4 = 9.$$

故

$$p = \text{proj}_v(u) = \frac{2}{9} v = \begin{pmatrix} 2/9 \\ 4/9 \\ 4/9 \end{pmatrix},$$

而

$$w = u - p = \begin{pmatrix} 2 \\ -1 \\ 1 \end{pmatrix} - \begin{pmatrix} 2/9 \\ 4/9 \\ 4/9 \end{pmatrix} = \begin{pmatrix} 16/9 \\ -13/9 \\ 5/9 \end{pmatrix}.$$

直接核对

$$v^T w = \frac{16}{9} - \frac{26}{9} + \frac{10}{9} = 0.$$

因此 $u = p + w$ 是所求正交分解。 □

来源：第 5 讲原讲义第 4-5 页

命题 1.14 (投影就是一维最小二乘解). 上面的系数

$$\alpha_\star = \frac{u^T v}{v^T v}$$

是 $\min_{\alpha \in \mathbb{R}} \|u - \alpha v\|^2$ 的唯一最优解。

证明. 令 $w = u - \alpha_\star v$, 则 $w \perp v$. 对任意 α ,

$$u - \alpha v = w + (\alpha_\star - \alpha)v.$$

由勾股定理,

$$\|u - \alpha v\|^2 = \|w\|^2 + (\alpha - \alpha_\star)^2 \|v\|^2 \geq \|w\|^2,$$

且因 $v \neq 0$, 等号仅在 $\alpha = \alpha_\star$ 时成立。 □

1.3.3 向子空间投影及一般最小二乘公式

来源：第 5 讲原讲义第 5 页

定理 1.15 (正交基给出的投影公式). 若 $v_1, \dots, v_m$ 是子空间 L 的一组正交基, 则对任意 $u \in \mathbb{R}^n$,

$$P_L u = \sum_{i=1}^m \frac{u^T v_i}{v_i^T v_i} v_i, \quad u = P_L u + w, \quad w \in L^\perp.$$

该分解唯一。若 $q_1, \dots, q_m$ 是标准正交基, 并令 $Q = (q_1, \dots, q_m)$, 则

$$P_L = Q Q^T, \quad P_L^T = P_L, \quad P_L^2 = P_L.$$

证明. 显然 $P_L u \in L$. 对每个 k ,

$$\begin{aligned} v_k^T (u - P_L u) &= v_k^T u - \sum_{i=1}^m \frac{u^T v_i}{v_i^T v_i} v_k^T v_i \\ &= v_k^T u - \frac{u^T v_k}{v_k^T v_k} v_k^T v_k = 0. \end{aligned}$$

所以 $u - P_L u$ 与 L 的一组基都垂直, 因而属于 $L^\perp$. 若还有 $u = p_1 + w_1 = p_2 + w_2$, 其中 $p_i \in L, w_i \in L^\perp$, 则 $p_1 - p_2 = w_2 - w_1 \in L \cap L^\perp = \{0\}$, 故分解唯一。

标准正交时, 求和式就是 $Q Q^T u$. 再由 $Q^T Q = I_m$,

$$(Q Q^T)^T = Q Q^T, \quad (Q Q^T)^2 = Q (Q^T Q) Q^T = Q Q^T.$$

□

易错点: 只有正交基才能逐项使用简单投影公式

若 $a_1, \dots, a_m$ 只是一般基, 通常不能写 $P_L u = \sum_i (a_i^\top u / a_i^\top a_i) a_i$, 因为各方向之间会相互耦合。令 $A = (a_1, \dots, a_m)$ 且 A 满列秩, 正确公式来自法方程:

$$P_L u = A(A^\top A)^{-1} A^\top u.$$

当 $A = Q$ 的列标准正交时, $A^\top A = I$, 它才退化为 $QQ^\top u$ 。

来源: 第 5 讲原讲义第 5 页

命题 1.16 (一般基下的最小二乘投影). 设 $A \in \mathbb{R}^{n \times m}$ 满列秩。问题

$$\min_{c \in \mathbb{R}^m} \|u - Ac\|^2$$

有唯一解 $c_\star = (A^\top A)^{-1} A^\top u$, 且残差 $r = u - Ac_\star$ 与 $\text{Range}(A)$ 垂直。

证明. 展开目标函数并求梯度:

$$\phi(c) = u^\top u - 2c^\top A^\top u + c^\top A^\top A c, \quad \nabla \phi(c) = 2A^\top (Ac - u).$$

满列秩意味着对 $z \neq 0$ 有 $z^\top A^\top A z = \|Az\|^2 > 0$, 故 $A^\top A$ 正定可逆。令梯度为零, 得法方程 $A^\top A c_\star = A^\top u$ 及所述唯一解; 法方程同时说明 $A^\top r = 0$, 也即 $r \perp \text{Range}(A)$ 。□

优化连接: 投影梯度法

若闭凸可行集恰是线性子空间 L , 一步投影梯度法为

$$x_{k+1} = P_L(x_k - \eta \nabla f(x_k)).$$

若 $x_k \in L$ 且 $P_L = QQ^\top$, 则 $x_{k+1} = x_k - \eta QQ^\top \nabla f(x_k)$: 算法只保留梯度在可行方向上的分量。对于仿射约束 $Cx = d$, 可先找一个可行点 x_0 , 再用 $\text{Ker } C$ 的标准正交基参数化 $x = x_0 + Qz$ 。

1.4 Gram-Schmidt 正交化

1.4.1 算法及其两个不变量

设 $v_1, \dots, v_m$ 张成 L 。经典 Gram-Schmidt 过程定义

$$\hat{u}_1 = v_1, \quad \hat{u}_k = v_k - \sum_{i=1}^{k-1} \frac{v_k^\top \hat{u}_i}{\hat{u}_i^\top \hat{u}_i} \hat{u}_i \quad (k \geq 2),$$

并删除所有 $\hat{u}_k = 0$ 的项。若需要标准正交基, 则把非零项归一化: $u_k = \hat{u}_k / \|\hat{u}_k\|$ 。用已经归一化的 u_i 写, 公式变为

$$\hat{u}_k = v_k - \sum_{i < k} (u_i^\top v_k) u_i.$$

来源: 第 5 讲原讲义第 5-6 页

定理 1.17 (Gram-Schmidt 的正确性). 对每个 k , Gram-Schmidt 过程满足:

1. 所有保留下来的向量两两正交;
2. $\text{span}\{\hat{u}_1, \dots, \hat{u}_k\} = \text{span}\{v_1, \dots, v_k\}$, 其中零向量可删去;
3. $\hat{u}_k = 0$ 当且仅当 $v_k \in \text{span}\{v_1, \dots, v_{k-1}\}$.

因此该过程删除的恰是线性冗余向量, 最终得到 L 的一组正交基。

证明. 用归一化形式证明。假设 $u_1, \dots, u_{k-1}$ 已标准正交。对任意 $j < k$,

$$\begin{aligned} u_j^\top \hat{u}_k &= u_j^\top v_k - \sum_{i < k} (u_i^\top v_k) u_j^\top u_i \\ &= u_j^\top v_k - (u_j^\top v_k) = 0. \end{aligned}$$

故新向量与所有旧向量正交, 归一化不改变正交性。

又因为 $\hat{u}_k = v_k - \sum_{i < k} (u_i^\top v_k) u_i$, 且归纳假设给出 $u_i \in \text{span}\{v_1, \dots, v_i\}$, 所以 $\hat{u}_k \in \text{span}\{v_1, \dots, v_k\}$ 。反过来,

$$v_k = \hat{u}_k + \sum_{i < k} (u_i^\top v_k) u_i$$

属于 $\text{span}\{\hat{u}_1, \dots, \hat{u}_k\}$ 。结合前 $k-1$ 步的归纳假设, 两边张成空间相同。

最后, $\hat{u}_k = 0$ 恰好表示 $v_k = \sum_{i < k} (u_i^\top v_k) u_i$, 也即 v_k 属于先前张成空间; 反向结论由 v_k 的正交投影等于自身立即得到。□

易错点：精确算法与浮点算法

上述经典 Gram-Schmidt (CGS) 在精确算术中完全正确, 但当输入列近乎相关时, 浮点舍入会使已经得到的向量丧失正交性。实际计算中常采用修正 Gram-Schmidt (MGS), 即每减去一个投影便立刻更新剩余向量; 要求更高稳定性时使用 Householder QR, 必要时还可做二次正交化。

1.4.2 课堂练习二：逐步求标准正交基

来源：第 5 讲原讲义第 6-7 页

思考题 1.18. 求下列向量所张成空间的一组标准正交基：

$$v_1 = \begin{pmatrix} 1 \\ 2 \\ 2 \\ 0 \end{pmatrix}, \quad v_2 = \begin{pmatrix} 0 \\ 1 \\ 2 \\ 2 \end{pmatrix}, \quad v_3 = \begin{pmatrix} 3 \\ 4 \\ 0 \\ 0 \end{pmatrix}.$$

详细解答. 第一步, $\|v_1\| = 3$, 所以

$$u_1 = \frac{v_1}{\|v_1\|} = \begin{pmatrix} 1/3 \\ 2/3 \\ 2/3 \\ 0 \end{pmatrix}.$$

第二步, $u_1^T v_2 = 2$, 故

$$\hat{u}_2 = v_2 - 2u_1 = \begin{pmatrix} -2/3 \\ -1/3 \\ 2/3 \\ 2 \end{pmatrix}, \quad \|\hat{u}_2\|^2 = \frac{4}{9} + \frac{1}{9} + \frac{4}{9} + 4 = 5.$$

因此

$$u_2 = \frac{\hat{u}_2}{\sqrt{5}} = \begin{pmatrix} -2/(3\sqrt{5}) \\ -1/(3\sqrt{5}) \\ 2/(3\sqrt{5}) \\ 2/\sqrt{5} \end{pmatrix}.$$

第三步, 两个投影系数为

$$u_1^T v_3 = \frac{11}{3}, \quad u_2^T v_3 = -\frac{10}{3\sqrt{5}} = -\frac{2\sqrt{5}}{3}.$$

于是

$$\begin{aligned} \hat{u}_3 &= v_3 - (u_1^T v_3)u_1 - (u_2^T v_3)u_2 \\ &= \begin{pmatrix} 3 \\ 4 \\ 0 \\ 0 \end{pmatrix} - \frac{11}{3} \begin{pmatrix} 1/3 \\ 2/3 \\ 2/3 \\ 0 \end{pmatrix} + \frac{2\sqrt{5}}{3} \begin{pmatrix} -2/(3\sqrt{5}) \\ -1/(3\sqrt{5}) \\ 2/(3\sqrt{5}) \\ 2/\sqrt{5} \end{pmatrix} \\ &= \begin{pmatrix} 4/3 \\ 4/3 \\ -2 \\ 4/3 \end{pmatrix}. \end{aligned}$$

其范数平方为

$$\|\hat{u}_3\|^2 = \frac{16}{9} + \frac{16}{9} + 4 + \frac{16}{9} = \frac{28}{3},$$

故

$$u_3 = \sqrt{\frac{3}{28}} \begin{pmatrix} 4/3 \\ 4/3 \\ -2 \\ 4/3 \end{pmatrix} = \begin{pmatrix} 2/\sqrt{21} \\ 2/\sqrt{21} \\ -\sqrt{3/7} \\ 2/\sqrt{21} \end{pmatrix}.$$

所以所求标准正交基为 $\{u_1, u_2, u_3\}$ 。最后可作完整核验：

$$u_i^T u_j = \delta_{ij} \quad (1 \leq i, j \leq 3),$$

且由 Gram-Schmidt 的张成空间不变量，它与原三个向量张成同一空间。 $\square$

该题还直接给出了矩阵 $A = (v_1, v_2, v_3)$ 的薄 QR 分解。令 $Q = (u_1, u_2, u_3)$ ，则

$$A = QR, \quad R = \begin{pmatrix} 3 & 2 & 11/3 \\ 0 & \sqrt{5} & -2\sqrt{5}/3 \\ 0 & 0 & 2\sqrt{21}/3 \end{pmatrix}.$$

其中 $r_{ij} = u_i^T v_j$ ($i < j$)，而 r_{jj} 是第 j 个正交化剩余量的范数。

1.4.3 超平面标准正交基：避免不必要的完整消元

来源：第 5 讲原讲义第 7-8 页

思考题 1.19. 求超平面

$$L = \{x \in \mathbb{R}^4 : (1, 2, -2, 3)x = 0\}$$

的一组标准正交基。

详细解答. 由于法向量 $a = (1, 2, -2, 3)^T \neq 0$ ，矩阵 a^T 的秩为 1，由秩-零度定理 $\dim L = 4 - 1 = 3$ 。

先直接构造两个既在 L 中又互相垂直的向量：

$$v_1 = \begin{pmatrix} -2 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \quad v_2 = \begin{pmatrix} 0 \\ 0 \\ 3 \\ 2 \end{pmatrix}.$$

确有 $a^T v_1 = a^T v_2 = v_1^T v_2 = 0$ 。为构造第三个向量，要求 v_3 同时垂直于 a, v_1, v_2 ，即解

$$\begin{pmatrix} 1 & 2 & -2 & 3 \\ -2 & 1 & 0 & 0 \\ 0 & 0 & 3 & 2 \end{pmatrix} v_3 = 0.$$

可取

$$v_3 = \begin{pmatrix} 13/5 \\ 26/5 \\ 2 \\ -3 \end{pmatrix}.$$

逐项核验：

$$a^T v_3 = 0, \quad v_1^T v_3 = 0, \quad v_2^T v_3 = 0.$$

三个向量均非零且两两正交，故自动线性无关；又因 $\dim L = 3$ ，它们已经是 L 的正交基。

最后归一化。由

$$\|v_1\| = \sqrt{5}, \quad \|v_2\| = \sqrt{13}, \quad \|v_3\| = \frac{3\sqrt{130}}{5},$$

得到

$$u_1 = \begin{pmatrix} -2/\sqrt{5} \\ 1/\sqrt{5} \\ 0 \\ 0 \end{pmatrix}, \quad u_2 = \begin{pmatrix} 0 \\ 0 \\ 3/\sqrt{13} \\ 2/\sqrt{13} \end{pmatrix},$$

以及

$$u_3 = \begin{pmatrix} \sqrt{13}/(3\sqrt{10}) \\ \sqrt{26}/(3\sqrt{5}) \\ \sqrt{10}/(3\sqrt{13}) \\ -\sqrt{5}/\sqrt{26} \end{pmatrix}.$$

这就是所求标准正交基。

□

优化连接：零空间法

对等式约束 $a^T x = b$, 令 $Q = (u_1, u_2, u_3)$, 则 $Q^T Q = I$ 且 $a^T Q = 0$ 。选任一可行点 x_0 后, 所有可行点唯一写成 $x = x_0 + Qz$ 。于是约束问题 $\min_{a^T x=b} f(x)$ 化为无约束问题 $\min_z f(x_0 + Qz)$, 其梯度与 Hessian 分别为

$$Q^T \nabla f(x_0 + Qz), \quad Q^T \nabla^2 f(x_0 + Qz) Q.$$

标准正交的 Q 不会额外放大欧氏条件数, 是数值上理想的可行方向坐标。

1.5 QR 与 LQ 分解

1.5.1 分解的严格表述与证明

来源：第 5 讲原讲义第 8 页

定理 1.20 (完整 QR 与薄 QR). 对任意 $A \in \mathbb{R}^{m \times n}$, 存在正交矩阵 $Q \in \mathbb{R}^{m \times m}$ 和上梯形矩阵 $R \in \mathbb{R}^{m \times n}$, 使

$$A = QR, \quad r_{ij} = 0 \quad (i > j).$$

若 $m \geq n$ 且 A 满列秩, 则存在薄 QR 分解

$$A = Q_1 R_1, \quad Q_1 \in \mathbb{R}^{m \times n}, \quad Q_1^T Q_1 = I_n, \quad R_1 \in \mathbb{R}^{n \times n}$$

其中 R_1 上三角且对角元可选为正。在此正对角约定下, 薄 QR 分解唯一。

证明. 先证明满列秩情形。对 A 的列 $a_1, \dots, a_n$ 做 Gram-Schmidt。满列秩保证每一步的正交化剩余量都非零, 得到标准正交向量 $q_1, \dots, q_n$ 。第 k 列满足

$$a_k = \sum_{i=1}^{k-1} (q_i^T a_k) q_i + \|\hat{u}_k\| q_k = \sum_{i=1}^k r_{ik} q_i,$$

其中

$$r_{ik} = q_i^T a_k \quad (i < k), \quad r_{kk} = \|\hat{u}_k\| > 0, \quad r_{ik} = 0 \quad (i > k).$$

逐列合并便得 $A = Q_1 R_1$ 。

把 Q_1 的标准正交列扩充成 $\mathbb{R}^m$ 的标准正交基 $Q = (Q_1, Q_2)$ ，并令 $R = \begin{pmatrix} R_1 \\ 0 \end{pmatrix}$ ，便得到完整 QR。一般的秩亏矩阵也存在完整 QR；一种不依赖“删除零向量”细节的构造是依次用 Householder 正交反射把第 k 列在第 k 行以下的分量消为零。各反射的乘积仍正交，最终矩阵即为上梯形 R 。

最后证明唯一性。若 $A = Q_1 R_1 = \tilde{Q}_1 \tilde{R}_1$ 且两个三角因子的对角元均为正，则

$$U := \tilde{Q}_1^T Q_1 = \tilde{R}_1 R_1^{-1}.$$

因为 Q_1 与 $\tilde{Q}_1$ 都张成 $\text{Range}(A)$ ， U 是该子空间中两组标准正交基之间的换基矩阵，因而正交；等式右侧又说明它是上三角矩阵。上三角正交矩阵只能是对角元为 ± 1 的对角矩阵，而正对角约定又迫使这些符号全为 $+1$ 。所以 $U = I$ ，进而 $Q_1 = \tilde{Q}_1$ 、 $R_1 = \tilde{R}_1$ 。□

易错点：秩亏时“删去零向量”需要保留列号

若第 k 个 Gram-Schmidt 剩余量为零，只能说明 a_k 依赖于此前的列。计算 R 时仍需保留原列号，并记录 $r_{ik} = q_i^T a_k$ ；不能把 A 的这一列从分解中直接删去。秩亏 QR 的 Q 的补空间部分也不唯一。

来源：第 5 讲原讲义第 8 页

推论 1.21 (LQ 分解). 对任意 $A \in \mathbb{R}^{m \times n}$ ，把 A^T 作 QR 分解即可得到

$$A = LQ,$$

其中 L 为下梯形矩阵， Q 为相应尺寸的正交矩阵（或在经济型分解中具有标准正交行）。

证明. 若 $A^T = \tilde{Q}\tilde{R}$ ，取转置便有 $A = \tilde{R}^T \tilde{Q}^T$ 。令 $L = \tilde{R}^T$ 、 $Q = \tilde{Q}^T$ ；上梯形的转置是下梯形，正交矩阵的转置仍正交。□

1.5.2 QR 解方程与最小二乘：方阵和矩形必须区分

来源：第 5 讲原讲义第 9 页

命题 1.22 (QR 求解规则). 1. 若 $A \in \mathbb{R}^{n \times n}$ 非奇异且 $A = QR$ ，则 $Ax = b$ 等价于上三角方程 $Rx = Q^T b$ 。

2. 若 $A \in \mathbb{R}^{m \times n}$ 、 $m \geq n$ 满列秩，且薄 QR 为 $A = Q_1 R_1$ ，则

$$\arg \min_x \|Ax - b\|^2 = R_1^{-1} Q_1^T b.$$

证明. 方阵情形左乘 $Q^T = Q^{-1}$ 即得第一式。

矩形情形把 Q_1 扩充为 $Q = (Q_1, Q_2)$ 。由于正交变换保持范数，

$$\begin{aligned}\|Ax - b\|^2 &= \|Q^T(Q_1 R_1 x - b)\|^2 \\ &= \|R_1 x - Q_1^T b\|^2 + \|Q_2^T b\|^2.\end{aligned}$$

第二项与 x 无关；第一项能且只能在 $R_1 x = Q_1^T b$ 时取零。因为 R_1 可逆，解唯一。 $\square$

易错点：原讲义末页的等价变形有使用条件

只有 Q 是方形正交矩阵时， $Ax = b \iff Rx = Q^T b$ 才是一般的方程等价变形。对高矩阵的超定方程， b 通常不在 $\text{Range}(A)$ 中，应该把问题解释为最小二乘；此时 $Q_2^T b$ 是不可消除的最优残差分量。

来源：第 5 讲原讲义第 9 页

命题 1.23 (Gram 矩阵与三角因子). 若 $A = Q_1 R_1$ 是薄 QR，则

$$A^T A = R_1^T R_1.$$

若 $A = LQ_1$ 且 $Q_1 Q_1^T = I$ 是经济型 LQ，则

$$AA^T = LL^T.$$

证明. 直接利用标准正交列或行：

$$A^T A = R_1^T Q_1^T Q_1 R_1 = R_1^T R_1,$$

以及

$$AA^T = LQ_1 Q_1^T L^T = LL^T.$$

$\square$

优化连接：最小二乘、Gauss-Newton 与数值稳定性

非线性最小二乘在当前点线性化后需要求

$$\min_p \|Jp + r\|^2.$$

若直接形成法方程 $J^T J p = -J^T r$ ，在二范数下 $\text{cond}(J^T J) = \text{cond}(J)^2$ ，会把病态程度平方。用 QR 解 $Rp = -Q_1^T r$ 不必显式形成 $J^T J$ ，通常更稳定。这也是 Gauss-Newton、线性最小二乘和许多信赖域子问题中偏爱 QR 的原因。

1.6 Cholesky 分解与正定性的等价条件

原讲义最后提出：“哪些矩阵能写成 LL^T ，以及如何计算？”答案的核心是实对称正定性。以下把这一开放题完整解决。

1.6.1 存在性、唯一性和递推公式

来源：第 5 讲原讲义第 9 页

思考题 1.24 (Cholesky 开放题). 刻画所有能写成

$$A = LL^T$$

的实矩阵，其中 L 是对角元为正的可逆下三角矩阵；证明刻画，并给出实际计算公式。

详细解答. 恰好是实对称正定矩阵，即满足

$$A = A^T, \quad x^T A x > 0 \quad (x \neq 0)$$

的矩阵。并且在要求 L 的对角元为正后，分解唯一。先证必要性。若 $A = LL^T$ 且 L 可逆，则 A 显然对称；对任意 $x \neq 0$,

$$x^T A x = x^T L L^T x = \|L^T x\|^2 > 0,$$

因为 L^T 可逆，不会把非零 x 映为零。再证充分性。对阶数作归纳。 $n = 1$ 时， $A = (a_{11})$ 正定意味着 $a_{11} > 0$ ，取 $L = (\sqrt{a_{11}})$ 。设结论对 $n - 1$ 阶矩阵成立，把 n 阶正定矩阵分块为

$$A = \begin{pmatrix} a & r^T \\ r & B \end{pmatrix}, \quad a = a_{11} > 0.$$

令 $\ell = r/\sqrt{a}$ ，并定义 Schur 补

$$S = B - \frac{1}{a} r r^T = B - \ell \ell^T.$$

对任意 $y \neq 0$ ，取 $t = -r^T y/a$ ，则

$$\begin{pmatrix} t \\ y \end{pmatrix}^T A \begin{pmatrix} t \\ y \end{pmatrix} = y^T S y > 0,$$

故 S 仍正定。由归纳假设， $S = L_2 L_2^T$ ，其中 L_2 下三角且对角元为正。于是

$$L = \begin{pmatrix} \sqrt{a} & 0 \\ \ell & L_2 \end{pmatrix}$$

满足

$$LL^T = \begin{pmatrix} a & \sqrt{a} \ell^T \\ \sqrt{a} \ell & \ell \ell^T + L_2 L_2^T \end{pmatrix} = \begin{pmatrix} a & r^T \\ r & B \end{pmatrix} = A.$$

比较等式 $a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} l_{jk}$ ，便得到逐列递推：

$$l_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2},$$

$$l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}}{l_{jj}}, \quad i = j+1, \dots, n.$$

正定性保证每个根号内严格为正，所以不会遇到零主元。

唯一性也可从递推式看出：正对角约定唯一确定 l_{11} ，继而唯一确定第一列；然后唯一确定 l_{22} 和第二列，如此继续。故 L 唯一。 $\square$

来源：第 5 讲原讲义第 9 页

例 1.25 (手算一个 Cholesky 分解). 取

$$A = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 5 & 1 \\ 2 & 1 & 3 \end{pmatrix}.$$

依递推式，

$$l_{11} = 2, \quad l_{21} = 1, \quad l_{31} = 1, \quad l_{22} = \sqrt{5-1} = 2, \quad l_{32} = \frac{1-1 \cdot 1}{2} = 0, \quad l_{33} = \sqrt{3-1} = \sqrt{2}.$$

所以

$$A = LL^T, \quad L = \begin{pmatrix} 2 & 0 & 0 \\ 1 & 2 & 0 \\ 1 & 0 & \sqrt{2} \end{pmatrix}.$$

相乘可直接核验。该例的三个顺序主子式为 4, 16, 32，均为正，与下面的 Sylvester 判据一致。

易错点：半正定、奇异或不定时会发生什么

若只知道 $A \succeq 0$ ，可以写成某个 Gram 因子 $A = BB^T$ ，但因子可能奇异，无主元 Cholesky 递推可能遇到零主元，需要枢轴处理。实对称不定矩阵一般不能写成实的 LL^T ，因为后者必半正定；它更适合用带符号的 LDL^T 分解（实际算法常用 Bunch-Kaufman 枢轴）。非对称矩阵更不属于上述 Cholesky 定理的范围。

1.6.2 正定性的完整等价链与 Sylvester 判据

记 $A_k = A[1:k, 1:k]$ 为左上 k 阶顺序主子矩阵， $\Delta_k = \det A_k$ ，并约定 $\Delta_0 = 1$ 。

来源：第 5 讲原讲义第 9 页（围绕 Cholesky 问题的补充）

定理 1.26 (实对称矩阵正定的等价条件). 设 $A = A^T \in \mathbb{R}^{n \times n}$ 。以下条件等价：

1. $x^T A x > 0$ 对所有 $x \neq 0$ 成立；
2. A 的全部特征值均为正；
3. 存在可逆矩阵 B 使 $A = B^T B$ ；
4. 存在唯一的正对角下三角矩阵 L 使 $A = LL^T$ ；
5. 所有顺序主子式均为正： $\Delta_k > 0$ ($k = 1, \dots, n$)；
6. 所有主子式均为正；
7. A 有分解 $A = L_0 D L_0^T$ ，其中 L_0 是单位下三角矩阵， $D = \text{diag}(d_1, \dots, d_n)$ 且每个 $d_k > 0$ 。

第 5 条通常称为 Sylvester 判据。

证明. (1) $\iff$ (2): 由实对称矩阵的谱定理, $A = U\Lambda U^\top$, 其中 U 正交、 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 。令 $y = U^\top x$, 则

$$x^\top Ax = y^\top \Lambda y = \sum_{i=1}^n \lambda_i y_i^2.$$

若所有 $\lambda_i > 0$, 该式对 $x \neq 0$ 为正; 反之取某个特征向量作为 x , 便知对应特征值必须为正。

(2) $\implies$ (3): 取 $B = \Lambda^{1/2} U^\top$, 则 B 可逆且 $B^\top B = U\Lambda U^\top = A$ 。(3) $\implies$ (1): $x^\top Ax = \|Bx\|^2 > 0$, 因为 B 可逆。

(1) $\iff$ (4) 已在 Cholesky 开放题中证明。

(1) $\implies$ (6): 任取非空指标集 I , 主子矩阵 $A[I, I]$ 对任意非零 z 满足

$$z^\top A[I, I]z = \tilde{z}^\top A \tilde{z} > 0,$$

其中 $\tilde{z}$ 是把 z 填入坐标 I 、其余坐标置零所得向量。因此每个主子矩阵正定, 其特征值均正, 行列式 (特征值之积) 也正。显然 (6) $\implies$ (5)。

(5) $\implies$ (7): 顺序主子式都非零, 故对称高斯消元可在不换行列的情况下进行, 得到 $A = L_0 D L_0^\top$ 。取前 k 阶行列式, 单位下三角因子的行列式为 1, 故

$$\Delta_k = d_1 \cdots d_k, \quad d_k = \frac{\Delta_k}{\Delta_{k-1}} > 0.$$

(7) $\implies$ (1): 对 $x \neq 0$, $L_0^\top x \neq 0$, 且

$$x^\top Ax = (L_0^\top x)^\top D (L_0^\top x) > 0.$$

这闭合了全部等价关系。另由 $D^{1/2}$ 可见 $L = L_0 D^{1/2}$ 正是 Cholesky 因子。 $\square$

注记 1.27. “顺序主子式全正” 只在已经假设 A 对称 (复数情形为 Hermitian) 时等价于正定。仅有 $\det A > 0$ 远远不够, 例如 $\text{diag}(-1, -1)$ 的行列式为正, 但它是负定矩阵。

1.6.3 正定性在优化器中的直接作用

来源: 第 5 讲原讲义第 9 页 (Cholesky 的优化应用补充)

命题 1.28 (正定 Hessian 与强凸二次函数). 设

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \quad A = A^\top.$$

则 $A \succ 0$ 当且仅当 f 严格 (事实上强) 凸。此时唯一极小点 $x_\star = A^{-1}b$, 并且

$$f(x) - f(x_\star) = \frac{1}{2} (x - x_\star)^\top A (x - x_\star).$$

若 $0 < \lambda_{\min} \leq \lambda_{\max}$ 是 A 的极端特征值, 则

$$\frac{\lambda_{\min}}{2} \|x - x_\star\|^2 \leq f(x) - f(x_\star) \leq \frac{\lambda_{\max}}{2} \|x - x_\star\|^2.$$

证明. $\nabla f(x) = Ax - b$, $\nabla^2 f(x) = A$ 。若 $A \succ 0$, 方程 $Ax = b$ 有唯一解 $x_\star$ 。将 $b = Ax_\star$ 代入并配方, 得到所述恒等式。再在正交特征基中展开 $x - x_\star$, 即可用 $\lambda_{\min}$ 与 $\lambda_{\max}$ 夹住二次型。反之, 若 A 有非正特征值 λ 及对应单位特征向量 v , 则沿直线 $x + tv$ 的二阶项为 $\lambda t^2/2$, 不可能严格凸; 故严格凸的对称二次函数必有 $A \succ 0$ 。 $\square$

优化连接：Newton 步、阻尼与 Cholesky 求解

在局部二次模型

$$m(p) = f(x) + g^\top p + \frac{1}{2} p^\top H p$$

中，若 $H \succ 0$ ，唯一 Newton 步满足 $H p = -g$ 。计算时先分解 $H = L L^\top$ ，再依次解两个三角方程

$$L y = -g, \quad L^\top p = y,$$

不应显式形成 H^{-1} 。分解一旦完成，每次三角求解约需 $O(n^2)$ 运算。

若 Hessian 不正定或接近奇异，常用阻尼 $H + \lambda I$ 。只要 $\lambda > -\lambda_{\min}(H)$ ，它就是正定的，从而 Cholesky 成功且所得方向满足

$$g^\top p = -p^\top (H + \lambda I) p < 0$$

($g \neq 0$)，即为下降方向。这是 Levenberg-Marquardt 和信赖域方法的重要线性代数基础。

优化连接：梯度下降速率由谱与条件数控制

对上述正定二次函数，固定步长梯度下降满足

$$e_{k+1} = (I - \eta A) e_k, \quad e_k = x_k - x_\star.$$

在特征方向上，第 i 个误差分量乘以 $1 - \eta \lambda_i$ 。因此收敛的充要步长条件是 $0 < \eta < 2/\lambda_{\max}$ 。使最坏方向收缩因子最小的固定步长为

$$\eta_\star = \frac{2}{\lambda_{\min} + \lambda_{\max}}, \quad \rho_\star = \frac{\kappa - 1}{\kappa + 1}, \quad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

这解释了预条件的目标：通过坐标变换使 Hessian 的谱更集中、条件数更接近 1。若 $A = L L^\top$ ，理想变换 $y = L^\top x$ 会把二次项化为 $\frac{1}{2} \|y\|^2$ 。

1.7 本讲逻辑总览与自检

本讲的核心依赖关系可以概括为

$$\begin{aligned} \text{线性无关} &\implies \text{基与坐标} \implies \text{正交化} \implies \text{QR}, \\ \text{QR 的 Gram 矩阵} &\implies A^\top A = R^\top R \implies \text{Cholesky 与正定性}, \\ \text{正交补} &\implies \text{投影} \implies \text{最小二乘与约束优化}. \end{aligned}$$

建议完成以下自检：

1. 能否解释为何 $L_1 \cup L_2$ 通常不是子空间，而 $L_1 + L_2$ 一定是？
2. 能否不借助行列式，仅按坐标顺序证明讲义第 3 页的三个基向量线性无关？
3. 能否从“残差与子空间垂直”重新推导法方程？
4. 能否由 Gram-Schmidt 的每一步写出 R 的一列？
5. 能否说明为什么矩形 QR 中 $Rx = Q^\top b$ 应解释为最小二乘而非总是等价方程？

6. 能否从 Cholesky 递推式解释正定矩阵为何不会出现非正根号？
7. 能否在不计算特征值的情况下，用顺序主子式判断一个实对称矩阵是否正定？

第 2 章

第 6 讲：维数、子空间运算与坐标变换

本章把原讲义第 6 讲的四页内容按“基与坐标—维数与秩—空间的和、直和与商—换基与相似”的逻辑补全。原讲义中的向量空间均为有限维实向量空间；涉及正交补和投影时，还默认空间带有欧氏内积。若底域为复数，只需把转置改为共轭转置。

易错点本章的三个记号约定

- (1) 基向量按列排成的矩阵仍用大写字母表示。例如 $V = [v_1, \dots, v_n]$ ，于是 $x = Vy$ 表示 $y = [x]_V$ 是 x 在基 V 下的坐标。
- (2) $U + W$ 表示子空间的和； $U \oplus W$ 表示直和。直和只要求分解唯一，并不要求 $U \perp W$ ；正交直和会明确写成 $U \overset{\perp}{\oplus} W$ 或同时注明正交。
- (3) 商空间中的元素是陪集 $x + W$ ，不是原空间中的单个向量。只有在选定内积后，才能借助正交投影把 V/W 具体实现为 $W^\perp$ 。

2.1 基、坐标与基的生成

2.1.1 基为何就是一个坐标系

来源：第 6 讲原讲义第 1 页

定义 2.1. 设 V 是线性空间。若向量组

$$\mathcal{B} = \{v_1, \dots, v_m\}$$

既线性无关又张成 V ，则称其为 V 的一组基。对任意 $x \in V$ ，若 $x = \sum_{i=1}^m \xi_i v_i$ ，则列向量 $[x]_{\mathcal{B}} = (\xi_1, \dots, \xi_m)^T$ 称为 x 在基 $\mathcal{B}$ 下的坐标。

来源：第 6 讲原讲义第 1 页 (Theorem 1.1 的证明补全)

定理 2.2 (坐标的存在唯一性). 若 $\mathcal{B} = \{v_1, \dots, v_m\}$ 是 V 的一组基，则每个 $x \in V$ 都存在唯一的坐标向量 $\xi \in \mathbb{R}^m$ ，使得

$$x = \sum_{i=1}^m \xi_i v_i.$$

若 $V = [v_1, \dots, v_m]$ ，则这也可写为 $V\xi = x$ 。

证明. 因为 $\text{span } \mathcal{B} = V$, 所以对每个 $x \in V$, 至少存在一组系数 $\xi_1, \dots, \xi_m$ 使上述等式成立, 这给出存在性。

再设 $\xi, \eta \in \mathbb{R}^m$ 都满足 $V\xi = x = V\eta$ 。两式相减得

$$0 = V(\xi - \eta) = \sum_{i=1}^m (\xi_i - \eta_i)v_i.$$

由于 $v_1, \dots, v_m$ 线性无关, 齐次线性组合只能有零系数, 故 $\xi_i - \eta_i = 0$ 对所有 i 成立, 即 $\xi = \eta$ 。这给出唯一性。 $\square$

易错点原证明中应如何读“矛盾”

若假设 $\xi \neq \eta$, 则 $\xi - \eta \neq 0$, 而 $\sum_i (\xi_i - \eta_i)v_i = 0$ 正好说明 $v_1, \dots, v_m$ 线性相关, 这与它们是基所要求的线性无关矛盾。不能把这一步误写成“说明向量组线性无关”。

坐标映射

$$\Phi_{\mathcal{B}} : V \longrightarrow \mathbb{R}^m, \quad x \longmapsto [x]_{\mathcal{B}}$$

是线性双射。因此, 选基等价于把抽象的 m 维空间与 $\mathbb{R}^m$ 建立一个线性坐标系统; 不同的基只是不同的坐标系统。

2.1.2 从生成集提取一组基

来源: 第 6 讲原讲义第 1 页 (“利用高斯消元删除多余向量”的计算题化)

思考题 2.3 (怎样从一组生成向量中删除冗余向量?). 给定 $a_1, \dots, a_m \in \mathbb{R}^n$, 如何求出 $\text{span}\{a_1, \dots, a_m\}$ 的一组基? 并对

$$A = [a_1, a_2, a_3] = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{pmatrix}$$

完成计算。

来源: 第 6 讲原讲义第 1 页 (详细解答)

详细解答. 对矩阵 $A = [a_1, \dots, a_m]$ 做行初等变换并求行最简形。行变换等于左乘可逆矩阵 E , 所以

$$\sum_{j=1}^m c_j a_j = 0 \iff \sum_{j=1}^m c_j (E a_j) = 0.$$

也就是说, 行变换保持列之间的全部线性关系。找到行最简形中的主元列后, 应取原矩阵中相同编号的列作为原列空间的一组基。

本题中

$$\begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{pmatrix} \xrightarrow{R_3 \leftarrow R_3 - R_1} \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{pmatrix} \xrightarrow{\substack{R_3 \leftarrow R_3 - R_2 \\ R_1 \leftarrow R_1 - 2R_2}} \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix}.$$

主元列为第 1, 2 列, 故

$$\left\{ \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \\ 3 \end{pmatrix} \right\}$$

是列空间的一组基。事实上 $a_3 = a_2 - a_1$, 这也直接显示第三个向量是冗余的, 且 $\dim \text{Range}(A) = 2$ 。□

易错点为什么不能直接取行最简形的主元列

行最简形的主元列通常不属于原列空间, 因为行变换会把每个列向量都施加同一个可逆变换。主元编号反映原列的独立性, 所以要回到原矩阵取对应列。若只想得到一个与原列空间同构的空间的基, 才可以直接使用变换后的列。

来源: 第 6 讲原讲义第 1 页 (Gram-Schmidt 步骤补全)

命题 2.4 (由线性无关组构造正交基). 设 $v_1, \dots, v_k$ 线性无关。递归定义

$$\begin{aligned} u_1 &= v_1, \\ u_j &= v_j - \sum_{i=1}^{j-1} \frac{\langle u_i, v_j \rangle}{\langle u_i, u_i \rangle} u_i, \quad j = 2, \dots, k. \end{aligned}$$

则 $u_1, \dots, u_k$ 两两正交, 并且对每个 j ,

$$\text{span}\{u_1, \dots, u_j\} = \text{span}\{v_1, \dots, v_j\}.$$

归一化 $q_i = u_i / \|u_i\|$ 后得到同一空间的一组标准正交基。

证明. 用归纳法。假设 $u_1, \dots, u_{j-1}$ 已两两正交。对任意 $\ell < j$,

$$\langle u_\ell, u_j \rangle = \langle u_\ell, v_j \rangle - \sum_{i=1}^{j-1} \frac{\langle u_i, v_j \rangle}{\langle u_i, u_i \rangle} \langle u_\ell, u_i \rangle = \langle u_\ell, v_j \rangle - \langle u_\ell, v_j \rangle = 0.$$

并且 u_j 是 v_j 与前面 u_i 的线性组合, 所以 $\text{span}\{u_1, \dots, u_j\} \subseteq \text{span}\{v_1, \dots, v_j\}$ 。反过来, 由定义

$$v_j = u_j + \sum_{i < j} \frac{\langle u_i, v_j \rangle}{\langle u_i, u_i \rangle} u_i,$$

故相反的包含关系也成立。若某个 $u_j = 0$, 则 v_j 属于前面向量的张成, 与原向量组线性无关矛盾, 因此归一化合法。□

优化连接: 坐标、正交化与数值稳定性

若 $V = [v_1, \dots, v_m]$ 是一般基, 求坐标需要解 $V\xi = x$; 当 V 近似线性相关时, 这个过程会放大舍入误差。若 Q 是标准正交基, 则

$$[x]_Q = Q^T x, \quad \|[x]_Q\| = \|x\|$$

(当 Q 为方阵时), 不需求逆且不放大二范数误差。最小二乘法中 $A = QR$ 后求解 $Rx =$

$Q^T b$, 通常也比直接形成 $A^T A$ 更稳定, 因为后者把条件数平方: $\text{cond}(A^T A) = \text{cond}(A)^2$ (二范数、满列秩情形)。

2.2 维数与矩阵的秩

2.2.1 超过维数的向量必然相关

来源: 第 6 讲原讲义第 1 页 (Lemma 2.1 的证明补全)

引理 2.5 (奇异方阵存在非零零空间向量). 对 $A \in \mathbb{R}^{n \times n}$, 若 $\det A = 0$, 则存在 $x \neq 0$ 使 $Ax = 0$ 。

证明. 对 A 做高斯消元。 $\det A = 0$ 表明消元后不可能每一列都有主元, 否则 A 可化为单位矩阵并可逆。因而齐次方程 $Ax = 0$ 至少有一个自由变量。令一个自由变量为 1、其余自由变量为 0, 再回代确定主元变量, 便得到一个非零解 x 。等价地说, $\det A = 0$ 意味着 $\text{rank } A < n$, 由秩-零化度关系 $\dim \text{Ker } A = n - \text{rank } A > 0$, 故 $\text{Ker } A$ 中含非零向量。□

来源: 第 6 讲原讲义第 1-2 页 (Lemma 2.2 的证明补全)

引理 2.6 ($n+1$ 个向量必相关). 在 n 维线性空间 V 中任取 $n+1$ 个向量 $w_1, \dots, w_{n+1}$, 它们必线性相关。

证明. 先选定 V 的一组基, 把每个 w_i 写成 $\mathbb{R}^n$ 中的坐标列, 线性相关性在坐标映射下保持不变。令 $A = [w_1, \dots, w_n]$ 。

若 $\det A = 0$, 上一引理给出非零 $c \in \mathbb{R}^n$ 使 $\sum_{i=1}^n c_i w_i = 0$, 故前 n 个已经相关。若 $\det A \neq 0$, 则 A 可逆, 取 $c = A^{-1}w_{n+1}$, 有

$$w_{n+1} = \sum_{i=1}^n c_i w_i.$$

于是 $\sum_{i=1}^n c_i w_i - w_{n+1} = 0$ 是系数不全为零的线性关系。两种情形都得到结论。□

2.2.2 维数定义不依赖基的选择

来源: 第 6 讲原讲义第 2 页 (Theorem 2.3 的证明补全)

定理 2.7 (维数良定义). 有限维空间 V 的任意两组基所含向量个数相同。这个共同的数称为 V 的维数, 记为 $\dim V$ 。

证明. 设 $\mathcal{B} = (v_1, \dots, v_m)$ 与 $\mathcal{C} = (u_1, \dots, u_n)$ 都是 V 的基。把每个 u_j 用 $\mathcal{B}$ 表示:

$$u_j = \sum_{i=1}^m a_{ij} v_i, \quad A = (a_{ij}) \in \mathbb{R}^{m \times n}.$$

若 $Ac = 0$, 则

$$0 = \sum_{i=1}^m (Ac)_i v_i = \sum_{j=1}^n c_j u_j.$$

由于 u_j 线性无关, 必有 $c = 0$ 。所以 $\text{Ker } A = \{0\}$, 即 A 的 n 个列向量线性无关, 进而 $n \leq m$ 。交换两组基的角色, 同理得 $m \leq n$, 故 $m = n$ 。□

来源: 第 6 讲原讲义第 2 页 (Theorem 2.4 与“基的扩张”的共同证明工具)

引理 2.8 (Steinitz 交换引理). 若 $s_1, \dots, s_m$ 张成 V , 而 $u_1, \dots, u_k$ 线性无关, 则 $k \leq m$, 并且可以用 $u_1, \dots, u_k$ 依次替换生成组中的 k 个向量, 仍得到一个含 m 个向量的生成组。

证明. 因为 $s_1, \dots, s_m$ 张成 V , 可写 $u_1 = \sum_j \alpha_j s_j$ 。 $u_1 \neq 0$, 故某个 $\alpha_{j_1} \neq 0$; 把等式解出 s_{j_1} , 可知用 u_1 替换 s_{j_1} 后仍张成 V 。

假设已经用 $u_1, \dots, u_r$ 替换了 r 个 s_j , 且新向量组仍张成 V 。把 u_{r+1} 用这个新生成组表示。若所有尚未被替换的 s_j 的系数都为零, 则 $u_{r+1} \in \text{span}\{u_1, \dots, u_r\}$, 与 $u_1, \dots, u_{r+1}$ 线性无关矛盾。因此至少有一个尚未替换的 $s_{j_{r+1}}$ 的系数非零, 可以解出它并以 u_{r+1} 替换。归纳进行到 $r = k$ 。每一步都要消耗一个尚未替换的 s_j , 所以必有 $k \leq m$ 。□

来源: 第 6 讲原讲义第 2 页 (Theorem 2.4 的证明补全)

定理 2.9 (维数的两个极值刻画). 若 $\dim V = n$, 则

$$\begin{aligned} n &= \min\{m : \exists v_1, \dots, v_m, V = \text{span}\{v_1, \dots, v_m\}\} \\ &= \max\{m : \exists v_1, \dots, v_m \in V, v_1, \dots, v_m \text{ 线性无关}\}. \end{aligned}$$

证明. 任取一组含 n 个向量的基。若某生成组含 m 个向量, 把基作为交换引理中的线性无关组, 得 $n \leq m$; 所以任何生成组至少含 n 个向量, 而基达到这个下界。

若某线性无关组含 k 个向量, 把基作为交换引理中的生成组, 得 $k \leq n$; 所以任何线性无关组至多含 n 个向量, 而基达到这个上界。□

来源: 第 6 讲原讲义第 2 页 (Theorem 2.4 后基扩张结论的补全)

推论 2.10 (基的扩张与生成组的缩减). 有限维空间中, 任意线性无关组都能扩张成一组基; 任意有限生成组都能删去若干冗余向量而缩减成一组基。

证明. 若线性无关组尚未张成 V , 就在其张成空间之外选一个向量加入; 加入后仍线性无关。向量个数不可能超过 $\dim V$, 所以有限步后必张成 V 。反之, 若生成组线性相关, 就删除一个能由其余向量表示的向量; 张成空间不变。向量个数每次减少一, 故有限步后得到线性无关的生成组, 即一组基。□

来源: 第 6 讲原讲义第 2 页 (维数与矩阵秩的自然补充)

定理 2.11 (秩-零化度定理). 设 $A \in \mathbb{R}^{m \times n}$ 表示线性映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $T(x) = Ax$, 则

$$\dim \text{Ker } A + \text{rank } A = n.$$

证明. 设 $z_1, \dots, z_k$ 是 $\text{Ker } A$ 的一组基, 把它扩张为定义域 $\mathbb{R}^n$ 的一组基

$$z_1, \dots, z_k, v_1, \dots, v_{n-k}.$$

下面证明 $Av_1, \dots, Av_{n-k}$ 是 $\text{Range } A$ 的一组基。

任取 $x \in \mathbb{R}^n$, 在上述基下写成 $x = \sum_i \alpha_i z_i + \sum_j \beta_j v_j$, 则

$$Ax = \sum_j \beta_j Av_j,$$

所以这些像向量张成 $\text{Range } A$ 。若 $\sum_j \beta_j Av_j = 0$, 则 $\sum_j \beta_j v_j \in \text{Ker } A$, 故它也可写成 z_i 的线性组合。由扩张后整组基的线性无关性, 所有 $\beta_j = 0$, 所以像向量线性无关。因此

$$\text{rank } A = \dim \text{Range } A = n - k = n - \dim \text{Ker } A.$$

□

2.2.3 行秩等于列秩

来源: 第 6 讲原讲义第 2 页 (Theorem 2.5 的四步证明补全)

定理 2.12 (行秩等于列秩). 对任意 $A \in \mathbb{R}^{m \times n}$,

$$\dim \text{row}(A) = \dim \text{col}(A).$$

这个共同的数定义为矩阵的秩 $\text{rank}(A)$ 。

证明. 先说明初等变换不会改变行秩或列秩。

行变换: 一次行变换等于左乘一个可逆初等矩阵 E 。矩阵 EA 的每一行是 A 的行的线性组合, 而 $A = E^{-1}(EA)$ 又说明 A 的每一行是 EA 的行的线性组合, 故二者行空间相同。另一方面, EA 的列是 A 的各列在可逆线性映射 E 下的像; 可逆映射保持线性无关组的最大长度, 故列秩不变。

列变换: 一次列变换等于右乘可逆初等矩阵 F 。同理, AF 与 A 的列空间互相由可逆列组合生成, 故列秩不变; 每一行 r^T 则被送到 $r^T F$, 这是 $\mathbb{R}^n$ 上的可逆线性映射, 故行秩也不变。

通过有限次行、列初等变换, 存在可逆矩阵 P, Q 使

$$PAQ = \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix}.$$

右端恰有 r 个线性无关行, 也恰有 r 个线性无关列。由于上述变换同时保持两种秩, A 的行秩和列秩都等于 r 。 □

来源: 第 6 讲原讲义第 2 页 (“例子及证明” 的计算补充)

思考题 2.13 (用同一例子核对行秩与列秩). 对

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{pmatrix},$$

分别从原矩阵的行和列中找出一组最大线性无关组。

来源：第 6 讲原讲义第 2 页（详细解答）

详细解答. 前面的行消元给出两个主元, 所以 $\text{rank } A = 2$. 列方面, a_1, a_2 线性无关且 $a_3 = a_2 - a_1$, 故最大无关列组可取 $\{a_1, a_2\}$.

行方面, 记原矩阵三行为 r_1^T, r_2^T, r_3^T . 有 $r_3 = r_1 + r_2$, 而 r_1, r_2 不成比例, 所以 $\{r_1^T, r_2^T\}$ 是最大无关行组. 两者的大小都为 2. $\square$

优化连接：秩、参数可识别性与最小二乘

在线性最小二乘

$$\min_x \frac{1}{2} \|Ax - b\|^2$$

中, Hessian 为 $A^T A$. 它正定当且仅当 A 满列秩, 因为

$$x^T A^T A x = \|Ax\|^2,$$

右端对所有 $x \neq 0$ 严格为正恰好等价于 $\text{Ker } A = \{0\}$. 因此满列秩不仅意味着参数可识别, 也意味着最小二乘解唯一. 若秩亏, 则沿任意 $z \in \text{Ker } A$ 有 $A(x+z) = Ax$, 目标函数无法区分 x 与 $x+z$; 正则项 $\frac{\lambda}{2} \|x\|^2$ 则把 Hessian 改为 $A^T A + \lambda I \succ 0$.

2.3 空间的和、正交补、直和与商空间

2.3.1 子空间的和

来源：第 6 讲原讲义第 2 页

定义 2.14. 若 $V_1, \dots, V_m$ 是同一线性空间 V 的子空间, 定义

$$V_1 + \dots + V_m = \{v_1 + \dots + v_m : v_i \in V_i\}.$$

标量系数无需单独写出, 因为 $c_i v_i \in V_i$. 这个集合是包含每个 V_i 的最小子空间, 并且

$$V_1 + \dots + V_m = \text{span}(V_1 \cup \dots \cup V_m).$$

证明. 零向量可取为 $0 + \dots + 0$; 两个和的相加以及数乘仍可逐分量进行, 所以 $V_1 + \dots + V_m$ 是子空间. 它包含每个 V_i , 因此包含这些子空间并集的线性包. 反过来, 每个 $v_1 + \dots + v_m$ 本身就是并集中向量的有限线性组合, 故属于该线性包. 两边相等. $\square$

若 $\mathcal{B}_i$ 是 V_i 的一组基, 则 $\bigcup_i \mathcal{B}_i$ 一定张成 $\sum_i V_i$, 但通常不是基, 因为不同子空间可能有非零交集。

2.3.2 正交分解与投影

来源: 第 6 讲原讲义第 3 页 (Theorem 3.1 中投影存在性的补全)

定理 2.15 (有限维正交分解). 设 W 是有限维内积空间 V 的子空间, 则

$$V = W \oplus W^\perp.$$

也就是说, 每个 $x \in V$ 唯一分解为

$$x = P_W x + P_{W^\perp} x, \quad P_W x \in W, \quad P_{W^\perp} x \in W^\perp.$$

证明. 取 W 的一组标准正交基 $q_1, \dots, q_k$, 定义

$$w = \sum_{i=1}^k \langle q_i, x \rangle q_i, \quad u = x - w.$$

显然 $w \in W$. 对每个 j ,

$$\langle q_j, u \rangle = \langle q_j, x \rangle - \sum_{i=1}^k \langle q_i, x \rangle \langle q_j, q_i \rangle = 0,$$

故 $u \in W^\perp$, 从而 $V = W + W^\perp$.

若 $z \in W \cap W^\perp$, 则既有 $z \in W$ 又有 $z \perp W$, 特别地 $\langle z, z \rangle = 0$, 所以 $z = 0$. 因此和是直和, 分解唯一。上述 w, u 分别就是 $P_W x, P_{W^\perp} x$. $\square$

来源: 第 6 讲原讲义第 3 页 (“距离最近的点” 的严格证明补充)

命题 2.16 (正交投影是唯一最近点). 对任意 $x \in V$,

$$P_W x = \arg \min_{w \in W} \|x - w\|.$$

证明. 写 $x = P_W x + r$, 其中 $r \in W^\perp$. 任取 $w \in W$, $P_W x - w \in W$, 故两者正交。由勾股定理,

$$\|x - w\|^2 = \|r + (P_W x - w)\|^2 = \|r\|^2 + \|P_W x - w\|^2 \geq \|r\|^2.$$

等号成立当且仅当 $w = P_W x$, 所以最近点存在且唯一。 $\square$

若 $Q = [q_1, \dots, q_k]$ 的列是 W 的标准正交基, 则

$$P_W = QQ^\top, \quad P_{W^\perp} = I - QQ^\top.$$

若只有一般满列秩基矩阵 B , 则

$$P_W = B(B^\top B)^{-1}B^\top.$$

后一公式来自最小化 $\|x - Bc\|^2$ 的正规方程 $B^\top Bc = B^\top x$ 。

2.3.3 基的扩张与直和判据

来源: 第 6 讲原讲义第 3 页 (“基的扩张” 三条结论的证明补全)

命题 2.17 (和空间中基的拼接). 设 $\mathcal{B}_U, \mathcal{B}_W$ 分别是 U, W 的基。

- (1) $\mathcal{B}_U \cup \mathcal{B}_W$ 张成 $U + W$ 。
- (2) 若 $U \cap W = \{0\}$, 则该并集线性无关, 因而是 $U + W$ 的基。
- (3) 特别地, 若 $U \perp W$, 则 $U \cap W = \{0\}$; 若两边的基各自标准正交, 则拼接后是 $U + W$ 的标准正交基。

证明. 第一点来自任意 $x \in U + W$ 可写为 $x = u + w$, 再分别用两组基展开。

对第二点, 若

$$\sum_i \alpha_i u_i + \sum_j \beta_j w_j = 0,$$

则 $\sum_i \alpha_i u_i = -\sum_j \beta_j w_j \in U \cap W = \{0\}$ 。两边各自的基线性无关, 故所有 α_i, β_j 都为零。

若 $U \perp W$, 任意 $z \in U \cap W$ 满足 $\|z\|^2 = \langle z, z \rangle = 0$, 故 $z = 0$ 。若各自基标准正交, 跨子空间的内积也为零, 拼接后仍标准正交。□

来源: 第 6 讲原讲义第 3 页 (基扩张结论的构造性证明)

命题 2.18 (子空间的基可扩张为全空间的基). 若 $W \subseteq V$ 且 $\mathcal{B}_W$ 是 W 的基, 则存在向量组 $\mathcal{C}$, 使 $\mathcal{B}_W \cup \mathcal{C}$ 是 V 的基。在有限维内积空间中, 可取 $\mathcal{C}$ 为 $W^\perp$ 的一组基。

证明. 一般情形可用前述逐个添加不属于当前张成空间的向量的方法, 过程至多进行 $\dim V - \dim W$ 步。内积空间中, 由 $V = W \oplus W^\perp$, 取 $W^\perp$ 的任意一组基 $\mathcal{C}$, 上一命题直接说明两组基的并集是 V 的基。□

来源: 第 6 讲原讲义第 3 页 (直和定义及直观解释的严格化)

思考题 2.19 (什么时候空间的和是直和?). 说明外直和与内直和的区别, 并给出内直和的等价判据。直和是否一定是正交和?

来源: 第 6 讲原讲义第 3 页 (详细解答)

详细解答. 外直和定义为笛卡尔积

$$\bigoplus_{i=1}^m V_i = \{(v_1, \dots, v_m) : v_i \in V_i\},$$

运算逐分量进行。不同分量天然被区分, 可把它们想成放在互相独立的“坐标槽”中。

若 V_i 已经是同一空间 V 的子空间, 则称 $V_1 + \dots + V_m$ 是内直和, 当且仅当每个 $x \in V_1 + \dots + V_m$ 的分解 $x = v_1 + \dots + v_m$ 唯一。以下条件等价:

- (i) $V_1 + \dots + V_m = V_1 \oplus \dots \oplus V_m$;
- (ii) 若 $v_i \in V_i$ 且 $\sum_i v_i = 0$, 则每个 $v_i = 0$;

(iii) 对每个 i , $V_i \cap \sum_{j \neq i} V_j = \{0\}$;

(iv) 任取各 V_i 的基, 把这些基拼接后得到一个线性无关组。

例如, 由两个分解相减可知, 分解唯一等价于齐次分解只有零解, 即 (i) $\Leftrightarrow$ (ii); 把等式移项立即给出 (ii) $\Leftrightarrow$ (iii); 把每个 v_i 在对应基下展开则给出 (ii) $\Leftrightarrow$ (iv)。

正交只是一条充分条件, 不是必要条件。例如在 $\mathbb{R}^2$ 中,

$$\mathbb{R}^2 = \text{span}\{(1, 0)^\top\} \oplus \text{span}\{(1, 1)^\top\},$$

两条直线交集只有零向量, 故是直和, 但它们并不正交。 □

2.3.4 维数公式

来源: 第 6 讲原讲义第 3 页 (Theorem 3.2 未完成证明的补全)

定理 2.20 (子空间维数的容斥公式). 对有限维空间的子空间 U, W ,

$$\dim(U + W) = \dim U + \dim W - \dim(U \cap W).$$

特别地, 若 $U \cap W = \{0\}$, 则 $\dim(U \oplus W) = \dim U + \dim W$ 。

证明. 取 $U \cap W$ 的一组基

$$e_1, \dots, e_k.$$

把它扩张为 U 的一组基

$$e_1, \dots, e_k, u_1, \dots, u_p,$$

并扩张为 W 的一组基

$$e_1, \dots, e_k, w_1, \dots, w_q.$$

考虑拼接向量组

$$\mathcal{S} = (e_1, \dots, e_k, u_1, \dots, u_p, w_1, \dots, w_q).$$

它显然张成 $U + W$ 。下面证明它线性无关。若

$$\sum_i \alpha_i e_i + \sum_j \beta_j u_j + \sum_\ell \gamma_\ell w_\ell = 0,$$

则

$$\sum_j \beta_j u_j = -\sum_i \alpha_i e_i - \sum_\ell \gamma_\ell w_\ell \in W.$$

左端也属于 U , 故它属于 $U \cap W = \text{span}\{e_i\}$ 。但 e_i, u_j 是 U 的一组基, 所以只能有全部 $\beta_j = 0$ 。余下等式 $\sum_i \alpha_i e_i + \sum_\ell \gamma_\ell w_\ell = 0$, 再由 e_i, w_ℓ 是 W 的一组基, 得到全部 $\alpha_i, \gamma_\ell = 0$ 。故 $\mathcal{S}$ 是 $U + W$ 的基。

于是

$$\dim(U + W) = k + p + q = (k + p) + (k + q) - k = \dim U + \dim W - \dim(U \cap W).$$

□

易错点原页证明为何需要补完

原讲义第 3 页的证明在页末停在“由于”处, 而且用正交基计算内积时还需要继续证明剩余系数为零。上面的基扩张证明不依赖内积, 因而对任意有限维线性空间都成立, 也完整覆盖了中断部分。

来源: 第 6 讲原讲义第 3 页 (其余维数结论的证明补全)

推论 2.21. (1) 若 W 是 V 的子空间, 则 $\dim W \leq \dim V$; 若 $W \subsetneq V$, 则 $\dim W < \dim V$ 。

(2) 对外直和,

$$\dim \left(\bigoplus_{i=1}^m V_i \right) = \sum_{i=1}^m \dim V_i.$$

(3) 对有限维内积空间,

$$\dim V = \dim W + \dim W^\perp.$$

证明. 把 W 的基扩张为 V 的基, 立即得到第一点; 若 $W \neq V$, 扩张时至少需要增加一个向量, 故严格小于。

若 $\mathcal{B}_i$ 是 V_i 的基, 则向量 $(0, \dots, 0, b, 0, \dots, 0)$ (其中 $b \in \mathcal{B}_i$ 位于第 i 个分量) 组成外直和的一组基, 向量总数是 $\sum_i \dim V_i$ 。第三点由正交直和 $V = W \oplus W^\perp$ 和第二点 (或直和维数公式) 得到。□

2.3.5 商空间及其与正交补的关系

来源: 第 6 讲原讲义第 4 页 (“空间的除法” 定义补全)

定义 2.22. 设 $W \subseteq V$ 。定义

$$x \sim y \iff x - y \in W.$$

x 的等价类是陪集 $x + W = \{x + w : w \in W\}$, 所有陪集组成商空间

$$V/W = \{x + W : x \in V\}.$$

运算定义为

$$(x + W) + (y + W) = (x + y) + W, \quad \alpha(x + W) = (\alpha x) + W.$$

来源: 第 6 讲原讲义第 4 页 (商空间运算良定义的省略证明)

命题 2.23. 上述关系是等价关系, 而且商空间的加法与数乘不依赖代表元的选择。

证明. 因为 $x - x = 0 \in W$, 关系自反; 若 $x - y \in W$, 则 $y - x = -(x - y) \in W$, 关系对称; 若 $x - y, y - z \in W$, 则 $x - z = (x - y) + (y - z) \in W$, 关系传递。

若 $x' = x + w_1, y' = y + w_2$, 其中 $w_1, w_2 \in W$, 则

$$(x' + y') - (x + y) = w_1 + w_2 \in W,$$

所以 $x' + y' + W = x + y + W$ 。同理 $\alpha x' - \alpha x = \alpha w_1 \in W$, 数乘也与代表元无关。□

来源: 第 6 讲原讲义第 4 页 (商空间同构与维数公式的证明补全)

定理 2.24 (商空间维数与正交代表). 若 V 有限维, 则

$$\dim(V/W) = \dim V - \dim W.$$

若 V 还带有内积, 则映射

$$\Psi: V/W \longrightarrow W^\perp, \quad \Psi(x+W) = P_{W^\perp}x$$

是线性同构。

证明. 取 W 的基 $w_1, \dots, w_k$, 并扩张为 V 的基 $w_1, \dots, w_k, u_1, \dots, u_r$. 则

$$u_1 + W, \dots, u_r + W$$

是 V/W 的一组基: 任意 x 展开后, 所有 w_i 项在商空间中都变成零陪集, 故这些陪集张成; 若 $\sum_j c_j u_j + W = W$, 则 $\sum_j c_j u_j \in W$, 由全空间基的线性无关性知所有 $c_j = 0$. 所以 $\dim(V/W) = r = \dim V - \dim W$.

在内积情形, 若 $x+W = y+W$, 则 $x-y \in W$, 从而 $P_{W^\perp}(x-y) = 0$, 所以 Ψ 良定义。它显然线性。若 $\Psi(x+W) = 0$, 则 $x = P_W x \in W$, 故 $x+W = W$, 所以它单射。任取 $u \in W^\perp$, 有 $\Psi(u+W) = u$, 所以它满射。□

易错点原讲义第 4 页第 4 条的记号修正

正确公式是

$$\dim \left(\bigoplus_{i=1}^n L_i \right) = \sum_{i=1}^n \dim L_i,$$

而不是在等号右侧对数字写直和, 也不应把所有下标都写成 L_1 。此外, $V/W \cong W^\perp$ 依赖所选内积; 不选内积时, 商空间维数公式仍成立, 但没有天然的“垂直代表”。

优化连接: 约束优化的零空间法与投影法

考虑等式约束 $Ax = b$, 并设可行点 x_p 已知。两个可行点之差满足 $A(x - x_p) = 0$, 所以全部可行点恰为

$$x = x_p + Nz,$$

其中 N 的列构成 $\text{Ker } A$ 的一组基。这就是零空间参数化: 把有约束问题

$$\min_{Ax=b} f(x)$$

化成无约束问题 $\min_z f(x_p + Nz)$ 。若 N 标准正交, 则降维后的梯度和 Hessian 为

$$\nabla_z f = N^\top \nabla f, \quad \nabla_z^2 f = N^\top (\nabla^2 f) N.$$

再看欧氏投影

$$\min_{Ax=b} \frac{1}{2} \|x - c\|^2.$$

若 A 满行秩，拉格朗日条件给出 $x - c + A^T \lambda = 0$ 与 $Ax = b$ ，从而

$$x^* = c + A^T(AA^T)^{-1}(b - Ac).$$

这里 $\text{Ker } A = (\text{Range } A^T)^\perp$ ：因为 $z \in \text{Ker } A$ 当且仅当 $\langle A^T y, z \rangle = \langle y, Az \rangle = 0$ 对所有 y 成立。因此可行方向位于 $\text{Ker } A$ ，而投影修正量位于其正交补 $\text{Range } A^T$ ；这正是 KKT 乘子所表达的几何结构。

2.4 坐标变换、相似矩阵与优化器中的重参数化

2.4.1 同一向量在两组基下的坐标

来源：第 6 讲原讲义第 4 页（问题“同一个点的空间坐标如何变化？”）

思考题 2.25 (换基公式). 设

$$V = [v_1, \dots, v_n], \quad U = [u_1, \dots, u_n]$$

是 $\mathbb{R}^n$ 的两组基。同一向量 x 在两组基下的坐标分别为 $y = [x]_V$ 与 $z = [x]_U$ 。求 y 与 z 的关系，并说明基为标准正交基时的特殊形式。

来源：第 6 讲原讲义第 4 页（详细解答）

详细解答. 按坐标定义，

$$x = Vy = Uz.$$

两组基矩阵都可逆，因此

$$z = U^{-1}Vy, \quad y = V^{-1}Uz.$$

记

$$C_{U \leftarrow V} = U^{-1}V,$$

则下标清楚地表示它把 V 坐标变成 U 坐标： $z = C_{U \leftarrow V}y$ ，且 $C_{V \leftarrow U} = C_{U \leftarrow V}^{-1}$ 。

若 U, V 都是标准正交基矩阵，则 $U^{-1} = U^T$ 、 $V^{-1} = V^T$ ，故

$$C_{U \leftarrow V} = U^T V.$$

此矩阵本身也是正交矩阵，因为

$$C_{U \leftarrow V}^T C_{U \leftarrow V} = V^T U U^T V = I.$$

所以标准正交基保持向量的二范数和夹角。 □

来源：第 6 讲原讲义第 4 页（坐标变换计算补充）

思考题 2.26 (二维换基计算). 在 $\mathbb{R}^2$ 中令 $V = I$,

$$U = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad x = \begin{pmatrix} 3 \\ 1 \end{pmatrix}.$$

求 $[x]_V$ 与 $[x]_U$.

来源: 第 6 讲原讲义第 4 页 (详细解答)

详细解答. 显然 $[x]_V = x = (3, 1)^\top$. 又

$$U^{-1} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix},$$

所以

$$[x]_U = U^{-1}x = \frac{1}{2} \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

核对: $2(1, 1)^\top + 1(1, -1)^\top = (3, 1)^\top$. □

2.4.2 同一线性变换在两组基下的矩阵

来源: 第 6 讲原讲义第 4 页 (问题 “运动对应的矩阵如何变化?”)

思考题 2.27 (线性运动的矩阵怎样随坐标改变?). 设 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 是线性变换, 其标准坐标矩阵为 M . 若 $P = [v_1, \dots, v_n]$ 是一组基, 求 T 在基 P 下的矩阵 B . 再设 $A = [T]_V$, $B = [T]_U$, 求两者的关系.

来源: 第 6 讲原讲义第 4 页 (详细解答与方向核对)

详细解答. 若 $y = [x]_P$, 则 $x = Py$. 设 $B = [T]_P$, 那么 $T(x)$ 的 P 坐标为 By , 即

$$MPy = T(Py) = PBy \quad \text{对所有 } y.$$

所以

$$MP = PB, \quad B = P^{-1}MP, \quad M = PBP^{-1}.$$

这补全了原讲义中的 $APy = PBy$ 推导, 也说明公式方向取决于 P 是 “坐标到向量” 还是 “旧坐标到新坐标” 的映射。

一般地, 令 $C = C_{U \leftarrow V} = U^{-1}V$, 于是新坐标 $z = Cy$. 若旧坐标下 $y' = Ay$, 则

$$z' = Cy' = CAy = CAC^{-1}z.$$

故

$$[T]_U = C[T]_V C^{-1}, \quad \text{即} \quad B = CAC^{-1}.$$

□

来源: 第 6 讲原讲义第 4 页 (矩阵相似结论的证明补全)

定理 2.28 (相似矩阵表示同一个线性变换). 若存在可逆矩阵 C 使 $B = CAC^{-1}$, 则 A, B 相似. 相似矩阵具有相同的特征多项式、特征值、行列式、迹、秩以及各次幂的秩。

证明. 相似关系正是同一线性变换在两组基下矩阵的换基关系。代数上,

$$\begin{aligned}\det(\lambda I - B) &= \det(\lambda I - CAC^{-1}) \\ &= \det(C(\lambda I - A)C^{-1}) = \det(\lambda I - A),\end{aligned}$$

故特征多项式与特征值相同。取 $\lambda = 0$ 得行列式相同。利用 $\text{tr}(XY) = \text{tr}(YX)$,

$$\text{tr}(B) = \text{tr}(CAC^{-1}) = \text{tr}(AC^{-1}C) = \text{tr}(A).$$

左右乘可逆矩阵不改变秩, 所以 $\text{rank } B = \text{rank } A$ 。又由归纳法 $B^k = CA^kC^{-1}$, 故 $\text{rank}(B^k) = \text{rank}(A^k)$ 。□

易错点相似与合同不能混为一谈

线性算子的矩阵随换基按相似变换 $A \mapsto CAC^{-1}$ 改变; 二次型或 Hessian 随变量替换 $x = Sy$ 按合同变换 $H \mapsto S^T H S$ 改变。前者保持特征值, 后者保持正、负、零惯性指数, 但一般不保持特征值。两种公式看起来相近, 却描述不同对象。

2.4.3 优化中的坐标选择、预条件与不变性

来源: 第 6 讲原讲义第 4 页 (坐标变换与优化器的应用补充)

命题 2.29 (目标函数在线性重参数化下的梯度与 Hessian). 令 $x = Sy$, 其中 S 可逆, 并定义 $\tilde{f}(y) = f(Sy)$ 。则

$$\nabla_y \tilde{f}(y) = S^T \nabla_x f(x), \quad \nabla_y^2 \tilde{f}(y) = S^T \nabla_x^2 f(x) S.$$

证明. 对任意方向 h , 链式法则给出

$$D\tilde{f}(y)[h] = Df(x)[Sh] = \langle \nabla_x f(x), Sh \rangle = \langle S^T \nabla_x f(x), h \rangle,$$

所以梯度公式成立。再对 $S^T \nabla_x f(Sy)$ 关于 y 求导, S 为常矩阵, 得到 Hessian 公式。□

优化连接: 为什么预条件就是选择坐标

对严格凸二次函数

$$f(x) = \frac{1}{2} x^T H x - b^T x, \quad H \succ 0,$$

作变量替换 $x = Sy$ 后, 新的 Hessian 是 $H_y = S^T H S$ 。若理想地取 $S = H^{-1/2}$, 则 $H_y = I$, 所有方向的曲率完全一致, 梯度下降一步 (合适步长下) 即可到达极小点。实际预条件器正是在可承受计算成本下近似这个“白化”坐标系。

若在 y 坐标做普通梯度下降 $y^+ = y - \eta \nabla_y \tilde{f}$, 换回 x 得

$$x^+ = x - \eta S S^T \nabla_x f(x).$$

所以坐标变换等价于在原坐标使用正定预条件矩阵 SS^T 。对角方法（如 AdaGrad/Adam 的核心缩放思想）只近似坐标轴方向的曲率，因而会依赖所选参数坐标；完整矩阵预条件能够表达旋转后的耦合方向，但代价更高。

来源：第 6 讲原讲义第 4 页（换基公式在牛顿法中的应用补充）


命题 2.30 (牛顿步对可逆线性重参数化保持协变). 若 $H = \nabla_x^2 f(x)$ 可逆, $g = \nabla_x f(x)$, 则 x 坐标中的牛顿步 $\Delta x = -H^{-1}g$ 与 y 坐标中的牛顿步表示同一个几何位移。

证明. 在 $x = Sy$ 下, $g_y = S^T g$, $H_y = S^T H S$, 因此

$$\Delta y = -H_y^{-1} g_y = -(S^T H S)^{-1} S^T g = -S^{-1} H^{-1} g.$$

乘以 S 得 $S\Delta y = -H^{-1}g = \Delta x$ 。所以牛顿步在任意可逆线性坐标变换下描述同一个原空间位移。相比之下，普通梯度下降依赖欧氏内积；非正交变换基后， $S\Delta y = -SS^T g$ 一般不等于 $-g$ 。□

优化连接：本讲知识在优化器中的一条主线



因此，本讲不是孤立的抽象概念：QR 最小二乘、投影梯度、零空间法、预条件共轭梯度、牛顿法以及自适应优化器，都在使用“选一个更合适的子空间或坐标系”这一共同思想。

第3章

第7讲：特征值、特征向量与根子空间分解

本讲的主线是：把一个线性算子换到合适的坐标系中，使其作用尽可能透明。相似变换描述“同一个线性算子在不同基下的矩阵”，特征向量给出一维不变方向，根子空间则在矩阵不可对角化时补足缺失的方向。对优化而言，这条主线直接对应于预条件、二次目标的逐谱模态分析、迭代矩阵的稳定性以及 Krylov 方法。

除特别说明外，本章在复数域 $\mathbb{C}$ 上讨论特征值与根子空间；实矩阵可先复化。若全部特征值均为实数，则相同结论可直接在 $\mathbb{R}$ 上使用。

3.1 换基、相似与商空间

设 V 是 n 维线性空间，两组有序基写成列矩阵

$$\mathcal{V} = (v_1, \dots, v_n), \quad \mathcal{U} = (u_1, \dots, u_n).$$

存在唯一可逆矩阵 P 使得 $\mathcal{U} = \mathcal{V}P$ 。若同一向量在两组基下的坐标分别为 x, y ，则

$$\mathcal{V}x = \mathcal{U}y = \mathcal{V}Py, \quad x = Py, \quad y = P^{-1}x.$$

来源：第7讲原讲义第1页

命题 3.1 (换基公式与相似矩阵). 若线性算子 T 在基 $\mathcal{V}, \mathcal{U}$ 下的矩阵分别为 A, B ，且 $\mathcal{U} = \mathcal{V}P$ ，则

$$B = P^{-1}AP.$$

反之，若 $B = P^{-1}AP$ ，则 A, B 表示同一个线性算子在两组基下的矩阵。

证明补全. 取任意 $y \in \mathbb{F}^n$ 。向量 $\mathcal{U}y$ 在 $\mathcal{V}$ 下的坐标是 Py ，故先施加 T 再用 $\mathcal{V}$ 表示得到 APy ；另一方面，在 $\mathcal{U}$ 下施加 T 得坐标 By ，换到 $\mathcal{V}$ 下是 PBy 。于是对所有 y 都有

$$APy = PBy.$$

由 P 可逆，左乘 P^{-1} 得 $B = P^{-1}AP$ 。反向只需把等式倒读即可。 $\square$

来源：第7讲原讲义第1页

命题 3.2 (相似变换保持的对象). 若 $B = P^{-1}AP$, 则对任意多项式 f 及任意 $k \geq 1$,

$$f(B) = P^{-1}f(A)P, \quad (B - \lambda I)^k = P^{-1}(A - \lambda I)^k P.$$

因此 A, B 有相同的秩、行列式、迹、特征多项式、特征值及其代数重数, 并且

$$V_\lambda(A) = PV_\lambda(B), \quad W_\lambda^k(A) = PW_\lambda^k(B).$$

证明补全. 由归纳法, $B^j = P^{-1}A^jP$; 把多项式按幂展开即得 $f(B) = P^{-1}f(A)P$. 左右乘可逆矩阵不改变秩, 且

$$\det B = \det(P^{-1}) \det A \det P = \det A, \quad \operatorname{tr}(B) = \operatorname{tr}(P^{-1}AP) = \operatorname{tr}(APP^{-1}) = \operatorname{tr}(A).$$

进一步,

$$\det(tI - B) = \det(P^{-1}(tI - A)P) = \det(tI - A),$$

故特征多项式完全相同. 若 $x = Py$, 则

$$(B - \lambda I)^k y = 0 \iff P^{-1}(A - \lambda I)^k x = 0 \iff (A - \lambda I)^k x = 0,$$

这同时给出特征空间和各层根子空间的一一对应. 这里正确的坐标对应是 $x = Py$ (等价地 $y = P^{-1}x$). $\square$

3.1.1 商空间的构造与维数

给定子空间 $L \subseteq V$, 定义

$$u \sim_L v \iff u - v \in L.$$

u 的等价类记为 $[u] = u + L$, 所有等价类组成商空间 V/L .

来源: 第 7 讲原讲义第 1 页

命题 3.3 (商空间中省略的验证). 在 V/L 上定义

$$[u] + [v] = [u + v], \quad a[u] = [au].$$

这些运算与代表元的选取无关. 若 $\dim V = n, \dim L = r$, 则

$$\dim(V/L) = n - r.$$

若 $V = L \oplus L'$, 则映射 $\Phi: L' \rightarrow V/L, w \mapsto [w]$ 是线性同构; 在内积空间中可取 $L' = L^\perp$.

证明补全. 若 $u - u' \in L, v - v' \in L$, 则

$$(u + v) - (u' + v') = (u - u') + (v - v') \in L,$$

且 $au - au' = a(u - u') \in L$, 所以加法和数乘定义良好。

取 L 的一组基 $\ell_1, \dots, \ell_r$, 扩充成 V 的基 $\ell_1, \dots, \ell_r, w_{r+1}, \dots, w_n$ 。任意 $v \in V$ 可写成

$$v = \sum_{i=1}^r a_i \ell_i + \sum_{j=r+1}^n b_j w_j,$$

故 $[v] = \sum_{j=r+1}^n b_j [w_j]$ 。若 $\sum b_j [w_j] = [0]$, 则 $\sum b_j w_j \in L$; 由扩充后整组向量线性无关, 所有 $b_j = 0$ 。所以 $[w_{r+1}], \dots, [w_n]$ 是 V/L 的基, 维数为 $n - r$ 。

最后, 若 $V = L \oplus L'$, 每个等价类恰有一个属于 L' 的代表元, 故 Φ 同时为单射与满射。在有限维内积空间中 $V = L \oplus L^\perp$, 于是 $V/L \cong L^\perp$ 。□

优化连接: 等式约束与零空间法

考虑 $Cx = d$, 取一个可行点 x_0 。全部可行点为仿射空间

$$x_0 + \text{Ker } C.$$

若 Z 的列构成 $\text{Ker } C$ 的一组基, 则可写 $x = x_0 + Zz$, 从而把约束优化 $\min_{Cx=d} f(x)$ 化成无约束问题 $\min_z f(x_0 + Zz)$ 。商空间观点则把相差一个可行方向的点归为同一类; 而 $V/\text{Ker } C \cong (\text{Ker } C)^\perp = \text{Range}(C^\top)$ 正是拉格朗日乘子所作用的法向空间。

易错点: 相似与合同不要混淆

线性算子的换基是 $P^{-1}AP$, 称为相似变换; 二次型 $q(x) = \frac{1}{2}x^\top Hx$ 在代换 $x = Py$ 后的矩阵却是 $P^\top H P$, 称为合同变换。相似保持特征值, 合同一般不保持特征值, 但保持正、负惯性指数。预条件分析中两种变换都会出现, 不能把公式混用。

3.2 特征值、特征空间与根子空间

对 $A \in \mathbb{C}^{n \times n}$, 若存在 $u \neq 0$ 使 $Au = \lambda u$, 则称 λ 为特征值, u 为相应特征向量。定义

$$p_A(t) = \det(tI - A), \quad V_\lambda(A) = \text{Ker}(A - \lambda I), \quad W_\lambda^k(A) = \text{Ker}(A - \lambda I)^k.$$

由于 $(\lambda I - A)^k$ 与 $(A - \lambda I)^k$ 只差符号, 两个根子空间定义相同。

矩阵的谱与谱半径分别记为

$$\sigma(A) = \{\lambda \in \mathbb{C} : p_A(\lambda) = 0\}, \quad \rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|.$$

通常 $\sigma(A)$ 指集合, 而原讲义把代数重数也记录在内, 因而把 $\text{diag}(2, 2, 2, 3, 3)$ 的谱写成多重集 $\{2, 2, 2, 3, 3\}$; 两种约定使用时应说明。

来源: 第 7 讲原讲义第 1-2 页

命题 3.4 (特征值判据与重数). 下列条件等价:

$$\lambda \text{ 是 } A \text{ 的特征值} \iff \text{Ker}(\lambda I - A) \neq \{0\} \iff \det(\lambda I - A) = 0 \iff p_A(\lambda) = 0.$$

若 $p_A(t) = \prod_{i=1}^s (t - \lambda_i)^{d_i}$, 则 d_i 称为 λ_i 的代数重数, $g_i = \dim V_{\lambda_i}(A) = n - \text{rank}(\lambda_i I - A)$ 称为几何重数。

证明补全. $Au = \lambda u$ 等价于 $(\lambda I - A)u = 0$. 齐次方程存在非零解, 当且仅当其系数矩阵不可逆; 对方阵, 这又等价于行列式为零. 最后一个等价关系就是 p_A 的定义. 秩-零度公式给出 $\dim \operatorname{Ker}(\lambda_i I - A) = n - \operatorname{rank}(\lambda_i I - A)$. $\square$

来源: 第 7 讲原讲义第 2 页

命题 3.5 (特征空间确为线性空间). 对任意标量 λ ,

$$V_\lambda(A) = \{u : Au = \lambda u\} = \operatorname{Ker}(A - \lambda I)$$

是线性子空间; 当且仅当 λ 是特征值时, 它含有非零向量.

补全并纠正记号. 核空间总含零向量. 若 $u, v \in V_\lambda(A)$, $a, b \in \mathbb{F}$, 则

$$(A - \lambda I)(au + bv) = a(A - \lambda I)u + b(A - \lambda I)v = 0,$$

所以 $au + bv \in V_\lambda(A)$. 原讲义排版末项看起来像 $(\lambda I - A)^\perp$; 此处需要的是核空间 $\operatorname{Ker}(\lambda I - A)$, 一般不能改成正交补. $\square$

来源: 第 7 讲原讲义第 2 页

命题 3.6 (根子空间链必然稳定). 对固定 λ , 有递增链

$$\{0\} = W_\lambda^0 \subseteq W_\lambda^1 \subseteq W_\lambda^2 \subseteq \cdots$$

并且

$$W_\lambda^{k+1} = \{u : (A - \lambda I)u \in W_\lambda^k\}.$$

存在 $r \leq n$ 使 $W_\lambda^r = W_\lambda^{r+1} = W_\lambda^{r+2} = \cdots$; 稳定后的空间记为 $W_\lambda(A)$. 而且一旦某一层相等, 后面永远相等.

证明补全. 记 $N = A - \lambda I$. 由 $N^{k+1}u = 0 \iff Nu \in \operatorname{Ker} N^k$, 先得到所列的迭代描述. 若 $N^k u = 0$, 则 $N^{k+1}u = 0$, 所以链递增. 每次严格包含都会使维数至少增加 1, 而维数不超过 n , 故至多严格增加 n 次, 必在第 n 层以前稳定.

若 $\operatorname{Ker} N^k = \operatorname{Ker} N^{k+1}$, 取 $u \in \operatorname{Ker} N^{k+2}$, 则 $Nu \in \operatorname{Ker} N^{k+1} = \operatorname{Ker} N^k$, 从而 $N^{k+1}u = 0$, 即 $u \in \operatorname{Ker} N^{k+1}$. 反向包含本来就成立, 所以 $\operatorname{Ker} N^{k+2} = \operatorname{Ker} N^{k+1}$; 归纳即得后续各层全相等. $\square$

来源: 第 7 讲原讲义第 2 页

命题 3.7 (迹、Frobenius 范数与谱范数). 若乘积有定义, 则

$$\operatorname{tr}(AB) = \operatorname{tr}(BA), \quad \operatorname{tr}(ABC) = \operatorname{tr}(BCA).$$

并且

$$\|A\|_F^2 = \operatorname{tr}(A^H A) = \sum_{i,j} |a_{ij}|^2, \quad \|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

任意特征值满足 $|\lambda| \leq \|A\|_2$; 若 A 是正规矩阵 (特别地, 实对称或复 Hermitian), 则 $\|A\|_2 = \max_i |\lambda_i|$.

证明补全. 按元素求和,

$$\operatorname{tr}(AB) = \sum_i \sum_j a_{ij} b_{ji} = \sum_j \sum_i b_{ji} a_{ij} = \operatorname{tr}(BA),$$

三因子的循环性质由此对 $(AB)C$ 使用一次即可. 又

$$\operatorname{tr}(A^H A) = \sum_i (A^H A)_{ii} = \sum_{i,j} \overline{a_{ji}} a_{ji} = \sum_{i,j} |a_{ij}|^2.$$

若 $Au = \lambda u$ 且 $u \neq 0$, 则 $|\lambda| \|u\|_2 = \|Au\|_2 \leq \|A\|_2 \|u\|_2$. 正规矩阵可酉对角化为 $A = Q \operatorname{diag}(\lambda_i) Q^H$; 酉矩阵保持二范数, 因此最大伸缩率就是 $\max_i |\lambda_i|$. $\square$

来源: 第 7 讲原讲义第 2 页

命题 3.8 (迹、行列式与全部特征值). 把特征值按代数重数列列为 $\lambda_1, \dots, \lambda_n$, 则

$$\operatorname{tr}(A) = \sum_{i=1}^n \lambda_i, \quad \det(A) = \prod_{i=1}^n \lambda_i.$$

证明补全. 一方面,

$$p_A(t) = \prod_{i=1}^n (t - \lambda_i) = t^n - \left(\sum_i \lambda_i \right) t^{n-1} + \dots + (-1)^n \prod_i \lambda_i.$$

另一方面, 按行列式的排列展开, t^{n-1} 项只能选一个对角元 $-a_{ii}$ 并从其他行列选 t , 故其系数为 $-\sum_i a_{ii} = -\operatorname{tr} A$; 常数项为 $\det(-A) = (-1)^n \det A$. 比较对应系数即得结论. $\square$

优化连接: 二次目标的梯度下降逐谱分析

设

$$f(x) = \frac{1}{2} x^T H x - b^T x, \quad 0 < \mu I \preceq H \preceq LI, \quad x_* = H^{-1} b.$$

梯度下降 $x_{k+1} = x_k - \eta(Hx_k - b)$ 的误差满足

$$e_{k+1} = (I - \eta H) e_k.$$

写 $H = Q \operatorname{diag}(\lambda_i) Q^T$, 令 $z_k = Q^T e_k$, 便得到完全解耦的标量递推

$$(z_{k+1})_i = (1 - \eta \lambda_i) (z_k)_i.$$

所以收敛当且仅当 $0 < \eta < 2/L$, 且

$$\|e_k\|_2 \leq \rho(I - \eta H)^k \|e_0\|_2, \quad \rho(I - \eta H) = \max_i |1 - \eta \lambda_i|.$$

常步长的最坏情形最优选择为 $\eta_* = 2/(L + \mu)$, 相应收缩因子为 $(L - \mu)/(L + \mu) = (\kappa - 1)/(\kappa + 1)$, 其中 $\kappa = L/\mu$.

3.3 课堂练习与思考题详解

来源: 第 7 讲原讲义第 2-3 页

思考题 3.9 (课堂练习一: 三个 2×2 矩阵). 求下列矩阵的特征值、特征向量、特征空间与根子空间:

$$A = \begin{pmatrix} 0 & 2 \\ 1 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}.$$

详细解答. 对 A ,

$$p_A(t) = \det \begin{pmatrix} t & -2 \\ -1 & t-1 \end{pmatrix} = t(t-1) - 2 = (t-2)(t+1).$$

于是特征值是 $2, -1$, 且

$$V_2(A) = \text{Ker} \begin{pmatrix} -2 & 2 \\ 1 & -1 \end{pmatrix} = \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}, \quad V_{-1}(A) = \text{Ker} \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix} = \text{span} \left\{ \begin{pmatrix} 2 \\ -1 \end{pmatrix} \right\}.$$

两个特征值互异, 两个特征向量线性无关, 故 A 可对角化; 相应根子空间已经在第一层稳定: $W_2(A) = V_2(A)$, $W_{-1}(A) = V_{-1}(A)$ 。

对 B ,

$$p_B(t) = (t-1)^2, \quad I - B = \begin{pmatrix} 0 & 0 \\ -1 & 0 \end{pmatrix},$$

故唯一特征值为 1 , 代数重数为 2 , 而

$$V_1(B) = \text{span} \left\{ \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right\}, \quad \dim V_1(B) = 1.$$

又因 $(B - I)^2 = 0$,

$$W_1^2(B) = \text{Ker}(B - I)^2 = \mathbb{C}^2, \quad W_1(B) = \mathbb{C}^2.$$

因此 B 不可对角化; 向量 $e_1 = (1, 0)^T$ 是二阶广义特征向量, 因为 $(B - I)e_1 = e_2$, $(B - I)e_2 = 0$ 。

对 C ,

$$p_C(t) = (t-1)^2 + 1 = (t-1-i)(t-1+i).$$

在 $\mathbb{R}$ 上没有特征值; 在 $\mathbb{C}$ 上有两个特征值 $1+i, 1-i$, 并且

$$V_{1+i}(C) = \text{span} \left\{ \begin{pmatrix} i \\ 1 \end{pmatrix} \right\}, \quad V_{1-i}(C) = \text{span} \left\{ \begin{pmatrix} 1 \\ i \end{pmatrix} \right\}.$$

二者不同, 所以各自的根子空间就是特征空间, 且 C 在 $\mathbb{C}$ 上可对角化。原讲义第二个复特征值的方程中出现的 $((1-i)I - A)x = 0$ 应为 $((1-i)I - C)x = 0$ 。□

来源: 第 7 讲原讲义第 3 页

思考题 3.10 (观察题: 矩阵满足什么多项式?). 直接计算可见

$$A^2 - A - 2I = 0, \quad B^2 - 2B + I = 0, \quad C^2 - 2C + 2I = 0.$$

观察三个等式与相应特征多项式的关系，并给出猜想。

详细解答. 三个左端恰好分别是 $p_A(A), p_B(B), p_C(C)$ 。由此应猜想：对任意方阵 M ，其特征多项式都能消去自身，

$$p_M(M) = 0.$$

这就是 Cayley-Hamilton 定理。更精细地，能消去 M 的首一多项式中次数最低者称为最小多项式 m_M ；总有 $m_M \mid p_M$ 。本题三个矩阵的最小多项式都等于其特征多项式： A, C 有两个不同特征值， $B \neq I$ 且 $(B - I)^2 = 0$ 。□

来源：第 7 讲原讲义第 3-4 页

思考题 3.11 (课堂练习二：四阶矩阵与遗漏的根子空间). 求矩阵

$$M = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 11 & 6 & -4 & -4 \\ 22 & 15 & -8 & -9 \\ -3 & -2 & 1 & 2 \end{pmatrix}$$

的特征值、特征向量、特征空间和全部根子空间，并判断其是否可对角化。

详细解答. 先计算特征多项式。沿 $tI - M$ 的第一行展开，记对应两个非零项的余子式为 D_{11}, D_{12} ，则

$$p_M(t) = tD_{11} + D_{12},$$

$$D_{11} = \det \begin{pmatrix} t-6 & 4 & 4 \\ -15 & t+8 & 9 \\ 2 & -1 & t-2 \end{pmatrix} = t^3 + 9t - 10,$$

$$D_{12} = \det \begin{pmatrix} -11 & 4 & 4 \\ -22 & t+8 & 9 \\ 3 & -1 & t-2 \end{pmatrix} = -11t^2 + 10t + 1.$$

因此

$$p_M(t) = t^4 - 2t^2 + 1 = (t-1)^2(t+1)^2.$$

所以特征值为 $1, -1$ ，代数重数都为 2。

对 $\lambda = 1$ ，行化简给出

$$I - M \sim_{\text{row}} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix},$$

故

$$V_1(M) = \text{span} \left\{ v_+ = \begin{pmatrix} 0 \\ 0 \\ 1 \\ -1 \end{pmatrix} \right\}, \quad \dim V_1(M) = 1.$$

再计算

$$(M - I)^2 = \begin{pmatrix} 12 & 4 & -4 & -4 \\ -32 & -16 & 12 & 12 \\ -28 & -20 & 12 & 12 \\ 0 & 0 & 0 & 0 \end{pmatrix} \sim_{\text{row}} \begin{pmatrix} 1 & 0 & -\frac{1}{4} & -\frac{1}{4} \\ 0 & 1 & -\frac{1}{4} & -\frac{1}{4} \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}.$$

于是

$$\begin{aligned} W_1^2(M) &= \text{span} \left\{ \begin{pmatrix} 1 \\ 1 \\ 2 \\ 2 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \\ -1 \end{pmatrix} \right\} \\ &= \text{span} \left\{ v_+, g_+ = \begin{pmatrix} 1 \\ 1 \\ 4 \\ 0 \end{pmatrix} \right\}, \end{aligned}$$

其中 $(M - I)g_+ = v_+$ 、 $(M - I)v_+ = 0$ 。直接再乘一次可得 $\text{Ker}(M - I)^3 = \text{Ker}(M - I)^2$ ，故 $W_1(M) = W_1^2(M)$ ，维数为 2。

对 $\lambda = -1$ ，原讲义省略了根子空间的具体过程。行化简为

$$M + I \sim_{\text{row}} \begin{pmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix},$$

故

$$V_{-1}(M) = \text{span} \left\{ v_- = \begin{pmatrix} 1 \\ -1 \\ 1 \\ 0 \end{pmatrix} \right\}, \quad \dim V_{-1}(M) = 1.$$

而

$$(M + I)^2 = \begin{pmatrix} 12 & 8 & -4 & -4 \\ 12 & 8 & -4 & -4 \\ 60 & 40 & -20 & -24 \\ -12 & -8 & 4 & 8 \end{pmatrix} \sim_{\text{row}} \begin{pmatrix} 1 & \frac{2}{3} & -\frac{1}{3} & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}.$$

于是

$$W_{-1}^2(M) = \text{span} \left\{ v_-, g_- = \begin{pmatrix} -2 \\ 3 \\ 0 \\ 0 \end{pmatrix} \right\},$$

并且 $(M+I)g_- = v_-$ 、 $(M+I)v_- = 0$ 。同样有 $\text{Ker}(M+I)^3 = \text{Ker}(M+I)^2$, 所以 $W_{-1}(M) = W_{-1}^2(M)$, 维数也为 2。

把两条 Jordan 链排成

$$P = (v_-, g_-, v_+, g_+) = \begin{pmatrix} 1 & -2 & 0 & 1 \\ -1 & 3 & 0 & 1 \\ 1 & 0 & 1 & 4 \\ 0 & 0 & -1 & 0 \end{pmatrix}, \quad \det P = -1 \neq 0.$$

由链关系可直接验证

$$P^{-1}MP = \begin{pmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}.$$

因此每个特征值都只有一个特征向量方向而有一个二阶 Jordan 块, M 不可对角化; 其最小多项式为

$$m_M(t) = (t-1)^2(t+1)^2 = p_M(t).$$

□

优化连接: 缺陷矩阵为何会让迭代出现瞬态放大

二阶 Jordan 块 $J_\lambda = \lambda I + N$ ($N^2 = 0$) 满足

$$J_\lambda^k = \lambda^k I + k\lambda^{k-1}N.$$

所以即使 $|\lambda| < 1$, 也会出现额外的多项式因子 k ; 当 $|\lambda| = 1$ 时, 上题矩阵的某些轨道会线性增长。对形如 $e_{k+1} = Ge_k$ 的优化算法, 只有在 G 正规 (例如对称) 时, 特征值模长才几乎完整描述每步行为; 非正规或不可对角化的迭代矩阵还必须检查特征向量条件数、Jordan 结构或奇异值。

3.4 相似不变量与 Cayley–Hamilton 定理

来源: 第 7 讲原讲义第 4-5 页

定理 3.12 (相似矩阵的谱空间对应). 若 $B = P^{-1}AP$, 则 A, B 的特征多项式相同, 且对所有 $\lambda, k \geq 1$,

$$V_\lambda(A) = PV_\lambda(B), \quad W_\lambda^k(A) = PW_\lambda^k(B).$$

原讲义证明的完整化. 特征多项式满足

$$\begin{aligned} p_B(t) &= \det(tI - P^{-1}AP) = \det(P^{-1}(tI - A)P) \\ &= \det(P^{-1}) \det(tI - A) \det(P) = p_A(t). \end{aligned}$$

此外

$$B - \lambda I = P^{-1}(A - \lambda I)P,$$

利用中间的 PP^{-1} 逐次消去可归纳得到

$$(B - \lambda I)^k = P^{-1}(A - \lambda I)^k P.$$

若 $x = Py$, 则

$$(B - \lambda I)^k y = 0 \iff P^{-1}(A - \lambda I)^k x = 0 \iff (A - \lambda I)^k x = 0.$$

取 $k = 1$ 得特征空间对应; 任意 k 得各层根子空间对应. 由于 P 可逆, 这些对应都是线性同构, 故维数也分别相等. $\square$

来源: 第 7 讲原讲义第 5 页

定理 3.13 (Cayley–Hamilton). 每个方阵都满足自己的特征多项式: 若

$$p_A(t) = \det(tI - A) = t^n + c_{n-1}t^{n-1} + \cdots + c_1t + c_0,$$

则

$$p_A(A) = A^n + c_{n-1}A^{n-1} + \cdots + c_1A + c_0I = 0.$$

补全为不依赖 *Jordan* 标准形的证明. 令

$$B(t) = \text{adj}(tI - A) = B_{n-1}t^{n-1} + \cdots + B_1t + B_0.$$

伴随矩阵恒等式给出

$$(tI - A)B(t) = B(t)(tI - A) = p_A(t)I. \quad (1)$$

由左右两式相等, $AB(t) = B(t)A$, 比较 t 的系数可知每个 B_j 都与 A 交换. 再把 (1) 左侧展开并比较系数, 得到

$$B_{n-1} = I, \quad B_{k-1} - AB_k = c_k I \quad (1 \leq k \leq n-1), \quad -AB_0 = c_0 I. \quad (2)$$

利用交换性, 把 (2) 中第 k 个等式右乘 A^k , 再全部相加:

$$\begin{aligned} p_A(A) &= B_{n-1}A^n + \sum_{k=1}^{n-1} (B_{k-1} - AB_k)A^k - AB_0 \\ &= B_{n-1}A^n - AB_{n-1}A^{n-1} + \sum_{k=1}^{n-1} (B_{k-1}A^k - AB_{k-1}A^{k-1}) \\ &= 0. \end{aligned}$$

最后一行是逐项望远镜消去. 这个系数比较证明也解释了为什么不能把 $\det(tI - A)$ 中的标量 t 直接“机械地代成矩阵 A ”: 矩阵条目一般不交换, 必须先把行列式化成标量多项式, 再按多项式求值. $\square$

优化连接：矩阵多项式、Krylov 子空间与有限终止

Cayley-Hamilton 表明 A^n 以后的一切幂都可由 $I, A, \dots, A^{n-1}$ 线性表示。因此线性迭代的轨道总位于 Krylov 子空间

$$\mathcal{K}_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}.$$

对二次优化的共轭梯度法，误差可写成 $e_k = q_k(H)e_0$ 。若 H 的最小多项式相对于 e_0 的次数为 r ，则精确算术下至多 r 步终止；当 H 只有少量不同特征值时， r 可能远小于维数。这是“谱聚集会加速 Krylov 方法”的代数根源。

3.5 几何重数、代数重数与不同谱空间的独立性

来源：第 7 讲原讲义第 5 页

定理 3.14 (几何重数不超过代数重数). 设 λ 是 A 的特征值，其几何重数为 $g_\lambda = \dim V_\lambda(A)$ ，代数重数为 d_λ ，则

$$1 \leq g_\lambda \leq d_\lambda.$$

用适配基补全原讲义中的行列式跳步. 取 $V_\lambda(A)$ 的一组基 $u_1, \dots, u_g$ ，把它扩充成全空间的一组基。因为 $Au_j = \lambda u_j$ ， A 在这组基下的前 g 列为 $\begin{pmatrix} \lambda I_g \\ 0 \end{pmatrix}$ ，所以矩阵具有分块形状

$$[A]_{\mathcal{B}} = \begin{pmatrix} \lambda I_g & C \\ 0 & D \end{pmatrix}.$$

于是

$$p_A(t) = \det \begin{pmatrix} (t - \lambda)I_g & -C \\ 0 & tI - D \end{pmatrix} = (t - \lambda)^g \det(tI - D).$$

故 $(t - \lambda)^g$ 整除 $p_A(t)$ ，即 $g \leq d_\lambda$ 。又因为 λ 是特征值，特征空间至少含一个非零向量，故 $g \geq 1$ 。□

来源：第 7 讲原讲义第 5-6 页

定理 3.15 (不同特征值的特征向量线性无关). 设 $\lambda_1, \dots, \lambda_m$ 两两不同，且 $0 \neq v_i \in V_{\lambda_i}(A)$ ，则 $v_1, \dots, v_m$ 线性无关。

补全原讲义的最小反例论证. 反设存在相关组，从所有相关组中取向量个数最少的一组，仍记为 $v_1, \dots, v_m$ 。于是存在

$$\sum_{i=1}^m c_i v_i = 0,$$

且每个 $c_i \neq 0$ ；否则删去零系数项会得到更小的相关组。对等式施加 $A - \lambda_m I$ ，得到

$$0 = \sum_{i=1}^{m-1} c_i (\lambda_i - \lambda_m) v_i.$$

由于 $\lambda_i \neq \lambda_m$ 且 $c_i \neq 0$ ，这是 $m-1$ 个向量的非平凡线性关系，与所取相关组的最小性矛盾。因此原向量组必线性无关。□

来源: 第 7 讲原讲义第 6 页

定理 3.16 (不同根子空间中的向量线性无关). 设 $\lambda_1, \dots, \lambda_m$ 两两不同, 且 $0 \neq v_i \in W_{\lambda_i}(A)$, 则 $v_1, \dots, v_m$ 线性无关。

补全并整理原讲义的势函数证明. 对每个 v_i , 令 r_i 是满足

$$(A - \lambda_i I)^{r_i} v_i = 0$$

的最小正整数. 对势函数 $R = \sum_i r_i$ 作强归纳. 单个非零向量显然线性无关; 若所有 $r_i = 1$, 结论也正是上一条定理. 归纳假设是: 所有总势严格小于 R 的这类向量组均线性无关。

一般地, 反设 $\sum_i c_i v_i = 0$ 是一个非平凡关系, 删去零系数项后可设每个 $c_i \neq 0$. 固定一个下标 j , 对关系施加 $A - \lambda_j I$:

$$\sum_i c_i (A - \lambda_j I) v_i = 0. \quad (3)$$

对 $i = j$, 若 $r_j > 1$, 向量 $(A - \lambda_j I) v_j$ 的阶恰为 $r_j - 1$; 若 $r_j = 1$, 该项为零. 对 $i \neq j$, 写

$$A - \lambda_j I = (A - \lambda_i I) + (\lambda_i - \lambda_j) I.$$

于是

$$\begin{aligned} (A - \lambda_i I)^{r_i} (A - \lambda_j I) v_i &= 0, \\ (A - \lambda_i I)^{r_i-1} (A - \lambda_j I) v_i &= (\lambda_i - \lambda_j) (A - \lambda_i I)^{r_i-1} v_i \neq 0. \end{aligned}$$

因此 $(A - \lambda_j I) v_i$ 仍是 λ_i 的阶为 r_i 的非零广义特征向量. 关系 (3) 中非零向量的总势严格小于 R , 由归纳假设它们线性无关, 故所有相应系数必须为零. 这与 $c_i \neq 0$ 矛盾. 归纳完成. $\square$

3.6 互素多项式的核分解

来源: 第 7 讲原讲义第 6-7 页

引理 3.17 (Bézout 核分解). 若 $f, g \in \mathbb{F}[t]$ 互素, 则

$$\text{Ker}(f(A)g(A)) = \text{Ker } f(A) \oplus \text{Ker } g(A).$$

逐项补全. 矩阵的多项式彼此交换, 故 $f(A)g(A) = g(A)f(A)$. 若 $u_f \in \text{Ker } f(A)$ 、 $u_g \in \text{Ker } g(A)$, 则

$$f(A)g(A)(u_f + u_g) = g(A)f(A)u_f + f(A)g(A)u_g = 0,$$

所以两核之和包含于左端的核。

由 $\gcd(f, g) = 1$, Bézout 等式保证存在多项式 a, b 使

$$a(t)f(t) + b(t)g(t) = 1. \quad (4)$$

任取 $u \in \text{Ker}(f(A)g(A))$, 令

$$u_g = a(A)f(A)u, \quad u_f = b(A)g(A)u.$$

由交换性,

$$g(A)u_g = a(A)g(A)f(A)u = 0, \quad f(A)u_f = b(A)f(A)g(A)u = 0.$$

而 (4) 给出 $u = u_g + u_f$. 故左端的每个向量都属于两核之和。

最后, 若 $w \in \text{Ker } f(A) \cap \text{Ker } g(A)$, 则再由 (4),

$$w = a(A)f(A)w + b(A)g(A)w = 0.$$

交集只有零向量, 所以这个和是直和。对有限个两两互素多项式反复使用本引理, 即得相应的多项式核的直和分解。□

注记 3.18. 上述证明还给出了显式投影: 在 $\text{Ker}(f(A)g(A))$ 上, $E_f = b(A)g(A)$ 投到 $\text{Ker } f(A)$, $E_g = a(A)f(A)$ 投到 $\text{Ker } g(A)$, 且 $E_f + E_g = I$, $E_f E_g = 0$. 因此根子空间分解不仅是存在性结论, 还能由多项式构造谱投影。

3.7 根子空间分解定理

来源: 第 7 讲原讲义第 7 页

定理 3.19 (主分解定理). 设

$$p_A(t) = \prod_{i=1}^s (t - \lambda_i)^{d_i}, \quad \lambda_i \neq \lambda_j \ (i \neq j).$$

则

$$\mathbb{C}^n = \bigoplus_{i=1}^s W_{\lambda_i}(A) = \bigoplus_{i=1}^s \text{Ker}(A - \lambda_i I)^{d_i},$$

并且

$$\dim W_{\lambda_i}(A) = d_i.$$

换言之, 某个特征值的根子空间维数恰好等于它的代数重数, 而不同根子空间的和既是全空间又是直和。

补上原讲义遗漏的维数论证. 令 $f_i(t) = (t - \lambda_i)^{d_i}$. 这些多项式两两互素. 由 Cayley–Hamilton 定理,

$$\mathbb{C}^n = \text{Ker } p_A(A) = \text{Ker } \prod_{i=1}^s f_i(A).$$

反复使用 Bézout 核分解引理, 得到

$$\mathbb{C}^n = \bigoplus_{i=1}^s \text{Ker } f_i(A) = \bigoplus_{i=1}^s \text{Ker}(A - \lambda_i I)^{d_i}. \quad (5)$$

记右端第 i 个空间为 E_i . 它对 A 不变, 因为 A 与 $(A - \lambda_i I)^{d_i}$ 交换. 在与直和 (5) 适配的基下, A 为分块对角矩阵 $\text{diag}(A_1, \dots, A_s)$, 其中 $A_i = A|_{E_i}$. 在 E_i 上,

$$(A_i - \lambda_i I)^{d_i} = 0,$$

所以 $A_i = \lambda_i I + N_i$, 其中 N_i 幂零。幂零矩阵的全部特征值为 0, 故若 $m_i = \dim E_i$, 则

$$p_{A_i}(t) = (t - \lambda_i)^{m_i}.$$

另一方面, 分块对角矩阵的特征多项式是各块特征多项式之积, 因此

$$\prod_{i=1}^s (t - \lambda_i)^{d_i} = p_A(t) = \prod_{i=1}^s p_{A_i}(t) = \prod_{i=1}^s (t - \lambda_i)^{m_i}.$$

唯一分解性给出 $m_i = d_i$ 。

最后说明后续层不会越出 E_i 。在 E_j ($j \neq i$) 上有

$$A - \lambda_i I = (\lambda_j - \lambda_i)I + N_j, \quad N_j = A_j - \lambda_j I,$$

其中 N_j 幂零而 $\lambda_j - \lambda_i \neq 0$ 。因此该算子可逆, 其逆可显式写为有限几何级数

$$((\lambda_j - \lambda_i)I + N_j)^{-1} = \frac{1}{\lambda_j - \lambda_i} \sum_{r=0}^{d_j-1} \left(-\frac{N_j}{\lambda_j - \lambda_i} \right)^r.$$

若 $(A - \lambda_i I)^k v = 0$, 把 v 按直和 (5) 分解, 则所有 $j \neq i$ 的分量都被一个可逆算子的 k 次幂消去, 只能为零; 故 $v \in E_i$ 。反过来 E_i 本来就在第 d_i 层内, 所以 $E_i = W_{\lambda_i}(A)$ 。这同时证明了原讲义注释中的“根子空间维数等于代数重数”。□

来源: 第 7 讲原讲义第 7 页

推论 3.20 (可对角化判据). 对 $A \in \mathbb{C}^{n \times n}$, 下列条件等价:

1. A 可对角化;
2. 对每个特征值 λ_i , 几何重数等于代数重数;
3. $W_{\lambda_i}(A) = V_{\lambda_i}(A)$ 对所有 i 成立;
4. 最小多项式 $m_A(t)$ 没有重根。

证明. 由主分解定理, 各根子空间维数之和为 n 。若每个根子空间已在第一层稳定, 则所有特征空间的直和就是全空间, 取各空间的基便得到特征向量基, 从而可对角化; 反之, 可对角化矩阵显然有 n 个线性无关特征向量, 所以每个几何重数都达到代数重数。

再把最小多项式写成 $m_A(t) = \prod_i (t - \lambda_i)^{s_i}$ 。在主分解的第 i 块上, s_i 正是使 $(A - \lambda_i I)^{s_i}$ 消去整个 $W_{\lambda_i}(A)$ 的最小指数。因此 $s_i = 1$ 当且仅当 $A - \lambda_i I$ 在该根子空间上恒为零, 也就是 $W_{\lambda_i}(A) = V_{\lambda_i}(A)$ 。故所有 $s_i = 1$ 当且仅当最小多项式没有重根。□

易错点: 实矩阵的复特征值

主分解定理在特征多项式完全分裂的域上成立。实矩阵若有非实特征值, 应在 $\mathbb{C}^n$ 中把共轭特征值分别处理; 若坚持在 $\mathbb{R}^n$ 中工作, 则应按不可约实因子 (一次因子或二次因子) 分解, 成对的共轭特征值对应一个实不变子空间。课堂练习一中的矩阵 C 正是最小的例子。

3.8 在数学优化器中的进一步应用

3.8.1 预条件梯度法：把广义特征值化成普通特征值

设 $H \succ 0$ 是二次目标的 Hessian, $M \succ 0$ 是预条件矩阵。预条件梯度法

$$x_{k+1} = x_k - \eta M^{-1}(Hx_k - b)$$

的误差迭代矩阵为 $G = I - \eta M^{-1}H$ 。虽然 $M^{-1}H$ 通常不对称, 但它相似于对称正定矩阵

$$S = M^{-1/2}HM^{-1/2}, \quad M^{-1}H = M^{-1/2}SM^{1/2}.$$

所以 $M^{-1}H$ 可对角化且全部特征值为正; 这些特征值正是广义特征值问题 $Hv = \lambda Mv$ 的解。令 $0 < \tilde{\mu} \leq \lambda(S) \leq \tilde{L}$, 则稳定步长为 $0 < \eta < 2/\tilde{L}$, 最优固定步长为 $2/(\tilde{L} + \tilde{\mu})$ 。预条件的目的就是让 $\kappa(S) = \tilde{L}/\tilde{\mu}$ 尽量接近 1。

3.8.2 动量法：每个 Hessian 特征方向对应一个二阶系统

对重球法

$$x_{k+1} = x_k - \eta \nabla f(x_k) + \beta(x_k - x_{k-1})$$

作用于二次函数, 沿 H 的特征向量 q_i 写误差坐标 $z_{k,i} = q_i^\top(x_k - x_*)$, 则每个模态独立满足

$$\begin{pmatrix} z_{k+1,i} \\ z_{k,i} \end{pmatrix} = \underbrace{\begin{pmatrix} 1 + \beta - \eta\lambda_i & -\beta \\ 1 & 0 \end{pmatrix}}_{T_{\lambda_i}} \begin{pmatrix} z_{k,i} \\ z_{k-1,i} \end{pmatrix}.$$

因此稳定性等价于对每个 $\lambda_i \in [\mu, L]$, 二次特征方程

$$r^2 - (1 + \beta - \eta\lambda_i)r + \beta = 0$$

的两个根都位于单位圆内。这里“特征值与根子空间”把一个高维优化器精确拆成许多二维动力系统; 若某些参数使重根落在单位圆附近, 还会出现与 Jordan 块相同的 kr^k 瞬态项。

3.8.3 谱估计、步长选择与正则化

对大规模问题不能显式形成 Hessian, 但可以用 Hessian-向量积执行幂迭代

$$v_{j+1} = \frac{Hv_j}{\|Hv_j\|_2}, \quad \hat{L}_j = \frac{v_j^\top Hv_j}{v_j^\top v_j},$$

以估计最大特征值并选择安全步长。若 H 的最大模特征值唯一且初值在对应特征向量上分量非零, 则幂迭代方向收敛到该特征方向, 速度由 $|\lambda_2/\lambda_1|$ 决定。

加入 ℓ_2 正则项 $f_\gamma(x) = f(x) + \frac{\gamma}{2}\|x\|_2^2$ 会把 Hessian 变成 $H + \gamma I$, 即把每个特征值统一平移为 $\lambda_i + \gamma$ 。这提高最小特征值并改善病态程度, 但也改变最优点, 体现“数值稳定性与偏差”的权衡。迹正则 $\text{tr}(H)$ 衡量特征值总和, Frobenius 正则 $\|H\|_F^2$ (对称时为 $\sum_i \lambda_i^2$) 则更强地惩罚少数过大的曲率方向。

注记 3.21 (本讲结论的逻辑依赖). 根子空间链稳定只用有限维性; 不同根子空间独立可用势函数归纳直接证明; 全空间根子空间分解则使用 Cayley–Hamilton 与 Bézout 恒等式; 最后通过限制算子的特征多项式, 才得到每个根子空间维数等于相应代数重数。这样安排避免把尚未证明的 Jordan 标准形反过来用于 Cayley–Hamilton, 从而不存在循环论证。

第 4 章

第 8 讲：约当标准形、矩阵幂与马尔可夫过程

本讲的主线是：把一般线性算子分解为若干条“广义特征向量链”，再据此理解矩阵幂 A^m 。矩阵幂控制离散动力系统，因此它也直接控制迭代优化算法和马尔可夫链的稳定性。

4.1 根子空间与约当链

设 $A \in \mathbb{C}^{n \times n}$ ， λ 是 A 的特征值。记

$$W_\lambda^k(A) = \text{Ker}(\lambda I - A)^k, \quad W_\lambda(A) = W_\lambda^n(A).$$

W_λ^1 是通常的特征空间， W_λ^k 称为第 k 层根子空间。由于

$$W_\lambda^1 \subseteq W_\lambda^2 \subseteq \cdots \subseteq W_\lambda^n,$$

该序列至多经过 n 步便稳定；而且一旦 $W_\lambda^K = W_\lambda^{K+1}$ ，以后各层也都相等。把满足该等式的最小 K 称为稳定指数。后面的约当形构造将证明：它恰是特征值 λ 的最大约当块尺寸。

定理 4.1 (根子空间的直和分解). 设 A 的不同特征值为 $\lambda_1, \dots, \lambda_s$ ，则

$$\mathbb{C}^n = W_{\lambda_1}(A) \oplus \cdots \oplus W_{\lambda_s}(A).$$

来源：第 8 讲原讲义第 1 页，Theorem 1.2

证明. 设特征多项式为

$$p_A(t) = \prod_{i=1}^s (t - \lambda_i)^{a_i}.$$

先说明本节定义中的 $W_{\lambda_i}^n$ 也可写成 $\text{Ker}(A - \lambda_i I)^{a_i}$ 。事实上，令 $q_i(t) = p_A(t)/(t - \lambda_i)^{a_i}$ ；由于 q_i 与 $(t - \lambda_i)^n$ 互素，可写成

$$\alpha_i(t)(t - \lambda_i)^n + \beta_i(t)q_i(t) = 1.$$

若 $(A - \lambda_i I)^n x = 0$ ，则 $x = \beta_i(A)q_i(A)x$ ，从而由 Cayley–Hamilton 定理

$$(A - \lambda_i I)^{a_i} x = \beta_i(A)p_A(A)x = 0.$$

反向包含关系显然 ($a_i \leq n$), 所以两种写法确实相同。

令 $q_i(t) = p_A(t)/(t - \lambda_i)^{a_i}$ 。因 q_i 与 $(t - \lambda_i)^{a_i}$ 互素, Bézout 恒等式给出多项式 u_i, v_i , 使

$$u_i(t)q_i(t) + v_i(t)(t - \lambda_i)^{a_i} = 1.$$

进一步由中国剩余定理, 可取多项式 $e_i(t)$ 满足

$$e_i \equiv 1 \pmod{(t - \lambda_i)^{a_i}}, \quad e_i \equiv 0 \pmod{(t - \lambda_j)^{a_j}} \quad (j \neq i),$$

并且 $\sum_i e_i(t) \equiv 1 \pmod{p_A(t)}$ 。令 $E_i = e_i(A)$ 。Cayley-Hamilton 定理 $p_A(A) = 0$ 蕴含

$$\sum_i E_i = I, \quad E_i E_j = 0 \quad (i \neq j), \quad E_i^2 = E_i.$$

又因为 $(A - \lambda_i I)^{a_i} E_i = 0$, 故 $\text{Im } E_i \subseteq W_{\lambda_i}(A)$ 。于是任意 x 都能写成

$$x = \sum_i E_i x, \quad E_i x \in W_{\lambda_i}(A),$$

说明这些根子空间之和为全空间。

若 $x_1 + \cdots + x_s = 0$ 且 $x_i \in W_{\lambda_i}(A)$, 左乘 E_k 。由上述同余关系, $E_k x_k = x_k$ 而 $E_k x_i = 0$ ($i \neq k$), 所以 $x_k = 0$ 。对每个 k 均成立, 故该和是直和。□

引理 4.2 (一组链同时线性无关). 令 $N = \lambda I - A$ 且 $k \geq 1$ 。若 $v_1, \dots, v_m \in W_\lambda^k$ 的陪集 $[v_1], \dots, [v_m]$ 在商空间 $W_\lambda^k/W_\lambda^{k-1}$ 中线性无关, 则

$$\{N^j v_i : i = 1, \dots, m, j = 0, \dots, k-1\}$$

线性无关。

来源: 第 8 讲原讲义第 1-2 页, Lemma 1.3; 此处补上严谨证明

证明. 假设存在关系

$$\sum_{i=1}^m \sum_{j=0}^{k-1} c_{ij} N^j v_i = 0.$$

若并非所有系数为零, 取最小的 r , 使某个 $c_{ir} \neq 0$ 。对等式作用 N^{k-1-r} 。所有 $j > r$ 的项含 $N^{k+(j-r-1)} v_i$, 因 $v_i \in \text{Ker } N^k$ 而消失; $j < r$ 的系数按 r 的最小性本来就是零。因此

$$N^{k-1} \left(\sum_{i=1}^m c_{ir} v_i \right) = 0,$$

即 $\sum_i c_{ir} v_i \in W_\lambda^{k-1}$ 。但 $[v_i]$ 在 $W_\lambda^k/W_\lambda^{k-1}$ 中线性无关, 所以所有 $c_{ir} = 0$, 矛盾。故原集合线性无关。□

易错点: 不需要、且一般不能使用的等式

原讲义证明中出现了 $W_\lambda^{k-1} = N W_\lambda^k$ 。这个等式一般不成立。例如 $N = 0$ 时, $W^1 = V$, 但 $N W^2 = \{0\}$ 。正确且总成立的是 $N W^k \subseteq W^{k-1}$; 上面的“取最小幂次并作用 N^{k-1-r} ”证明避开了这一问题。

4.2 复数约当标准形及其构造

采用原讲义的符号约定：约当块的超对角元为 -1 ，即

$$J_k(\lambda) = \begin{pmatrix} \lambda & -1 & & 0 \\ & \lambda & \ddots & \\ & & \ddots & -1 \\ 0 & & & \lambda \end{pmatrix}.$$

很多教材采用 $+1$ ；两种块通过对链向量交替变号相似，结论完全相同。

定理 4.3 (复数约当标准形). 对任意 $A \in \mathbb{C}^{n \times n}$ ，存在可逆矩阵 P ，使

$$A = PJP^{-1},$$

其中 J 是若干约当块的分块对角矩阵。同一特征值的所有约当块尺寸之和等于该特征值的代数重数。

来源：第 8 讲原讲义第 1-3 页，Theorem 1.1 与构造算法

证明. 由根子空间直和分解，只需在每个 $W_\lambda(A)$ 上处理 $N = \lambda I - A$ 。此时 N 是幂零算子。令

$$W_j = \text{Ker } N^j, \quad r_j = \dim W_j, \quad \Delta_j = r_j - r_{j-1}, \quad W_0 = \{0\}.$$

映射

$$\phi_j : W_{j+1}/W_j \longrightarrow W_j/W_{j-1}, \quad [v] \longmapsto [Nv]$$

是良定义的：若 $v - v' \in W_j$ ，则 $N(v - v') \in W_{j-1}$ ，所以 $[Nv] = [Nv']$ 。它还是单射：若 $Nv \in W_{j-1}$ ，则 $N^j v = 0$ ，故 $v \in W_j$ 。因此

$$\Delta_1 \geq \Delta_2 \geq \cdots \geq 0.$$

令 K 为稳定指数并约定 $\Delta_{K+1} = 0$ 。从第 K 层向下递归选链头。先在 W_K/W_{K-1} 取一组基，并选代表元作为长度 K 的链头。假设所有长度大于 j 的链头已经选好，而且它们在第 $j+1$ 层留下的向量陪集构成 W_{j+1}/W_j 的一组基。把这组基经单射 ϕ_j 映到 W_j/W_{j-1} ，得到 Δ_{j+1} 个线性无关陪集；再把它们扩充为该商空间的一组基。新增的 $\Delta_j - \Delta_{j+1}$ 个陪集各取一个代表元，作为长度 j 的新链头。如此下降到 $j = 1$ 。

递归构造保证：对每个 j ，所有长度至少为 j 的链在第 j 层恰留下 Δ_j 个向量，其陪集构成 W_j/W_{j-1} 的一组基。因此若全部链向量之间存在关系，从最高的非零商层开始逐层取陪集，便迫使该层系数全为零；下降归纳后所有系数都为零。故全部链向量联合线性无关。其总数为

$$\sum_{j \geq 1} j(\Delta_j - \Delta_{j+1}) = \sum_{j \geq 1} \Delta_j = r_K = \dim W_\lambda,$$

所以它们构成 W_λ 的一组基。

若按 $N^{j-1}u, \dots, Nu, u$ 排列一条链，则

$$A(N^\ell u) = \lambda N^\ell u - N^{\ell+1}u,$$

故 A 在该链基下的矩阵正是 $J_j(\lambda)$ 。把所有特征值的链基合并，便得到 P 与 J 。 $\square$

上述证明还给出约当块的唯一尺寸数据:

$$\Delta_j = \text{尺寸至少为 } j \text{ 的约当块个数}, \quad \Delta_j - \Delta_{j+1} = \text{尺寸恰为 } j \text{ 的块数}.$$

思考题 4.4 (构造指定约当块并写出各层根子空间). 矩阵 A 有两个特征值; 特征值 5 有两个约当块, 尺寸分别为 3 与 2. 构造一个这样的矩阵, 并给出根子空间各层的一组基.

来源: 第 8 讲原讲义第 3 页, 例一 (计算)

详细解答. 另一个特征值可自由选取, 例如取 1. 按原讲义的 -1 超对角约定, 令

$$A = \text{diag} \left(\begin{pmatrix} 5 & -1 & 0 \\ 0 & 5 & -1 \\ 0 & 0 & 5 \end{pmatrix}, \begin{pmatrix} 5 & -1 \\ 0 & 5 \end{pmatrix}, [1] \right) \in \mathbb{R}^{6 \times 6}.$$

记标准基为 $e_1, \dots, e_6$, $N = 5I - A$. 则

$$Ne_2 = e_1, \quad Ne_3 = e_2, \quad Ne_5 = e_4, \quad Ne_1 = Ne_4 = 0,$$

而 N 在 e_6 方向上等于乘以 4, 所以 e_6 不属于特征值 5 的根子空间. 逐层得到

$$\begin{aligned} W_5^1 &= \text{Ker } N = \text{span} \{e_1, e_4\}, \\ W_5^2 &= \text{Ker } N^2 = \text{span} \{e_1, e_2, e_4, e_5\}, \\ W_5^3 &= \text{Ker } N^3 = \text{span} \{e_1, e_2, e_3, e_4, e_5\}, \\ W_5^k &= W_5^3 \quad (k \geq 3). \end{aligned}$$

维数增量为 $(\Delta_1, \Delta_2, \Delta_3) = (2, 2, 1)$, 所以尺寸至少为 1, 2, 3 的块数分别是 2, 2, 1; 尺寸恰为 2 和 3 的块各一个. 对另一特征值 1,

$$W_1^k = \text{span} \{e_6\} \quad (k \geq 1).$$

两者直和为 $\mathbb{R}^6$. □

例 4.5 (原讲义四阶矩阵的链验证). 原讲义同时给出了 A, P, J , 但其中 A 的 (2, 2) 元素印成 2 时实际有 $AP \neq PJ$. 保留原讲义的 P, J 并由 $A = PJP^{-1}$ 反算, 正确矩阵应为

$$A = \begin{pmatrix} 3 & -1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ -6 & 6 & -3 & 3 \end{pmatrix}, \quad P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 2 & 1 & 0 \\ 0 & 0 & 3 & 1 \end{pmatrix},$$

并给出

$$J = \begin{pmatrix} 2 & -1 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 3 \end{pmatrix}.$$

最直接的核验不是展开 $P^{-1}AP$ ，而是逐列检查 $AP = PJ$ 。设 $P = [p_1, p_2, p_3, p_4]$ ，对上面修正后的 A 确有

$$Ap_1 = 2p_1, \quad Ap_2 = -p_1 + 2p_2, \quad Ap_3 = 2p_3, \quad Ap_4 = 3p_4.$$

这同时说明 $p_2 \mapsto p_1 \mapsto 0$ 是特征值 2 的长度 2 链， p_3 是另一个长度 1 链， p_4 是特征值 3 的特征向量。

来源：第 8 讲原讲义第 3 页，例二

4.3 实约当标准形

定理 4.6 (实约当标准形). 若 $A \in \mathbb{R}^{n \times n}$ ，则存在实可逆矩阵 P ，使

$$P^{-1}AP = \text{diag}(J_R, J_C).$$

实特征值对应通常的实约当块；每一对非实共轭特征值 $z = a + bi$ 与 $\bar{z}$ 对应以

$$C(z) = \begin{pmatrix} a & b \\ -b & a \end{pmatrix}$$

为对角块、以 $-I_2$ 为超对角块的实块。

来源：第 8 讲原讲义第 3-4 页，Theorem 1.4；此处补全证明

证明. 因为 A 为实矩阵，非实特征值成共轭对。每一对只选取 $z = a + bi$ ($b > 0$) 作为代表；若 u 是 z 的复特征向量或广义特征向量，则 $\bar{u}$ 是 $\bar{z}$ 的对应向量。先看特征向量 $u = p + iq$ ：

$$A(p + iq) = (a + bi)(p + iq) = (ap - bq) + i(bp + aq),$$

故

$$Ap = ap - bq, \quad Aq = bp + aq.$$

所以 A 在实基 (p, q) 下的矩阵是 $C(z)$ 。

对长度 k 的复约当链，把每个链向量的实部、虚部分别列入实基。链关系中的乘法 z 变为 $C(z)$ ，系数 -1 同时作用于实部和虚部，因而变为 $-I_2$ 。任何关于这些实部、虚部的实线性关系，都可借 $p = (u + \bar{u})/2$ 、 $q = (u - \bar{u})/(2i)$ 改写为 $w_z + w_{\bar{z}} = 0$ ，其中 $w_z \in W_z$ 、 $w_{\bar{z}} \in W_{\bar{z}}$ 。根子空间的直和性以及各条复链的线性无关性迫使全部系数为零。因此它们张成一个 $2k$ 维实不变子空间；换言之，同尺寸的 $J_k(z)$ 与 $J_k(\bar{z})$ 配成一个 $2k \times 2k$ 实块。对每对共轭链重复此过程，再加入实特征值的实链，得到所述实标准形。 $\square$

4.4 约当块的幂与迭代稳定性

若采用标准写法 $J = \lambda I + N$ ，其中 $N^s = 0$ ，则对 $m \in \mathbb{N}_0$ ，二项式定理给出

$$J^m = \sum_{r=0}^{\min\{m, s-1\}} \binom{m}{r} \lambda^{m-r} N^r.$$

原讲义使用 $J = \lambda I - N$ ，相应变为交替符号

$$J^m = \sum_{r=0}^{\min\{m, s-1\}} (-1)^r \binom{m}{r} \lambda^{m-r} N^r.$$

来源：第 8 讲原讲义第 4 页，矩阵幂补充内容

这条公式说明：

1. $|\lambda| < 1$ 时，虽然有 m^{s-1} 的多项式因子，仍有 $J^m \rightarrow 0$ ；
2. $|\lambda| > 1$ 时必然指数发散；
3. $|\lambda| = 1$ 且 $s > 1$ 时，通常以 m^{s-1} 增长；
4. 因此 $A^m \rightarrow 0$ 当且仅当谱半径 $\rho(A) < 1$ 。

优化连接：非正规矩阵的瞬态放大

即使 $\rho(A) < 1$ ，若 A 高度非正规或接近大约当块， $\|A^m\|$ 也可能先显著增大再衰减。优化算法的线性化只看特征值可能低估早期振荡；还应关注特征向量矩阵条件数、伪谱或直接估计 $\|A^m\|$ 。

4.5 马尔可夫链与 Perron–Frobenius 理论

本讲义采用列向量状态 S^t ，因此转移矩阵 P 是列随机矩阵：

$$P \geq 0, \quad e^\top P = e^\top, \quad S^{t+1} = PS^t.$$

其中 $e = (1, \dots, 1)^\top$ 。概率单纯形为

$$\Delta = \{x \in \mathbb{R}^n : x \geq 0, e^\top x = 1\}.$$

思考题 4.7 (一般马尔可夫链也总会逐步收敛吗？)。二状态例

$$P = \begin{pmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{pmatrix}$$

满足 $P^t e_1$ 与 $P^t e_2$ 都趋于 $(0.6, 0.4)^\top$ 。对一般随机矩阵是否总有类似性质？

来源：第 8 讲原讲义第 4 页，“问题”

详细解答。不总是。三类现象必须区分。

1. **不可约且非周期 (primitive)**：存在唯一稳态 $\pi > 0$ ，且对任意初始分布 S^0 ， $P^t S^0 \rightarrow \pi$ ，并具有几何收敛率。
2. **不可约但周期**：稳态仍唯一，但 $P^t S^0$ 可振荡。例如

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

使 e_1, e_2 交替出现，故没有逐点极限；但时间平均收敛到 $(1/2, 1/2)^\top$ 。

3. **可约**：可能有多个稳态，极限即使存在也会依赖初值。例如 $P = I$ 时每个概率向量都是稳态。

谱语言中的精确条件是：对所有初值都收敛到同一个稳态，当且仅当特征值 1 代数单且其余特征值模严格小于 1。有限状态链中，“不可约且非周期”保证这一条件。□

定理 4.8 (Perron–Frobenius: 正矩阵版本). 若 $A > 0$ (每个元素严格为正), 则谱半径 $\rho(A) > 0$ 是代数单特征值, 存在唯一的归一化正特征向量 $x > 0$ 使

$$Ax = \rho(A)x, \quad e^T x = 1.$$

而且其他特征值 λ 均满足 $|\lambda| < \rho(A)$ 。若 $A \geq 0$ 仅不可约, 则仍存在正 Perron 向量且 $\rho(A)$ 代数单, 但圆周 $|\lambda| = \rho(A)$ 上可能还有其他特征值。

来源：第 8 讲原讲义第 4-5 页, Theorem 2.2; 此处补全存在性与代数单性

证明. 先证 $A > 0$ 。定义连续映射

$$F: \Delta \rightarrow \Delta, \quad F(x) = \frac{Ax}{e^T Ax}.$$

分母严格为正, 且 $F(x) > 0$ 。由 Brouwer 不动点定理, 存在 $x \in \Delta$ 使 $F(x) = x$ 。令 $r = e^T Ax > 0$, 便有 $Ax = rx$ 且 $x > 0$ 。

现证 $r = \rho(A)$ 。若 $Av = \lambda v$ (允许 v 为复向量), 令

$$\alpha = \max_i \frac{|v_i|}{x_i},$$

并取达到最大值的指标 i 。则

$$|\lambda| |v_i| = |(Av)_i| \leq \sum_j A_{ij} |v_j| \leq \alpha \sum_j A_{ij} x_j = \alpha r x_i = r |v_i|.$$

所以 $|\lambda| \leq r$, 从而 $r = \rho(A)$ 。若等号成立, 由于所有 $A_{ij} > 0$, 三角不等式和逐项估计必须处处取等; 这迫使全部 v_j/x_j 有相同模与相位, 因此 $v = cx$ 且 $\lambda = r$ 。故 Perron 特征空间一维, 并且其他特征值模严格小于 r 。

最后证明代数单性。对 $A^T > 0$ 同理得到左正特征向量 $y > 0$, $y^T A = ry^T$ 。若存在长度至少为 2 的广义链, 则可缩放链向量使 $(A - rI)z = x$ 。左乘 y^T 得

$$0 = y^T (A - rI)z = y^T x > 0,$$

矛盾。因此不存在更大的约当块, r 代数单。

再证 $A \geq 0$ 不可约的情形。若 $n = 1$ 结论显然; 以下设 $n \geq 2$ 。不可约性意味着其有向图中任意两点间都有长度不超过 $n - 1$ 的简单路径, 因此

$$B = (I + A)^{n-1} > 0.$$

对正矩阵 B 应用刚证完的结论, 取其归一化 Perron 向量 $x > 0$ 。因为 A 与 B 交换,

$$B(Ax) = A(Bx) = \rho(B)Ax.$$

B 的 Perron 特征空间是一维的, 故 $Ax = cx$; 由 $A \geq 0$, $x > 0$ 及不可约性知 $c > 0$ 。于是 $\rho(B) = (1+c)^{n-1}$ 。对 A 的任一复特征对 $Av = \lambda v$, 沿用上面的最大比值估计 (这一步只需 $A \geq 0$) 可得 $|\lambda| \leq c$, 所以 $c = \rho(A)$ 。

同理, 对 B^T 的左 Perron 向量 $y > 0$, 交换关系给出 $y^T A = cy^T$ 。若 A 在 c 处存在长度至少为 2 的广义链, 则因其特征空间已经是一维, 可取 z 使 $(A - cI)z = x$; 左乘 y^T 又得到 $0 = y^T x > 0$ 的矛盾。因此 c 代数单。此时三角不等式未必严格, 故仍可能有其他满足 $|\lambda| = c$ 的周期性圆周特征值。□

定理 4.9 (随机矩阵的谱与稳态). 若 P 是列随机矩阵, 则:

1. 1 是 P 的特征值, 且所有特征值满足 $|\lambda| \leq 1$;
2. 至少存在一个稳态分布 $x \in \Delta$, 使 $Px = x$ 。

来源: 第 8 讲原讲义第 5 页, Theorem 2.3; 此处补全不动点论证

证明. 由 $e^T P = e^T$, 1 是 P^T 的特征值; P 与 P^T 特征多项式相同, 故 1 也是 P 的特征值。又因

$$\|P\|_1 = \max_j \sum_i |P_{ij}| = 1,$$

谱半径满足 $\rho(P) \leq \|P\|_1 = 1$ 。

另一方面, $P\Delta \subseteq \Delta$: 若 $x \geq 0$ 且 $e^T x = 1$, 则 $Px \geq 0$ 且 $e^T Px = e^T x = 1$ 。 Δ 是非空紧凸集, 连续映射 $x \mapsto Px$ 由 Brouwer 定理至少有一个不动点。这就是非负稳态向量。□

4.6 长期平均定理: 完整而准确的版本

定理 4.10 (有限马尔可夫链的 Cesàro 长期平均). 对任意有限维列随机矩阵 P 和初始分布 S^0 ,

$$\bar{S}_T = \frac{1}{T} \sum_{t=0}^{T-1} P^t S^0$$

必收敛到某个稳态分布。若 P 不可约, 则稳态唯一, 故极限与 S^0 无关; 但除非再加非周期性, $P^t S^0$ 本身未必收敛。

来源: 第 8 讲原讲义第 6 页, Theorem 2.4; 此处补全证明并澄清条件

证明. 由 $\|P^t\|_1 = 1$, 序列 P^t 有界。因此 P 在单位圆上的特征值不可能拥有尺寸大于 1 的约当块; 否则约当幂公式会产生 $t, t^2, \dots$ 的增长, 与有界性矛盾。

在复约当基下逐块考察

$$\frac{1}{T} \sum_{t=0}^{T-1} J^t.$$

若 $|\lambda| < 1$, 约当块的各项至多是 $t^r |\lambda|^{t-r}$ 型, 故 $\sum_{t \geq 0} J^t$ 绝对收敛, 部分和有界, 除以 T 后趋于零; 若 $|\lambda| = 1$ 且 $\lambda \neq 1$, 对应块只有一阶, 且

$$\frac{1}{T} \sum_{t=0}^{T-1} \lambda^t = \frac{1 - \lambda^T}{T(1 - \lambda)} \rightarrow 0;$$

若 $\lambda = 1$ ，平均值保持为 1。故矩阵平均

$$\Pi = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} P^t$$

存在，并且 $P\Pi = \Pi P = \Pi$ 、 $\Pi^2 = \Pi$ ，即它是投影到 $\text{Ker}(P - I)$ 的谱投影。因此 $\bar{S}_T \rightarrow \Pi S^0$ ，且

$$P(\Pi S^0) = \Pi S^0.$$

每个 $\bar{S}_T$ 都在闭集 Δ 中，所以极限也是概率分布。

若 P 不可约，Perron-Frobenius 定理保证归一化稳态唯一，故 ΠS^0 必为同一个 π 。若进一步非周期，则除 1 外所有特征值模小于 1，于是 $P^t S^0$ 本身几何收敛到 π 。□

易错点：时间平均一般不是指数收敛

原讲义将“long-run average 收敛”与“指数速度收敛到唯一稳态”放在一起，需分开理解。周期链的时间平均通常只有 $O(1/T)$ 误差。在不可约链的讨论中，非周期性保证原始迭代 $P^t S^0$ 指数收敛；一般可约链也可能因自身的谱条件而指数收敛。例如翻转矩阵的状态永远振荡，而时间平均才收敛。

优化连接：迭代算法就是矩阵幂

对二次函数

$$f(x) = \frac{1}{2} x^\top H x - b^\top x, \quad H \succ 0,$$

令 $x_\star = H^{-1}b$ 、 $e_k = x_k - x_\star$ 。使用固定实标量步长的梯度下降满足

$$e_{k+1} = (I - \eta H) e_k.$$

所以对所有初值收敛的条件是 $\rho(I - \eta H) < 1$ ，即 $0 < \eta < 2/\lambda_{\max}(H)$ 。在所有常数标量步长中，使欧氏最坏方向收缩因子 $\|I - \eta H\|_2$ 最小的步长为

$$\eta_\star = \frac{2}{\lambda_{\min} + \lambda_{\max}}$$

并给出最坏方向收缩率

$$\frac{\kappa(H) - 1}{\kappa(H) + 1}, \quad \kappa(H) = \frac{\lambda_{\max}(H)}{\lambda_{\min}(H)}.$$

动量法把状态扩为 (e_k, e_{k-1}) ，其稳定性由一个 $2n \times 2n$ 伴随矩阵的约当结构决定。若特征值靠近单位圆且矩阵非正规，就可能出现明显瞬态放大，这正是本讲“约当块 $\rightarrow$ 矩阵幂 $\rightarrow$ 迭代稳定性”的优化含义。

第5章

专题补充：正定矩阵的完整工具箱

正定性把二次型、特征值、行列式、矩阵分解与凸优化连成一条完整的等价链。本章给出用户特别要求的 Cholesky 分解与顺序主子式判据，并把常用的其他等价条件一并证明。

5.1 定义与基本辨析

定义 5.1 (正定与半正定). 对实对称矩阵 $A = A^T \in \mathbb{R}^{n \times n}$:

$$A \succ 0 \iff x^T A x > 0 \quad \text{对一切 } x \neq 0,$$

$$A \succeq 0 \iff x^T A x \geq 0 \quad \text{对一切 } x.$$

负定、负半定分别记作 $A \prec 0, A \preceq 0$ 。既有正方向又有负方向时称为不定。

若 A 不对称, 则

$$x^T A x = x^T \frac{A + A^T}{2} x,$$

所以二次型只看 A 的对称部分。因而讨论“正定矩阵”时通常把对称性纳入定义; 否则应明确说“其对称部分正定”。

5.2 正定性的等价条件总表

记 $A_k = A[1:k, 1:k]$ 为左上角 k 阶顺序主子矩阵, $\Delta_k = \det A_k$, 并约定 $\Delta_0 = 1$ 。

定理 5.2 (实对称矩阵正定性的等价刻画). 对 $A = A^T \in \mathbb{R}^{n \times n}$, 以下条件等价:

- (i) $x^T A x > 0$ 对所有 $x \neq 0$;
- (ii) A 的所有特征值严格为正;
- (iii) 存在正交矩阵 Q 与正对角矩阵 Λ , 使 $A = Q \Lambda Q^T$;
- (iv) 存在可逆矩阵 B , 使 $A = B^T B$;
- (v) 存在唯一正定平方根 $A^{1/2} \succ 0$, 满足 $(A^{1/2})^2 = A$;
- (vi) 存在唯一的 Cholesky 分解 $A = L L^T$, 其中 L 为对角元严格为正的下三角矩阵;
- (vii) 所有顺序主子式严格为正: $\Delta_1, \dots, \Delta_n > 0$ (Sylvester判据);
- (viii) A 有无需选主元的分解 $A = L D L^T$, 其中 L 为单位下三角矩阵, $D = \text{diag}(d_1, \dots, d_n)$ 且所有 $d_i > 0$;

(ix) A 的每个主子式都严格为正;

(x) A 可逆且 $A^{-1} \succ 0$;

(xi) 二次函数 $q(x) = \frac{1}{2}x^T Ax$ 是严格凸的; 等价地, 它是 $\lambda_{\min}(A)$ -强凸的。

证明. 由实对称谱定理, $A = Q\Lambda Q^T$. 令 $y = Q^T x$, 则

$$x^T Ax = y^T \Lambda y = \sum_{i=1}^n \lambda_i y_i^2.$$

所以 (i)、(ii)、(iii) 等价。

若 (iii) 成立, 取 $A^{1/2} = Q\Lambda^{1/2}Q^T$, 便得到 (v)。若 (v) 成立, 记 $S = A^{1/2} \succ 0$, 则 $S = S^T$ 且

$$A = S^2 = S^T S,$$

取 $B = S$ 即得 (iv)。反过来, 若 $A = B^T B$ 且 B 可逆, 则

$$x^T Ax = \|Bx\|_2^2 > 0 \quad (x \neq 0),$$

故 (iv) $\Rightarrow$ (i)。正定平方根的唯一性可由谱投影说明: 任何正定 S 满足 $S^2 = A$ 时, S 与 A 对易, 并在 A 的每个特征空间上只能取正根 $\sqrt{\lambda}$, 所以 $S = Q\Lambda^{1/2}Q^T$ 。

(i) 蕴含任意主子矩阵正定。事实上, 对指标集 I 和非零 $z \in \mathbb{R}^{|I|}$, 把 z 嵌入原空间、在 I 外补零得到 x , 则

$$z^T A[I, I]z = x^T Ax > 0.$$

每个主子矩阵的特征值均为正, 行列式是特征值之积, 故每个主子式为正。这说明 (i) $\Rightarrow$ (ix) $\Rightarrow$ (vii)。

现证 (vii) $\Rightarrow$ (viii)。在精确算术中, 对称 Gaussian 消元在前 k 步的主元为

$$d_k = \frac{\Delta_k}{\Delta_{k-1}}.$$

因为所有 $\Delta_k > 0$, 每个主元均存在且 $d_k > 0$, 故消元无需换行便得到 $A = LDL^T$ 。该比值用于理论证明; 浮点实现应直接更新 LDL^T , 不应先计算可能严重失真的行列式。更完整的归纳写法是, 把

$$A = \begin{pmatrix} a & r^T \\ r & C \end{pmatrix}, \quad a = \Delta_1 > 0,$$

分解为

$$A = \begin{pmatrix} 1 & 0 \\ r/a & I \end{pmatrix} \begin{pmatrix} a & 0 \\ 0 & C - rr^T/a \end{pmatrix} \begin{pmatrix} 1 & r^T/a \\ 0 & I \end{pmatrix}.$$

Schur 补 $S = C - rr^T/a$ 的前 k 阶顺序主子式等于 $\Delta_{k+1}/a > 0$, 故可对 S 递归应用归纳假设。

由 (viii), 令 $D^{1/2} = \text{diag}(\sqrt{d_i})$, 则

$$A = (LD^{1/2})(LD^{1/2})^T,$$

得到 (vi)。而 (vi) 是 (iv) 的特殊情形, 故等价链闭合。

Cholesky 的唯一性如下。若 $LL^T = MM^T$ 且 L, M 均为正对角下三角, 则

$$M^{-1}L = M^T L^{-T}.$$

左边是正对角下三角，右边是正对角上三角，故两者只能是正对角矩阵；又其乘自身转置为 I ，故等于 I ，所以 $L = M$ 。

若 (ii) 成立，则 $A^{-1} = Q\Lambda^{-1}Q^T \succ 0$ ；反过来， A^{-1} 的特征值是 $1/\lambda_i(A)$ ，全为正便推出 A 的特征值全为正。因此 (ii) $\Leftrightarrow$ (x)。

最后， q 的 Hessian 恒为 A 。对这个二次函数， $A \succ 0$ 时有

$$q(y) \geq q(x) + \nabla q(x)^T(y-x) + \frac{\lambda_{\min}(A)}{2} \|y-x\|_2^2,$$

所以 q 是 $\lambda_{\min}(A)$ -强凸，特别是严格凸。反之，若 A 有负特征值，则 q 沿相应特征向量的一维限制不是凸函数；若 $A \succeq 0$ 但有零特征值，则 q 沿非零零空间方向保持常数，因而不严格凸。故对本二次函数确有 (i) $\Leftrightarrow$ (xi)。一般二阶可微函数“严格凸”并不要求 Hessian 处处正定，例如 x^4 在原点的二阶导数为零。□

易错点：半正定版本不能只查顺序主子式

对称矩阵正半定当且仅当所有主子式非负；“所有顺序主子式非负”却不够。例如

$$A = \begin{pmatrix} 0 & 0 \\ 0 & -1 \end{pmatrix}$$

的顺序主子式为 $0, 0$ ，但 $e_2^T A e_2 = -1$ 。严格正定时 Sylvester 判据之所以只需顺序主子式，是因为严格正号保证每一步消元主元均为正。

5.3 Schur 补：递归正定判据

定理 5.3 (Schur 补判据). 设

$$M = \begin{pmatrix} A & B \\ B^T & C \end{pmatrix} = M^T.$$

若 A 可逆，则

$$M \succ 0 \iff A \succ 0 \text{ 且 } C - B^T A^{-1} B \succ 0.$$

对称地，若 C 可逆，也可交换两块。

证明. 作合同分解

$$\begin{pmatrix} I & 0 \\ -B^T A^{-1} & I \end{pmatrix} M \begin{pmatrix} I & -A^{-1} B \\ 0 & I \end{pmatrix} = \begin{pmatrix} A & 0 \\ 0 & C - B^T A^{-1} B \end{pmatrix}.$$

左右的三角矩阵互为转置且可逆。合同变换保持惯性指数（正、负、零特征值个数），故左侧正定当且仅当右侧两个对角块都正定。

也可直接配方。对 x, y ,

$$\begin{pmatrix} x \\ y \end{pmatrix}^T M \begin{pmatrix} x \\ y \end{pmatrix} = (x + A^{-1} B y)^T A (x + A^{-1} B y) + y^T (C - B^T A^{-1} B) y.$$

若 $A \succ 0$ 且 Schur 补正定，则两项均非负，并且除 $(x, y) = (0, 0)$ 外不可能同时为零，所以其和严格为正；反向取 $y = 0$ 及 $x = -A^{-1}By$ 即可分别恢复两个正定条件。□

Schur 补在块坐标下降、KKT 系统、高斯条件分布、Kalman 滤波和块预条件中反复出现。它也是上述 Cholesky 归纳证明的核心。

5.4 Cholesky 与 LDL^T 的计算公式

令 $A = LL^T$, $L = (\ell_{ij})$ 。逐项比较可得

$$\begin{aligned}\ell_{jj} &= \sqrt{a_{jj} - \sum_{k=1}^{j-1} \ell_{jk}^2}, \\ \ell_{ij} &= \frac{a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} \ell_{jk}}{\ell_{jj}}, \quad i > j.\end{aligned}$$

正定性保证每个根号内严格为正，因此无需选主元。求解 $Ax = b$ 时不必显式求逆，只需两次三角求解：

$$Ly = b, \quad L^T x = y.$$

例 5.4 (手算 Cholesky). 令

$$A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}.$$

$\Delta_1 = 4 > 0$, $\Delta_2 = 8 > 0$, 故 $A \succ 0$ 。计算得

$$L = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix}, \quad LL^T = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}.$$

对应 LDL^T 可写成

$$L_0 = \begin{pmatrix} 1 & 0 \\ 1/2 & 1 \end{pmatrix}, \quad D = \text{diag}(4, 2), \quad A = L_0 D L_0^T.$$

注意 $d_1 = \Delta_1/\Delta_0 = 4$, $d_2 = \Delta_2/\Delta_1 = 2$ 。

易错点：数值计算中的“理论正定、浮点失败”

若最小特征值非常接近零，舍入误差可能使 Cholesky 根号内出现微小负数。这通常说明矩阵病态、数据噪声破坏了半正定性，或正则项太小。常见处理是先对称化 $S = (A + A^T)/2$ ，再加阻尼 $S + \varepsilon I$ 。要保证严格正定，必须有 $\varepsilon > -\lambda_{\min}(S)$ (并留出数值裕量)；任意“小”阻尼并不能修复负曲率。 ε 会改变问题，必须记录其大小。

5.5 半正定矩阵、Gram 矩阵与最小二乘

对任意 $X \in \mathbb{R}^{m \times n}$,

$$X^T X \succeq 0, \quad z^T X^T X z = \|Xz\|_2^2.$$

进一步,

$$X^T X \succ 0 \iff \text{Ker } X = \{0\} \iff X \text{ 满列秩.}$$

因此最小二乘问题 $\min_x \|Xx - y\|_2^2$ 在 X 满列秩时有唯一解, 正规方程为

$$X^T X x = X^T y.$$

虽然可以 Cholesky 求解, 但

$$\text{cond}_2(X^T X) = \text{cond}_2(X)^2,$$

正规方程会把条件数平方。病态问题应优先用 QR 或 SVD, 而不是显式形成 $X^T X$ 。

5.6 正定性在优化中的直接含义

优化连接: Hessian、曲率与唯一极小点

若 f 二阶可微且在凸域上, 对某些 $0 < \mu \leq L$ 有

$$\mu I \preceq \nabla^2 f(x) \preceq LI,$$

则 f 是 μ -强凸且梯度 L -Lipschitz。它至多有一个极小点, 并且普通梯度下降的难度由条件数 $\kappa = L/\mu$ 控制。若下界只有 $0 \preceq \nabla^2 f(x)$, 则只能推出凸性, 平坦方向可能导致非唯一解, 也不能定义有限的 L/μ 。

优化连接: Newton 法为何解一个正定系统

Newton 步 p 解

$$\nabla^2 f(x)p = -\nabla f(x).$$

若 Hessian 正定且 $\nabla f(x) \neq 0$, 则 p 是严格下降方向, 因为

$$\nabla f(x)^T p = -\nabla f(x)^T [\nabla^2 f(x)]^{-1} \nabla f(x) < 0.$$

Cholesky 是求 Newton 步的首选分解。非凸区域 Hessian 可能不定, 此时需要阻尼、信赖域或修正 Cholesky, 而不能直接把不定矩阵当作正定矩阵开方。若 $\nabla f(x) = 0$, 则 $p = 0$ 且上式等于零, 此时已经是一阶驻点。

优化连接: 预条件就是改变度量

对 $H = H^T \succ 0$ 的二次目标, 给定 $M \succ 0$, 预条件梯度步

$$x_{k+1} = x_k - \eta M^{-1} \nabla f(x_k)$$

等价于在内积 $\langle u, v \rangle_M = u^T M v$ 下做最陡下降。对二次目标, 收敛由

$$M^{-1/2} H M^{-1/2} \succ 0$$

的条件数控制。好的预条件器让其特征值聚集在 1 附近; 这比“把每个坐标单独调步长”更准确地描述 Shampoo、自然梯度与二阶法的共同目标。若 H 不定, 正定预条件只是合同变换并保持惯性, 不能把负曲率变成正曲率。

第6章

从线性代数到数学优化与优化器

本章不把优化应用当作零散例子，而是把第 5–8 讲的概念按“模型 → 线性系统 → 分解 → 迭代稳定性”重新串联。

6.1 最小二乘：QR、Cholesky 与 SVD 如何选择

考虑

$$\min_x \frac{1}{2} \|Ax - b\|_2^2, \quad A \in \mathbb{R}^{m \times n}, m \geq n.$$

一阶条件是正规方程 $A^T Ax = A^T b$ 。若 A 满列秩，则 $A^T A \succ 0$ ，可用 Cholesky；但它会把条件数平方。

若用薄 QR 分解 $A = QR$ ，其中 $Q^T Q = I_n$ 、 R 可逆上三角，则

$$\|Ax - b\|_2^2 = \|Q^T b - Rx\|_2^2 + \|(I - QQ^T)b\|_2^2,$$

故只需解

$$Rx = Q^T b.$$

Householder QR 通常比经典 Gram–Schmidt 稳定。若 A 可能秩亏，则带列主元 QR 能揭示数值秩；SVD

$$A = U\Sigma V^T, \quad A^+ = V\Sigma^+ U^T$$

则 $x = A^+ b$ 是全部最小二乘最优解中欧氏范数最小者（当方程相容时也是最小范数精确解），代价更高但诊断最完整。

方法	适用情形	优点	主要风险
Cholesky 正规方程	满列秩且条件良好	快、存储少	条件数平方
Householder QR	一般满秩最小二乘	稳定、无需形成 $A^T A$	比 Cholesky 略贵
带主元 QR	可能近似秩亏	可估数值秩	结果依赖阈值
SVD	秩亏或极病态	最小范数解、完整谱信息	计算最贵

6.2 投影、正交补与约束优化

若 Q 的列为子空间 $\mathcal{S}$ 的标准正交基，则正交投影为

$$P_{\mathcal{S}} = QQ^{\top}, \quad x = P_{\mathcal{S}}x + (I - P_{\mathcal{S}})x,$$

两部分分别属于 $\mathcal{S}$ 与 $\mathcal{S}^{\perp}$ 。这就是第 5 讲正交化与第 6 讲正交补在优化中的共同接口。

对线性等式约束

$$\min_x f(x) \quad \text{s.t.} \quad Cx = d,$$

取一个可行点 x_0 ，并令 Z 的列构成 $\text{Ker } C$ 的标准正交基。所有可行点唯一写成

$$x = x_0 + Zz.$$

于是问题化为无约束问题 $\min_z f(x_0 + Zz)$ ，其梯度与 Hessian 分别为

$$Z^{\top} \nabla f(x_0 + Zz), \quad Z^{\top} \nabla^2 f(x_0 + Zz) Z.$$

这称为零空间法。特别地，对可行的等式约束二次问题 $f(x) = \frac{1}{2}x^{\top}Hx + c^{\top}x$ ($H = H^{\top}$)，若 Z 的列完整张成 $\text{Ker } C$ 且 $Z^{\top}HZ \succ 0$ ，则约化目标强凸，因而有唯一可行极小点；即使 H 在全空间中不定也可能如此。

6.3 谱、条件数与梯度下降

对 $H \succ 0$ 的二次函数

$$f(x) = \frac{1}{2}x^{\top}Hx - b^{\top}x, \quad x_{\star} = H^{-1}b,$$

梯度下降给出

$$e_{k+1} = (I - \eta H)e_k, \quad e_k = x_k - x_{\star}.$$

在 $H = Q\Lambda Q^{\top}$ 的特征基下，各坐标独立满足

$$\hat{e}_{k+1,i} = (1 - \eta\lambda_i)\hat{e}_{k,i}.$$

因此，对所有初始误差都收敛到零的充要稳定区间是 $0 < \eta < 2/\lambda_{\max}$ 。最优固定步长与收缩率为

$$\eta_{\star} = \frac{2}{\lambda_{\min} + \lambda_{\max}}, \quad q_{\star} = \frac{\kappa - 1}{\kappa + 1}, \quad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

这给条件数一个直接的算法解释： κ 大意味着不同方向要求互相冲突的步长。

6.3.1 动量法与二阶状态矩阵

重球法

$$x_{k+1} = x_k - \eta \nabla f(x_k) + \beta(x_k - x_{k-1})$$

在 Hessian 的一个特征方向 λ 上满足

$$\begin{pmatrix} e_{k+1} \\ e_k \end{pmatrix} = \underbrace{\begin{pmatrix} 1 + \beta - \eta\lambda & -\beta \\ 1 & 0 \end{pmatrix}}_{M_\lambda} \begin{pmatrix} e_k \\ e_{k-1} \end{pmatrix}.$$

特征多项式为

$$r^2 - (1 + \beta - \eta\lambda)r + \beta = 0.$$

所有 $\lambda \in [\mu, L]$ 对应的两个根都在单位圆内时算法才稳定。若出现重根且 M_λ 不可对角化, 误差含 kr^k ; 这正是约当块的多项式因子。实际调参中“谱半径略小于 1 但仍有大幅振荡”, 常与这种近缺陷或非正规瞬态有关。

6.4 预条件、变量替换与坐标几何

令 $x = Cz$, 其中 C 可逆, 则二次型变为

$$\frac{1}{2}z^\top(C^\top HC)z - (C^\top b)^\top z.$$

Hessian 在坐标变换下作合同变换而非相似变换。若 $H \succ 0$ 且 $M \succ 0$, 取主平方根对应的 $C = M^{-1/2}$, 新的 Hessian 是

$$\tilde{H} = M^{-1/2}HM^{-1/2} \succ 0.$$

预条件的目标就是减小 $\text{cond}_2(\tilde{H})$ 。在局部 Hessian 正定时, Newton 法理想地取 $M = H$, 使二次模型被白化为单位矩阵。若 H 不定, 合同变换保持惯性, 不能用 SPD 条件数作同样解释。

6.4.1 Adam: 对角预条件的优点与坐标依赖

忽略偏差校正, Adam 形式上使用

$$D_t = \text{diag}(\sqrt{v_t} + \varepsilon), \quad \theta_{t+1} = \theta_t - \eta D_t^{-1} m_t.$$

v_t 是逐坐标非负二阶矩估计, 且 $\varepsilon > 0$, 所以 $D_t \succ 0$ 。这是时变对角度量下的预条件步。它廉价、适合尺度差异明显的坐标; 但“取对角”依赖所选基。若完整梯度二阶矩为 $S = \mathbb{E}[gg^\top]$, 原坐标只保留 $\text{diag}(S)$; 在正交旋转 $g' = Q^\top g$ 后保留的是 $\text{diag}(Q^\top SQ)$ 。一般有

$$Q^\top \text{diag}(\text{diag}(S))Q \neq \text{diag}(\text{diag}(Q^\top SQ)),$$

这里内层 $\text{diag}(S)$ 表示抽取对角向量, 外层 $\text{diag}(\cdot)$ 表示组成对角矩阵。因此“先旋转再做 Adam”与“先做 Adam 再旋转”通常不等价。相关特征方向若不与坐标轴对齐, 对角预条件无法消除耦合曲率。

6.4.2 Shampoo: Kronecker 因子与双侧白化

对矩阵参数的梯度 $G_t \in \mathbb{R}^{m \times n}$, Shampoo 类方法累计

$$L_t = \varepsilon I_m + \sum_{s \leq t} G_s G_s^\top, \quad R_t = \varepsilon I_n + \sum_{s \leq t} G_s^\top G_s,$$

二者因 $\varepsilon > 0$ 而正定。典型双侧更新为

$$\tilde{G}_t = L_t^{-1/4} G_t R_t^{-1/4}.$$

用向量化恒等式

$$\text{vec}(L^{-1/4} G R^{-1/4}) = (R^{-1/4} \otimes L^{-1/4}) \text{vec}(G),$$

可见它用 Kronecker 结构近似一个全矩阵预条件器。此处 $\varepsilon > 0$ 保证两个累积 Gram 因子 SPD，因而其唯一 SPD 负四分之一次幂良好定义；若因子本来已 SPD，理论上不额外需要阻尼。半正定情形也可在支撑子空间上使用广义逆幂。

一个很有启发性的单步恒等式是：若 G 的秩为 r ，紧致 SVD 为 $G = U_r \Sigma_r V_r^T$ ，其中 $\Sigma_r \succ 0$ ，并在非零奇异子空间上取广义逆幂，则

$$(GG^T)^{-1/4} G (G^T G)^{-1/4} = U_r V_r^T.$$

右边是 G 的部分等距极因子。也就是说，双侧四次根白化会把所有非零奇异值归一为 1，只保留方向信息。

6.4.3 Muon 与极分解视角

Muon 类矩阵优化器会近似把梯度映到其极分解因子。若 $m \geq n$ 且 G 满列秩，薄 SVD 为

$$G = U \Sigma V^T,$$

则 $U^T U = V^T V = I_n$ ， UV^T 是 Frobenius 范数下离 G 最近的列半正交矩阵。对约束 $\|\Delta\|_2 \leq 1$ 的线性化最小化，最陡下降取负的极因子 $-UV^T$ 。若 $m < n$ 应交换行/列半正交条件；若秩亏， $U_r V_r^T$ 只是部分等距因子，最近的完整半正交补全一般不唯一。Newton-Schulz 迭代可避免显式 SVD，但必须先缩放，使奇异值落入其收敛区间。这里第 5 讲的正交结构、第 7 讲的矩阵函数、第 8 讲的迭代稳定性同时出现。

6.5 马尔可夫矩阵在优化与学习中的两类应用

6.5.1 PageRank 的阻尼为何有效

给定非负列随机矩阵 P ，令 $e = (1, \dots, 1)^T$ ，并取 $v > 0$ 、 $e^T v = 1$ ，定义

$$P_\alpha = \alpha P + (1 - \alpha) v e^T, \quad 0 < \alpha < 1.$$

$P_\alpha > 0$ ，所以 Perron-Frobenius 定理保证唯一正稳态。并且对总质量为零的差向量 z ，

$$P_\alpha z = \alpha P z, \quad \|P_\alpha z\|_1 \leq \alpha \|z\|_1.$$

因此阻尼不仅修补了可约性和周期性，还给出显式收缩因子 α 。

6.5.2 去中心化优化中的混合矩阵

多个节点做共识或去中心化 SGD 时，常用随机矩阵 W 混合本地参数。若 W 对称双随机、通信图连通且 1 是单特征值，则特征值 1 对应共识子空间，分歧的二范数按

$$\max_{i \geq 2} |\lambda_i(W)|$$

收缩，因而谱隙 $1 - \max_{i \geq 2} |\lambda_i(W)|$ 越大，信息混合越快。若网络有周期结构，原始状态可能振荡，需要自环、阻尼或平均化。对非对称或非正规混合矩阵，还必须指定左右稳态向量与共识投影；有限步衰减可能由加权范数、奇异值与瞬态放大控制，不能只看特征值模。

6.6 矩阵工具选择清单

面对一个优化相关矩阵问题，可以按下列顺序判断：

1. **矩阵是否对称/Hermitian**？若否，特征值可能不能完整描述范数增长；考虑 SVD、Schur 分解或伪谱。
2. **是否正定**？可用 Cholesky 尝试、Sylvester 判据（手算）或最小特征值（分析）；浮点环境不要用显式行列式作大规模判据。
3. **目标是解方程还是求逆**？几乎总应做分解后求解，不显式形成逆矩阵。
4. **是否病态或秩亏**？从 Cholesky/正规方程升级到带主元 QR 或 SVD。
5. **是否反复迭代**？检查谱半径之外，还要关注约当块、非正规性和舍入误差累积。
6. **是否计算分数次幂**？对本文预条件器所需的实对称负分数幂，先保证 SPD（必要时加入有记录的阻尼）再计算；更一般的矩阵分数次幂必须指定谱分支与适用算法。

优化连接：一句话知识图

基与正交化决定“怎样表示”；正定性决定“曲率是否可靠”；QR/SVD/Cholesky 决定“怎样稳定求解”；特征值与约当结构决定“迭代怎样演化”；预条件器则主动改变表示和曲率，使优化问题更接近各向同性。

第7章

原讲义问题覆盖索引与勘误

本章用于快速核验“题目是否漏掉”。四份原 PDF 共 $9 + 4 + 7 + 6 = 26$ 页，均以渲染图逐页检查。正文共设置 17 个显式 `problem--solution` 题框；讲义中已有答案但推导跳步的计算题也重新验算。除此之外，第 5–7 讲合计补写 58 个正式证明或关键证明段，第 8 讲补齐约当标准形、Perron–Frobenius 与长期平均等核心证明。

7.1 显式题目索引

讲义	原页	题目或待回答问题	本书位置
第 5 讲	第 2–3 页	四个四维向量经列消元求生成空间的一组基	第 1 章“高斯消元取基”
第 5 讲	第 3 页	为什么得到的三个主元向量一定线性无关？	第 1 章“讲义例题”
第 5 讲	第 3 页	取基时为何可缩放列，而算行列式时必须记账？	第 1 章“列初等变换”
第 5 讲	第 4–5 页	$u = (2, -1, 1)^T$ 向 $v = (1, 2, 2)^T$ 投影并求正交残差	第 1 章“向一条直线投影”
第 5 讲	第 6–7 页	对三个四维向量作 Gram–Schmidt，求标准正交基	第 1 章“课堂练习二”
第 5 讲	第 7–8 页	求超平面 $(1, 2, -2, 3)x = 0$ 的标准正交基	第 1 章“超平面标准正交基”
第 5 讲	第 9 页	哪些矩阵能作 $A = LL^T$ ？怎样计算？	第 1 章“Cholesky 分解”及第 5 章
第 6 讲	第 1 页	怎样从生成向量中删除冗余并保留原向量的一组基？	第 2 章“从生成集提取基”
第 6 讲	第 2 页	用同一矩阵具体核对行秩等于列秩	第 2 章“行秩等于列秩”
第 6 讲	第 3 页	子空间之和什么时候是内直和？	第 2 章“基的扩张与直和判据”

讲义	原页	题目或待回答问题	本书位置
第 6 讲	第 4 页	同一向量在两组基下的坐标怎样变化?	第 2 章“换基公式”
第 6 讲	第 4 页	二维换基的完整数值计算	第 2 章“同一向量的坐标”
第 6 讲	第 4 页	同一线性运动的矩阵怎样随坐标系变化?	第 2 章“相似矩阵”
第 7 讲	第 2-3 页	三个 2×2 矩阵的特征值、特征向量、特征空间与根子空间	第 3 章“课堂练习一”
第 7 讲	第 3 页	从 $A^2 - A - 2I = 0$ 等式猜出什么一般规律?	第 3 章“观察题”
第 7 讲	第 3-4 页	四阶矩阵的 $\lambda = \pm 1$ 特征/根子空间; 补出讲义省略的 -1 情形	第 3 章“课堂练习二”
第 8 讲	第 3 页	构造特征值 5 含尺寸 3, 2 两块的矩阵, 并写各层根子空间基	第 4 章“复数约当标准形”
第 8 讲	第 4 页	一般随机矩阵是否都像二状态例那样逐点收敛?	第 4 章“马尔可夫链”

7.2 省略证明与补全位置

讲义	原页	已补全内容
第 5 讲	第 1 页	生成空间最小性、二重正交补、和/交的正交补公式。
第 5 讲	第 2-3 页	基与极大无关组的等价、Steinitz 交换、三角主元列独立、正交组独立。
第 5 讲	第 4-8 页	投影的最优性和唯一性、一般基投影矩阵、Gram-Schmidt 两个不变量、QR/LQ 存在性与唯一性。
第 5 讲	第 9 页	矩形最小二乘的 QR 推导、Cholesky 存在唯一性、递推式、Sylvester 判据和 LDL^T 。
第 6 讲	第 1-2 页	唯一坐标、超过维数必相关、基的基数唯一、基扩张、秩-零化度、行秩等于列秩。
第 6 讲	第 3 页	投影存在与最近点、正交分解、内/外直和判据、讲义中断的维数公式证明。
第 6 讲	第 4 页	商空间运算良定义、商空间维数、与正交补同构、换基和相似公式。
第 7 讲	第 1-2 页	相似不变量、商空间维数、根子空间稳定、迹与范数性质。
第 7 讲	第 4-5 页	相似下每层根子空间对应; 不依赖约当形的 Cayley-Hamilton 证明。

讲义	原页	已补全内容
第 7 讲	第 5-7 页	几何重数不超过代数重数、不同特征/根子空间独立、Bézout 核分解、主分解及维数等于代数重数。
第 8 讲	第 1-3 页	根子空间直和、链向量独立、约当标准形构造与块数公式、实约当形。
第 8 讲	第 4-6 页	约当块幂、Perron–Frobenius 存在/唯一/代数单性、随机矩阵稳态存在、Cesàro 长期平均。

7.3 原讲义中需要澄清或修正之处

1. 第 5 讲第 1 页：子空间和应写成 $L_1 + L_2 = \text{span}(L_1 \cup L_2)$ ，一般不等于集合并 $L_1 \cup L_2$ 。
2. 第 5 讲第 9 页：对高矩阵， $QRx = b$ 与 $Rx = Q^T b$ 不能作为原方程的无条件等价变形；后者给出的是最小二乘正规条件，残差还含 $(I - QQ^T)b$ 。
3. 第 6 讲第 4 页：外直和维数应为 $\dim(\bigoplus_i L_i) = \sum_i \dim L_i$ ；原页把数字写入直和并重复同一下标。
4. 第 6-7 讲换基：公式方向取决于过渡矩阵把“哪组坐标”映到“哪组坐标”。本书统一从 $x = Py$ 推出 $B = P^{-1}AP$ ，避免同一个 P 被反向使用。
5. 第 7 讲第 2 页： $\text{Ker}(\lambda I - A)$ 是齐次方程解空间；原排版中的 $(\lambda I - A)^\perp$ 不能在一般意义下替代它。
6. 第 7 讲第 3 页：矩阵 C 的第二个复特征值方程误写了矩阵 A ；正文已改为 $((1-i)I - C)x = 0$ 。
7. 第 7 讲第 4 页：讲义明说特征值 -1 的根子空间计算省略；正文已给出平方、行化简、基与约当链。
8. 第 8 讲第 1 页：一般只有 $(\lambda I - A)W_\lambda^k \subseteq W_\lambda^{k-1}$ ，等号未必成立；链独立性证明已改为商空间论证。
9. 第 8 讲第 3 页：四阶例中原印刷矩阵的 $(2, 2)$ 元素为 2 时，与给出的 P, J 不满足 $AP = PJ$ ；正文依据 $A = PJP^{-1}$ 将该元素勘正为 1，并逐列复核全部链关系。
10. 第 8 讲第 6 页：long-run average 总会收敛，但一般只有 $O(1/T)$ 量级；原始状态的指数收敛还需要唯一稳态及非周期等谱条件。

7.4 最终自检清单

- 四份原讲义 26 页全部有逐页视觉核对记录。
- 17 个显式题框均紧跟详细解答；原讲义已有答案的算例也重新复算。
- 所有正式题目与补证明均有 \sourcepage 原页标记。
- 所有矩阵例题均检查了秩、核、特征多项式、正交性或矩阵乘积中的相应验证条件。
- 正定专题单独给出 11 条等价条件、完整等价链、Cholesky/LDL^T、Sylvester 与 Schur 补。
- 优化应用覆盖最小二乘、投影约束、梯度下降、动量、Newton/预条件、Adam、Shampoo、Muon、PageRank 与去中心化混合。

参考资料

1. 何斯迈, 2023年《线性代数》第 5–8 讲课程讲义。
2. Gilbert Strang, *Linear Algebra and Its Applications*.
3. Roger A. Horn and Charles R. Johnson, *Matrix Analysis*.
4. Gene H. Golub and Charles F. Van Loan, *Matrix Computations*.
5. Jorge Nocedal and Stephen J. Wright, *Numerical Optimization*.