

优化算法所需的线性代数基础：

谱分解、奇异值分解、矩阵范数与相关主题

基于张贤科《高等线性代数》与多本教材综合整理

2026 年 7 月 8 日

摘要

本文档为深度学习优化器（Adam、Shampoo、Muon、PolarGrad 等）的学习提供系统且详尽的线性代数基础。

核心问题意识：为什么 Adam 怕旋转而 Muon 不怕？Shampoo 的 $L^{-1/4}GR^{-1/4}$ 到底在做什么？

谱范数最陡下降的数学根源是什么？回答这些问题需要扎实理解以下工具：

阅读建议：§1–§3 是必修基础，§4–§5 用于理解 Shampoo/Muon，§6–§7 用于理论分析，§8 连接所有内容到优化器。

目录

1	特征值与谱分解	2
1.1	从线性变换到特征值	2
1.2	对称矩阵的谱定理	2
1.3	正定矩阵与半正定矩阵	3
1.4	谱分解的计算：从特征方程到 QR 迭代	3
2	奇异值分解 (SVD)	4
2.1	为什么需要 SVD？	4
2.2	SVD 的几何含义	4
2.3	SVD 的推导：利用 Gram 矩阵	5
2.4	Gram 矩阵的优化含义	6
2.5	低秩近似与 Eckart-Young 定理	6
3	矩阵范数	6
3.1	范数的公理化定义	6
3.2	矩阵范数：三类重要范数	7
3.3	三类范数的关系不等式	7

3.4	对偶范数与最陡下降	8
3.5	矩阵范数的次梯度 (Subgradient)	8
4	极分解 (Polar Decomposition)	9
4.1	极分解的定义与存在性	9
4.2	极分解与 SVD 的关系辨析	9
4.3	极分解在优化中的应用	10
5	矩阵函数 (Matrix Functions)	10
5.1	定义：从标量函数到矩阵函数	10
5.2	为什么不能对非对称矩阵随意做矩阵函数？	10
5.3	矩阵函数的性质与计算	11
5.4	Newton-Schulz 迭代的详细分析	11
6	Kronecker 积——完整版	12
6.1	定义与基本性质	12
6.2	核心性质（完整证明）	12
6.3	Shampoo 的 Kronecker 不等式	13
7	Loewner 偏序与矩阵不等式	14
7.1	定义与基本性质	14
7.2	迹不等式	14
8	从线性代数到优化器：整合与图示	15
8.1	知识地图：每个优化器依赖的线性代数工具	15
8.2	为什么谱范数约束产生 Muon：完整推导	15
8.3	为什么 Adam 怕旋转：对角预条件不是坐标不变的	16
9	练习	16
10	参考文献与进一步阅读	17

特征值与谱分解

从线性变换到特征值

定义 1.1 (特征值与特征向量). 设 $A \in \mathbb{C}^{n \times n}$. 若存在标量 $\lambda \in \mathbb{C}$ 和非零向量 $v \in \mathbb{C}^n$ 使得

$$Av = \lambda v, \quad (1)$$

则称 λ 为 A 的**特征值**, v 为对应的**特征向量**。

几何含义: A 作用在 v 上等价于将 v 沿自身方向缩放 λ 倍—— v 的方向不变。特征向量是线性变换 A 下的**不变方向**。

定义 1.2 (特征多项式). 特征值由特征方程 $\det(A - \lambda I) = 0$ 确定。 $p_A(\lambda) = \det(\lambda I - A)$ 称为 A 的**特征多项式**。 n 阶矩阵有恰好 n 个特征值 (计重数)。

代数重数: λ 作为特征多项式根的重数。

几何重数: λ 对应的特征空间的维数 $\dim \ker(A - \lambda I)$ 。

重要性: 若几何重数 = 代数重数 (对所有特征值), 则 A 可对角化。但一般矩阵不一定可对角化——可能出现 Jordan 块。

对称矩阵的谱定理

对一般矩阵, 特征值可能是复数, 特征向量不一定正交。但对于**实对称矩阵**, 一切都很完美:

定理 1.1 (实对称矩阵的谱定理). 设 $A \in \mathbb{R}^{n \times n}$ 满足 $A^\top = A$ (实对称)。则:

- (i) A 的所有特征值都是实数;
- (ii) 不同特征值对应的特征向量正交;
- (iii) 存在**正交矩阵** $Q = [q_1, \dots, q_n]$ ($Q^\top Q = I$) 和对角矩阵 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ 使得

$$A = Q\Lambda Q^\top = \sum_{i=1}^n \lambda_i q_i q_i^\top. \quad (2)$$

谱定理的证明概要. (i) **特征值为实数**: 设 $Av = \lambda v$ ($v \neq 0$). 将等式左乘 v^* (共轭转置):

$$v^* Av = \lambda v^* v = \lambda \|v\|^2.$$

对两边取共轭转置: $(v^* Av)^* = v^* A^* v = v^* Av$ (因为 $A = A^\top = \bar{A}$ 为实对称)。

所以 $v^* Av$ 是实数, 从而 $\lambda = (v^* Av) / \|v\|^2$ 也是实数。

(ii) 正交性：设 $Av = \lambda v$, $Aw = \mu w$, $\lambda \neq \mu$ 。则

$$\lambda \langle v, w \rangle = \langle Av, w \rangle = \langle v, Aw \rangle = \mu \langle v, w \rangle.$$

因为 $\lambda \neq \mu$, 必然 $\langle v, w \rangle = 0$ 。

(iii) 正交对角化：对每个特征空间取正交归一基。不同特征空间的正交性保证它们合起来是 $\mathbb{R}^n$ 的正交归一基。将这些基向量排成 Q , 即得 $AQ = Q\Lambda$, 或 $A = Q\Lambda Q^\top$ 。□

注记 1.1 (为什么叫“谱”分解)。“谱 (spectrum)”来源于物理学——原子光谱的谱线对应能量算符的特征值。在数学中, 矩阵的“谱”就是其特征值的集合: $\sigma(A) = \{\lambda_1, \dots, \lambda_n\}$ 。

注记 1.2 (特征向量的符号)。注意: 若 q_i 是特征向量, 则 $-q_i$ 也是。因此谱分解中的 Q 不是唯一的 (每列可有 ± 1 的符号歧义)。在实际算法中 (如 Shampoo 的特征基), 这种符号歧义需要在 Adam 状态转换时保持一致——这是 SOAP 实现中容易出错的地方。

正定矩阵与半正定矩阵

定义 1.3 (正定 / 半正定)。实对称矩阵 $A = A^\top$ 称为:

- 正半定 ($A \succeq 0$): 若对所有 $x \in \mathbb{R}^n$, $x^\top A x \geq 0$;
- 正定 ($A \succ 0$): 若对所有 $x \neq 0$, $x^\top A x > 0$ 。

定理 1.2 (正定性的等价刻画)。对实对称矩阵 A , 以下命题等价:

- (i) $A \succ 0$;
- (ii) A 的所有特征值 $\lambda_i > 0$;
- (iii) 存在可逆矩阵 B 使 $A = B^\top B$ (Cholesky 分解或其推广);
- (iv) A 的所有顺序主子式 > 0 (Sylvester 判据)。

例 1.1 (Hessian 与正定性)。在优化中, f 在局部极小点 θ^* 处满足 $\nabla f(\theta^*) = 0$ 且 $\nabla^2 f(\theta^*) \succeq 0$ 。若 Hessian 严格正定 ($\succ 0$), 则 θ^* 是严格局部极小。条件数 $\kappa = \lambda_{\max}/\lambda_{\min}$ 刻画了极小点附近曲率的各向异性程度。

谱分解的计算：从特征方程到 QR 迭代

小矩阵 ($n \leq 4$): 直接解特征方程 $\det(\lambda I - A) = 0$ 。

大矩阵: 实践中使用 QR 迭代算法 (Francis, 1961), 这是现代数值线性代数的基石之一。

QR 迭代的基本思想：

$$A_0 = A$$

$$A_k = Q_k R_k \quad (\text{QR 分解})$$

$$A_{k+1} = R_k Q_k \quad (\text{逆序乘积})$$

可以证明 A_k 收敛到一个上三角矩阵（或拟上三角矩阵），其对角元就是特征值。带原点位移（shift）的 QR 迭代收敛速度极快，是 LAPACK 和 PyTorch (`torch.linalg.eigh`) 背后的算法。

实践要点：对于对称矩阵，使用 `eigh`（Hermitian 专用）而非 `eig`——前者快约 2-3 倍，且数值更稳定（保证实数输出）。

奇异值分解 (SVD)

为什么需要 SVD?

谱分解仅适用于方阵（且最好是正规矩阵）。**奇异值分解 (SVD)** 是谱分解对任意矩阵（矩形、非对称）的推广。它是数据科学、机器学习中最重要矩阵分解，没有之一。

定理 2.1 (奇异值分解). 设 $G \in \mathbb{R}^{m \times n}$ ($m \geq n$ 不妨设)。则存在正交矩阵 $U = [u_1, \dots, u_m] \in \mathbb{R}^{m \times m}$, $V = [v_1, \dots, v_n] \in \mathbb{R}^{n \times n}$, 以及对角矩阵 $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n) \in \mathbb{R}^{m \times n}$, 其中 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$, 使得:

$$G = U \Sigma V^\top = \sum_{i=1}^r \sigma_i u_i v_i^\top, \quad (3)$$

其中 $r = \text{rank}(G)$ 是 G 的秩。

- σ_i 称为 G 的**奇异值** (singular values)
- u_i 称为**左奇异向量** (left singular vectors)
- v_i 称为**右奇异向量** (right singular vectors)

SVD 的几何含义


SVD 将任意线性变换分解为三步：

$$G: \mathbb{R}^n \xrightarrow{V^\top} \mathbb{R}^n \xrightarrow{\Sigma} \mathbb{R}^m \xrightarrow{U} \mathbb{R}^m$$

- (1) **旋转 ($V^\top$)**: 在输入空间 $\mathbb{R}^n$ 中旋转坐标系，使坐标轴对齐到 G 的“主方向”（右奇异向量）

(2) **缩放** (Σ): 沿每个对齐的方向按奇异值 σ_i 缩放 (可能降维—— $\sigma_i = 0$ 的方向被清零)

(3) **旋转** (U): 在输出空间 $\mathbb{R}^m$ 中旋转到最终方向 (左奇异向量)



关键直觉: G 将 $\mathbb{R}^n$ 中的单位球映射为 $\mathbb{R}^m$ 中的一个椭球。椭球的半轴长度恰好是 $\sigma_1, \dots, \sigma_r$, 方向由 $u_1, \dots, u_r$ 给出。

SVD 的推导：利用 Gram 矩阵

推导思路: G 不是方阵，我们不能直接做谱分解。但 $G^T G$ 和 GG^T 都是对称半正定矩阵！

- $G^T G \in \mathbb{R}^{n \times n}$: 半正定对称，有谱分解 $G^T G = V \Lambda V^T$, $\lambda_i \geq 0$
- 定义 $\sigma_i = \sqrt{\lambda_i}$ (非负平方根)
- $GG^T \in \mathbb{R}^{m \times m}$: 同样可对角化，且非零特征值与 $G^T G$ 的完全相同

SVD 的构造性证明. 第一步: $G^T G$ 是实对称半正定矩阵，由谱定理：

$$G^T G = V \Lambda V^T, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_i \geq 0.$$

记 $\sigma_i = \sqrt{\lambda_i}$, 排列使 $\sigma_1 \geq \dots \geq \sigma_n \geq 0$ 。

第二步: 定义 $u_i = \frac{1}{\sigma_i} G v_i$ (对 $\sigma_i > 0$ 的 i)。验证：

$$\langle u_i, u_j \rangle = \frac{1}{\sigma_i \sigma_j} \langle G v_i, G v_j \rangle = \frac{1}{\sigma_i \sigma_j} v_i^T G^T G v_j = \frac{1}{\sigma_i \sigma_j} \lambda_j \langle v_i, v_j \rangle = \delta_{ij}.$$

所以 $\{u_i : \sigma_i > 0\}$ 是标准正交组。将其扩充为 $\mathbb{R}^m$ 的标准正交基 $U = [u_1, \dots, u_m]$ 。

第三步: 验证 $U \Sigma V^T = G$ 。对任意 $x \in \mathbb{R}^n$, 将其在 $\{v_i\}$ 上展开：

$$U \Sigma V^T x = \sum_{i=1}^r \sigma_i u_i \langle v_i, x \rangle = \sum_{i=1}^r G v_i \langle v_i, x \rangle = G \left(\sum_{i=1}^n v_i v_i^T \right) x = G x.$$

其中用到 $\{v_i\}$ 是 $\mathbb{R}^n$ 的标准正交基 ($V^T V = I$)。 □

注记 2.1. 这个构造性证明说明了为什么 SVD 不需要额外假设： $G^T G$ 总是对称半正定，因此总是可正交对角化。SVD 的普适性来源于此。

Gram 矩阵的优化含义

在优化中， $G_t G_t^\top$ 和 $G_t^\top G_t$ 频繁出现：

- **Shampoo**: $L_t = \sum_s G_s G_s^\top$ (行空间协方差), $R_t = \sum_s G_s^\top G_s$ (列空间协方差)
- **Muon**: Newton-Schulz 迭代作用于 $BB^\top$ (B 为动量矩阵)
- **自然梯度**: Fisher 信息矩阵 $= \mathbb{E}[gg^\top]$

核心联系: $G^\top G$ 与 $GG^\top$ 的非零特征值完全相同 (都等于 σ_i^2)，但特征向量不同：

- v_i ($G^\top G$ 的特征向量) = 梯度在**输入空间**的主方向 (右奇异向量)
- u_i ($GG^\top$ 的特征向量) = 梯度在**输出空间**的主方向 (左奇异向量)

这就是 Shampoo 左/右因子分别捕获列/行空间相关性的数学依据。

低秩近似与 Eckart-Young 定理

定理 2.2 (Eckart-Young-Mirsky). 对任意 $k \leq r = \text{rank}(G)$ ，秩- k 矩阵的最佳 Frobenius 范数近似由截断 SVD 给出：

$$\arg \min_{\text{rank}(\hat{G}) \leq k} \|G - \hat{G}\|_F = \sum_{i=1}^k \sigma_i u_i v_i^\top, \quad (4)$$

且最小误差为 $\sqrt{\sum_{i=k+1}^r \sigma_i^2}$ 。

优化中的含义：如果梯度矩阵的奇异值快速衰减 ($\sigma_1 \gg \sigma_2 \gg \dots$)，则梯度是**近似低秩**的。这是 Muon 设计者的关键观察——Transformer 梯度确实是近似低秩的，所以正交化 (将所有 σ_i 置 1) 能显著提升小奇异值方向的更新。

矩阵范数

范数的公理化定义

定义 3.1 (向量范数). $\mathbb{R}^n$ 上的范数 $\|\cdot\|$ 是一个函数 $\mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}$ ，满足：

- (1) **正定性**: $\|x\| \geq 0$ ，且 $\|x\| = 0 \iff x = 0$
- (2) **齐次性**: $\|\alpha x\| = |\alpha| \|x\|$
- (3) **三角不等式**: $\|x + y\| \leq \|x\| + \|y\|$

ℓ_p 范数 ($p \geq 1$):

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

常用特例: ℓ_1 (曼哈顿距离)、 ℓ_2 (欧氏距离)、 $\ell_\infty = \max_i |x_i|$ (Chebyshev)。

矩阵范数：三类重要范数

矩阵范数比向量范数更复杂，因为有多种合理的定义方式。

定义 3.2 (Frobenius 范数).

$$\|G\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n G_{ij}^2} = \sqrt{\text{tr}(G^\top G)} = \sqrt{\sum_{i=1}^{\min(m,n)} \sigma_i^2}. \quad (5)$$

Frobenius 范数相当于将矩阵视为 mn 维向量后的 ℓ_2 范数。它是所有矩阵范数中最容易计算的（不需要分解，直接平方和开根）。

定义 3.3 (谱范数 / 算子范数).

$$\|G\|_{op} = \|G\|_2 = \max_{x \neq 0} \frac{\|Gx\|_2}{\|x\|_2} = \sigma_{\max}(G). \quad (6)$$

谱范数是矩阵作为线性算子的最大放大倍数——输入空间中单位球被拉伸的最大因子。它由最大奇异值给出。谱范数在优化中极为重要： L -光滑常数 L 本质上是 Hessian 的谱范数上界。

定义 3.4 (核范数 / 迹范数).

$$\|G\|_* = \sum_{i=1}^{\min(m,n)} \sigma_i(G) = \text{tr}(\sqrt{G^\top G}). \quad (7)$$

核范数是所有奇异值之和。它是谱范数的对偶范数（见后文），在低秩恢复和 Muon 的分析中起关键作用。

三类范数的关系不等式

定理 3.1 (矩阵范数之间的基本不等式). 对任意 $G \in \mathbb{R}^{m \times n}$:

- (i) $\|G\|_{op} \leq \|G\|_F \leq \sqrt{r} \|G\|_{op}$ ($r = \text{rank}(G)$)
- (ii) $\|G\|_F \leq \|G\|_* \leq \sqrt{r} \|G\|_F$
- (iii) $\langle G, H \rangle \leq \|G\|_{op} \|H\|_*$ (广义 Hölder 不等式, $\langle G, H \rangle = \text{tr}(G^\top H)$)

证明. (i): 设奇异值为 $\sigma_1 \geq \dots \geq \sigma_r > 0$. $\|G\|_{op} = \sigma_1$, $\|G\|_F = \sqrt{\sum \sigma_i^2}$. 显然 $\sigma_1 \leq \sqrt{\sum \sigma_i^2} \leq \sqrt{r \sigma_1^2} = \sqrt{r} \sigma_1$.

(ii): $\|G\|_F^2 = \sum \sigma_i^2 \leq (\sum \sigma_i)^2 = \|G\|_*^2$ (Cauchy-Schwarz 或 Jensen). 另一边, $\|G\|_* = \sum \sigma_i \cdot 1 \leq \sqrt{\sum \sigma_i^2} \sqrt{r} = \sqrt{r} \|G\|_F$.

(iii): 由 von Neumann 迹不等式: $\text{tr}(G^\top H) \leq \sum_i \sigma_i(G) \sigma_i(H)$ (奇异值按相同顺序排列). 于是 $\text{tr}(G^\top H) \leq \sigma_{\max}(G) \sum_i \sigma_i(H) = \|G\|_{op} \|H\|_*$. $\square$

注记 3.1 (关系不等式的含义). • $\|G\|_{op} \approx \|G\|_F$ 当梯度**低秩** (σ_1 主导) —— 此时 Frobenius 和算子范数接近

- $\|G\|_{op} \ll \|G\|_F$ 当梯度**高秩** (奇异值均匀) —— 此时 Frobenius 远大于算子范数
- 核范数和 Frobenius 范数的差距反映奇异值分布的“重尾”程度
这些关系在 ASGO 和 Muon 的收敛界中直接出现。

对偶范数与最陡下降

定义 3.5 (对偶范数). 范数 $\|\cdot\|$ 的**对偶范数**定义为:

$$\|y\|_* = \sup_{\|x\| \leq 1} \langle x, y \rangle. \quad (8)$$

对偶范数的核心作用: 在 $\|\cdot\|$ 约束下找最陡方向等价于在对偶范数单位球上最大化内积。

定理 3.2 (几对重要的对偶关系).

原始范数 $\ \cdot\ $	对偶范数 $\ \cdot\ _*$	优化器对应
ℓ_2 (欧氏)	ℓ_2 (自对偶)	SGD / GD
ℓ_∞	ℓ_1	SignSGD
$\ \cdot\ _F$ (Frobenius)	$\ \cdot\ _F$ (自对偶)	SGD (矩阵形式)
$\ \cdot\ _{op}$ (谱范数)	$\ \cdot\ _*$ (核范数)	Muon / PolarGrad

谱范数 $\leftrightarrow$ 核范数对偶性的证明. 需证明: $\sup_{\|X\|_{op} \leq 1} \langle G, X \rangle = \|G\|_*$.

设 $G = U\Sigma V^\top$. 取 $X = UV^\top$ (即 $\text{sgn}(G)$), 则 $\|X\|_{op} = 1$ 且

$$\langle G, X \rangle = \text{tr}(V\Sigma U^\top UV^\top) = \text{tr}(\Sigma) = \sum_i \sigma_i = \|G\|_*.$$

由广义 Hölder 不等式, $\langle G, X \rangle \leq \|G\|_* \|X\|_{op} \leq \|G\|_*$. 因此上界可达。 $\square$

这个证明直接给出了 **Muon** 的理论基础: 在谱范数球约束下, $-g_t$ 的最陡方向正是 $-\text{sgn}(G_t) = -UV^\top$ 。

矩阵范数的次梯度 (Subgradient)

在非光滑优化中, 核范数的次梯度与 SVD 密切相关:

命题 3.3 (核范数的次梯度). 设 $G = U\Sigma V^\top$. 则 $\partial\|G\|_* = \{UV^\top + W : \|W\|_{op} \leq 1, U^\top W = 0, WV = 0\}$.

这意味着 $UV^\top$ (即 $\text{sgn}(G)$) 是核范数在 G 处的**最小范数次梯度**——这是为什么许多矩阵恢复算法 (如矩阵补全) 使用软阈值 SVD 作为近端算子的原因。

极分解 (Polar Decomposition)

极分解的定义与存在性

定义 4.1 (极分解). 对任意实方阵 $G \in \mathbb{R}^{n \times n}$, 存在唯一的极分解:

$$G = UP, \quad (9)$$

其中 U 是正交矩阵 ($U^T U = I$), P 是正半定对称矩阵 ($P \succeq 0$).

从 SVD 构造极分解. 设 SVD 为 $G = U_{\text{SVD}} \Sigma V_{\text{SVD}}^T$. 定义:

$$U = U_{\text{SVD}} V_{\text{SVD}}^T, \quad P = V_{\text{SVD}} \Sigma V_{\text{SVD}}^T.$$

验证: $U^T U = V_{\text{SVD}} U_{\text{SVD}}^T U_{\text{SVD}} V_{\text{SVD}}^T = I$, 且 $P \succeq 0$. 乘积 $UP = U_{\text{SVD}} V_{\text{SVD}}^T V_{\text{SVD}} \Sigma V_{\text{SVD}}^T = U_{\text{SVD}} \Sigma V_{\text{SVD}}^T = G$. $\square$

极分解与复数的类比: 复数 $z = re^{i\theta}$ 的极坐标表示. 对应关系:

$$\underbrace{G}_{\text{矩阵}} = \underbrace{U}_{\text{“相位” } e^{i\theta}} \cdot \underbrace{P}_{\text{“模长” } r}.$$

正交因子 U 代表“方向” (旋转/反射), 正半定因子 P 代表“尺度” (沿各方向的拉伸).

极分解与 SVD 的关系辨析

	SVD	极分解
分解形式	$G = U_{\text{SVD}} \Sigma V_{\text{SVD}}^T$	$G = U_{\text{polar}} P$
因子个数	3 个 (左奇异向量 + 奇异值 + 右奇异向量)	2 个 (正交 + 正半定)
正交因子	$U_{\text{SVD}}, V_{\text{SVD}}$ 分别是 $m \times m, n \times n$	U_{polar} 是 $m \times n$
尺度因子	Σ 是对角矩阵	P 是正半定对称矩阵
适用性	任意矩形矩阵	方阵 (或可推广到矩形)
关系	$\rightarrow$ 极分解的 $U = U_{\text{SVD}} V_{\text{SVD}}^T,$ $P = V_{\text{SVD}} \Sigma V_{\text{SVD}}^T$	

易错点: SVD 的 U 和极分解的 U 是不同的矩阵! SVD 的 U 是左奇异向量组; 极分解的 U 是 $U_{\text{SVD}} V_{\text{SVD}}^T$.

极分解在优化中的应用

极分解在 Muon/PolarGrad 中至关重要：

- **Muon**: 提取动量矩阵的极分解正交因子 U （丢弃 P ），即 $\text{sgn}(B_t)$
- **PolarGrad**: 保留 U 作为方向，对 P 应用谱函数 $\phi(P)$ 来调节各方向的步长
- **数值计算**: QDWH（QR-based Dynamically Weighted Halley）和 ZOLO-PD 算法比 Newton-Schulz 更稳定，不需调参

例 4.1 (sgn 函数与极分解的联系). 矩阵符号函数定义为：

$$\text{sgn}(G) = \arg \min_{\|O\|_{op} \leq 1} \|O - G\|_F = U_{\text{polar}} = U_{\text{SVD}} V_{\text{SVD}}^\top.$$

即 $\text{sgn}(G)$ 是极分解的正交因子，也是谱范数单位球上离 G 最近的点。

矩阵函数 (Matrix Functions)

定义：从标量函数到矩阵函数

定义 5.1 (对称矩阵的函数). 设 $A = Q\Lambda Q^\top$ 为实对称矩阵的谱分解 ($\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$), $\phi: \mathbb{R} \rightarrow \mathbb{R}$ 为标量函数且在 $\{\lambda_i\}$ 上有定义。则：

$$\phi(A) := Q \text{diag}(\phi(\lambda_1), \dots, \phi(\lambda_n)) Q^\top. \quad (10)$$

这不是逐元素操作！ $\phi(A) \neq [\phi(a_{ij})]$ 。矩阵函数对特征值作用，保持特征向量不变。

例 5.1 (常用的矩阵函数). • A^{-1} : $\phi(x) = 1/x$ （要求所有 $\lambda_i \neq 0$ ）

• $A^{-1/2}$: $\phi(x) = 1/\sqrt{x}$ （要求所有 $\lambda_i > 0$ ，实践中通过 $A + \varepsilon I$ 保证）

• $A^{1/4}$: $\phi(x) = x^{1/4}$ （Shampoo 的左/右因子）

• $\exp(A)$: $\phi(x) = e^x$

• $\log(A)$: $\phi(x) = \log x$

为什么不能对非对称矩阵随意做矩阵函数？

对非对称矩阵 G （如梯度矩阵），没有谱分解（特征向量不正交，甚至可能不可对角化）。因此 $\phi(G)$ 在一般情况下没有标准定义。

两种推广方式：

(1) **通过 SVD**: 定义 $\phi_{\text{sing}}(G) = U \text{diag}(\phi(\sigma_1), \dots, \phi(\sigma_r)) V^\top$ 。即对**奇异值**（而非特征值）作用 ϕ 。

应用: $\text{sgn}(G) = \phi_{\text{sing}}(G)$, 其中 $\phi(\sigma) \equiv 1$ ——所有非零奇异值置 1。

(2) **通过极分解**: 先做极分解 $G = UP$, 然后对正半定因子 P 做矩阵函数（因为 P 对称!）: $\phi(G)_{\text{polar}} = U \cdot \phi(P)$ 。

应用: PolarGrad 的更新方向即 $U \cdot \phi(P)$ 。

注记 5.1. 对于对称矩阵, $\phi(A)$ 有良定义。对于非对称矩阵, 需要先借助 SVD 或极分解将其“对称化”。这就是为什么 Shampoo 维护的是对称矩阵 L_t, R_t （保证可对角化）, 而 Muon/PolarGrad 需要 SVD/极分解来处理非对称梯度 G_t 。

矩阵函数的性质与计算

性质 5.1 (矩阵函数的基本性质). (1) $\phi(A)$ 与 A 共享相同的特征向量

(2) 若 A, B 可交换 ($AB = BA$), 则 $\phi(A)\psi(B) = \psi(B)\phi(A)$

(3) 一般 $\phi(A + B) \neq \phi(A) + \phi(B)$ (非线性!)

(4) $\phi(P^\top A P) = P^\top \phi(A) P$ 仅当 P 正交 (这来自谱映射的定义)

计算矩阵函数的方法:

(1) **特征分解法**: $\phi(A) = Q\phi(\Lambda)Q^\top$ 。最精确, 但 $\mathcal{O}(n^3)$ 。

(2) **Newton-Schulz 迭代**: 用于 $\phi(x) = x^{-1/2}$ 或 $\phi(x) = \text{sgn}(x)$ 。仅需矩阵乘法, GPU 友好。

(3) **多项式/有理逼近**: 适用于特定函数 (如 $\exp$ 的 Padé 逼近)。

Newton-Schulz 迭代的详细分析

目标: 计算 $A^{-1/2}$ 或 $\text{sgn}(A)$ 而不做特征分解。

逆平方根迭代 (用于 Shampoo 的高效实现):

$$X_{k+1} = \frac{3}{2}X_k - \frac{1}{2}X_k^3 A, \quad X_0 = \frac{1}{\|A\|_F} A.$$

矩阵符号函数迭代 (用于 Muon):

$$X_{k+1} = aX_k + bX_k X_k^\top X_k + c(X_k X_k^\top)^2 X_k,$$

其中系数 $(a, b, c) = (3.4445, -4.7750, 2.0315)$ 是精心设计的 5 阶多项式, 使得 $\phi_5(\sigma) \approx \text{sgn}(\sigma)$ 。

收敛性分析（一维情形的洞见）：考虑 $x > 0$ ，迭代 $x_{k+1} = \frac{3}{2}x_k - \frac{1}{2}x_k^3$ 。不动点： $x = 0, \pm 1$ 。若 $x_0 \in (0, \sqrt{3})$ ，则 $x_k \rightarrow 1$ （符号函数的正半支）。多维分析通过特征值（或奇异值）解耦：每个 mode 独立地按一维迭代演化。

Kronecker 积——完整版

定义与基本性质

定义 6.1 (Kronecker 积). 对 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{p \times q}$, 定义:

$$A \otimes B = \begin{pmatrix} a_{11}B & a_{12}B & \cdots & a_{1n}B \\ a_{21}B & a_{22}B & \cdots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \cdots & a_{mn}B \end{pmatrix} \in \mathbb{R}^{mp \times nq}.$$

每个标量 a_{ij} 被替换为 $a_{ij}B$ 块。 $(A \otimes B)_{(i-1)p+k, (j-1)q+\ell} = a_{ij}b_{k\ell}$ 。

核心性质（完整证明）

性质 6.1 (混合积).

$$(A \otimes B)(C \otimes D) = AC \otimes BD,$$

前提: A 与 C 、 B 与 D 的维度分别匹配。

证明. 需逐元素验证。设 A 为 $m \times n$, C 为 $n \times r$; B 为 $p \times q$, D 为 $q \times s$ 。左边第 $(i-1)p+k, (j-1)r+\ell$ 个元素为:

$$\sum_{t=1}^n \sum_{u=1}^q a_{it}b_{ku} \cdot c_{tj}d_{u\ell} = \left(\sum_{t=1}^n a_{it}c_{tj} \right) \left(\sum_{u=1}^q b_{ku}d_{u\ell} \right) = (AC)_{ij}(BD)_{k\ell}.$$

这正是 $AC \otimes BD$ 的对应元素。 □

性质 6.2 (逆). 若 A, B 可逆, 则:

$$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}. \quad (11)$$

证明. 由性质 6.1: $(A \otimes B)(A^{-1} \otimes B^{-1}) = AA^{-1} \otimes BB^{-1} = I \otimes I = I$. □

性质 6.3 (矩阵函数 (幂)). 对 $A \succ 0, B \succ 0$ 和任意 $\alpha \in \mathbb{R}$:

$$(A \otimes B)^\alpha = A^\alpha \otimes B^\alpha. \quad (12)$$

完整证明. 设 $A = Q_A \Lambda_A Q_A^\top$, $B = Q_B \Lambda_B Q_B^\top$. 则:

$$A \otimes B = (Q_A \Lambda_A Q_A^\top) \otimes (Q_B \Lambda_B Q_B^\top) = (Q_A \otimes Q_B)(\Lambda_A \otimes \Lambda_B)(Q_A \otimes Q_B)^\top.$$

(最后一步使用了 $(X_1 Y_1) \otimes (X_2 Y_2) = (X_1 \otimes X_2)(Y_1 \otimes Y_2)$, 这是混合积的推论。) 注意 $Q_A \otimes Q_B$ 是正交矩阵 ($(Q_A \otimes Q_B)^\top (Q_A \otimes Q_B) = Q_A^\top Q_A \otimes Q_B^\top Q_B = I \otimes I = I$). 且 $\Lambda_A \otimes \Lambda_B$ 是对角矩阵 (Kronecker 积保留对角度)。

因此上式就是 $A \otimes B$ 的谱分解! 由矩阵函数的定义:

$$(A \otimes B)^\alpha = (Q_A \otimes Q_B)(\Lambda_A \otimes \Lambda_B)^\alpha (Q_A \otimes Q_B)^\top.$$

而对角矩阵的 α 次幂就是逐元素操作: $(\Lambda_A \otimes \Lambda_B)^\alpha = \Lambda_A^\alpha \otimes \Lambda_B^\alpha$. 代回即得 $(A \otimes B)^\alpha = (Q_A \Lambda_A^\alpha Q_A^\top) \otimes (Q_B \Lambda_B^\alpha Q_B^\top) = A^\alpha \otimes B^\alpha$. $\square$

这是 Shampoo 使用 $L^{-1/4} \otimes R^{-1/4}$ 而不必直接处理 $mn \times mn$ 矩阵的根本原因。

性质 6.4 (向量化).

$$\text{vec}(AXB) = (B^\top \otimes A) \text{vec}(X), \quad (13)$$

其中 $\text{vec}(\cdot)$ 将矩阵按列堆叠为向量。

证明. 记 $X = [x_1, \dots, x_p]$ 按列分块, $B = (b_{jk})$. 则 $AXB = [\sum_{j=1}^p b_{j1} A x_j, \dots, \sum_{j=1}^p b_{jq} A x_j]$. 向量化后:

$$\text{vec}(AXB) = \begin{pmatrix} \sum_j b_{j1} A x_j \\ \vdots \\ \sum_j b_{jq} A x_j \end{pmatrix} = \begin{pmatrix} b_{11} A & \cdots & b_{p1} A \\ \vdots & \ddots & \vdots \\ b_{1q} A & \cdots & b_{pq} A \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} = (B^\top \otimes A) \text{vec}(X).$$

注意分块矩阵 $(b_{kj} A)$ 的 (k, j) 块是 $b_{kj} A$, 从 Kronecker 积定义看, 这恰好是 $B^\top \otimes A$ ($B^\top$ 的第 k 行第 j 列是 b_{jk} , 不对——应仔细验证: $B^\top$ 的第 k 行第 j 列 = B 的第 j 行第 k 列 = b_{jk} , 确实与上述分块一致). $\square$

Shampoo 的 Kronecker 不等式

Shampoo 收敛分析的核心是以下矩阵不等式 (Loewner 序下):

引理 6.5 (Shampoo 的 Kronecker bound). 设 $G \in \mathbb{R}^{m \times n}$, $g = \text{vec}(G)$, $r = \text{rank}(G)$. 则:

$$\frac{1}{r} g g^\top \preceq I_m \otimes (G^\top G), \quad (14)$$

$$\frac{1}{r} g g^\top \preceq (G G^\top) \otimes I_n. \quad (15)$$

证明. 利用 SVD $G = U\Sigma V^\top$ (Σ 为 $r \times r$ 对角). 则:

$$g = \text{vec}(G) = (V \otimes U) \text{vec}(\Sigma).$$

其中 $\text{vec}(\Sigma)$ 只有前 r 个对角元非零 ($\sigma_1, \dots, \sigma_r$). 利用这个表示和 Kronecker 积的性质, 可推导出上述不等式。

直观: $gg^\top$ 在 Loewner 序下被 Kronecker 结构的上界控制——这保证了 Shampoo 使用的 Kronecker 预条件器不会比真实的 full-matrix 预条件器更差 (最多差一个因子 $\sqrt{r}$)。□

Loewner 偏序与矩阵不等式

定义与基本性质

定义 7.1 (Loewner 偏序). 对对称矩阵 $A, B \in \mathbb{R}^{n \times n}$, 定义:

$$A \preceq B \iff B - A \succeq 0 \iff \text{所有特征值 } \lambda_i(B - A) \geq 0.$$

性质 7.1 (Loewner 序的基本性质). (1) **保序**: 若 $A \preceq B$, 则对任意 X , $X^\top A X \preceq X^\top B X$ 。

(2) **逆序反转**: 若 $0 \prec A \preceq B$, 则 $B^{-1} \preceq A^{-1}$ 。

(3) **单调矩阵函数**: 若 ϕ 是算子单调的, 则 $A \preceq B \implies \phi(A) \preceq \phi(B)$ 。

(4) **Kronecker 保序**: 若 $0 \preceq A \preceq B$ 且 $0 \preceq C \preceq D$, 则 $A \otimes C \preceq B \otimes D$ 。

注记 7.1 (算子单调性). 函数 $\phi(x) = x^\alpha$ 对 $\alpha \in [0, 1]$ 是算子单调的 (Löwner-Heinz 定理)。这意味着 $A \preceq B \succ 0 \implies A^{1/2} \preceq B^{1/2}$, 但 $A^2 \preceq B^2$ 不保证! 在 Shampoo 中使用 $-1/4$ 次幂 ($\alpha = -1/4 < 0$) 时, 序方向反转。

迹不等式

定理 7.2 (von Neumann 迹不等式). 对任意 $A, B \in \mathbb{R}^{m \times n}$, 设 $\sigma_i(A), \sigma_i(B)$ 按降序排列:

$$\text{tr}(A^\top B) \leq \sum_{i=1}^{\min(m,n)} \sigma_i(A) \sigma_i(B). \quad (16)$$

这是谱范数—核范数对偶性的基础, 也用于 ASGO 和 Muon 的收敛证明中。

从线性代数到优化器：整合与图示

知识地图：每个优化器依赖的线性代数工具

优化器	核心操作	依赖的线性代数工具
SGD	$-\eta g$	向量 ℓ_2 范数
Adam	$-\eta \frac{m}{\sqrt{v+\varepsilon}}$	对角矩阵求逆、特征值（隐式）
AdamW	$-\eta \frac{m}{\sqrt{v+\varepsilon}} - \eta \lambda w$	同上
Shampoo	$-\eta L^{-1/4} G R^{-1/4}$	• 对称矩阵的谱分解 • Kronecker 积的性质 • 矩阵函数的定义 ($A^{-1/4}$) • Loewner 序的不等式 • 特征基的构造 (Q_L, Q_R)
SOAP	$Q_L(\frac{\tilde{m}}{\sqrt{v}})Q_R^\top$	• 基变换（正交变换） • Adam 在旋转坐标中的不变性分析 • SVD / 极分解 • 矩阵符号函数 $\text{sgn}(G) = UV^\top$
Muon	$-\eta \text{sgn}(B_t)$	• Newton-Schulz 迭代 • 谱范数与核范数的对偶性 • 极分解 $G = UP$
PolarGrad	$-\eta U\phi(P)$	• 矩阵函数 $\phi(P)$ • 谱范数最陡下降

为什么谱范数约束产生 Muon：完整推导

定理 8.1 (谱范数下的最陡下降等价于 Muon). 求解

$$\min_{\Delta} \left\{ \langle G, \Delta \rangle + \frac{1}{2\eta} \|\Delta\|_{op}^2 \right\},$$

得到的最优解为 $\Delta^* = -\eta \cdot \|G\|_* \cdot \text{sgn}(G)$ 。忽略标量因子 $\|G\|_*$ (吸收进步长中)，方向即为 $-\text{sgn}(G) = -UV^\top$ 。

证明. 将 Δ 分解为 $\Delta = c \cdot D$, 其中 $\|D\|_{op} = 1$, $c = \|\Delta\|_{op}$:

$$\min_{c \geq 0, \|D\|_{op}=1} c \cdot \langle G, D \rangle + \frac{c^2}{2\eta}.$$

固定 D , 对 c 求导: $\langle G, D \rangle + c/\eta = 0 \implies c = -\eta \langle G, D \rangle$ 。代入目标函数得: $-\frac{\eta}{2} \langle G, D \rangle^2$ 。因此需最大化 $\langle G, D \rangle$ 在 $\|D\|_{op} \leq 1$ 下。

由谱范数-核范数对偶性: $\max_{\|D\|_{op} \leq 1} \langle G, D \rangle = \|G\|_*$, 最优 $D^* = -\text{sgn}(G) = -UV^\top$ (取负号是因为最小化而非最大化)。因此 $c^* = \eta \|G\|_*$, $\Delta^* = -\eta \|G\|_* \cdot \text{sgn}(G)$ 。□

Muon 的做法: 丢弃 $\|G\|_*$ (核范数) 因子, 只用 $-\text{sgn}(G)$ 作为更新方向。这等价于谱归一化的最陡下降 (spectrally-normalized steepest descent)。

为什么 Adam 怕旋转：对角预条件不是坐标不变的

考虑对参数做正交变换 $\tilde{\theta} = Q^\top \theta$, Q 为正交矩阵。

在 $\tilde{\theta}$ 空间中运行 Adam, 梯度变为 $\tilde{g}_t = Q^\top g_t$ 。

Adam 的逐坐标二阶矩:

$$\tilde{v}_t = \beta_2 \tilde{v}_{t-1} + (1 - \beta_2) \underbrace{(Q^\top g_t)^{\odot 2}}_{\neq Q^\top (g_t^{\odot 2})}.$$

这里 $(Q^\top g_t)^{\odot 2}$ 是先旋转变换再逐元素平方, 与先平方再旋转 $Q^\top (g_t^{\odot 2})$ 完全不同。因此 $\tilde{v}_t \neq Q^\top v_t$, Adam 的预条件器 $\text{diag}(\tilde{v}_t)^{-1/2}$ 与 $\text{diag}(v_t)^{-1/2}$ 之间不是简单的坐标变换。

而 Muon 的 $\text{sgn}(G)$ 在正交变换下是协变的:

$$\text{sgn}(Q_L^\top G Q_R) = Q_L^\top \text{sgn}(G) Q_R,$$

这就是为什么 Muon 不像 Adam 那样怕旋转。

练习

理论练习 (带提示)

1. **特征值的连续性:** 证明实对称矩阵的特征值连续地依赖于矩阵元素。(提示: 利用特征多项式系数与矩阵元素的连续性, 或使用 Weyl 不等式。)
2. **SVD 的唯一性:** 证明若奇异值互不相同 ($\sigma_1 > \sigma_2 > \dots > \sigma_r$), 则左右奇异向量在符号上唯一确定。若有重奇异值, 奇异向量的选择有多少自由度?

3. **核范数对偶性的验证**: 对 2×2 矩阵 G , 直接验证 $\max_{\|X\|_{op} \leq 1} \langle G, X \rangle = \|G\|_*$ 。分别计算两边并确认相等。
4. **Kronecker 积的秩**: 证明 $\text{rank}(A \otimes B) = \text{rank}(A) \cdot \text{rank}(B)$ 。(提示: 利用 Kronecker 积的 SVD 表示。)
5. **Newton-Schulz 的收敛阶**: 分析一维迭代 $x_{k+1} = \frac{3}{2}x_k - \frac{1}{2}x_k^3$ 在 $x = 1$ 附近的收敛速度。证明它是二阶收敛的。(提示: 泰勒展开 $x_{k+1} - 1$ 关于 $x_k - 1$ 。)
6. **Shampoo 不等式的特殊情形**: 设 $G = uv^\top$ (秩-1 矩阵)。直接验证 $gg^\top = (v \otimes u)(v \otimes u)^\top$, 并证明它在 Loewner 序下满足不等式 (14)。

工程练习

1. **实现 SVD 的幂迭代**: 用幂迭代法 (power iteration) 计算随机矩阵的最大奇异值和对应的奇异向量。将其推广为同时求前 k 个奇异向量的子空间迭代。
2. **比较矩阵根的计算方法**: 对随机正定矩阵 (大小 100×100), 分别用 (a) 特征分解、(b) Newton-Schulz 迭代 (5 次迭代)、(c) Newton-Schulz (10 次迭代) 计算 $A^{-1/4}$ 。记录精度 (以特征分解为 ground truth) 和时间。
3. **可视化 SVD 的几何**: 随机生成 2×2 矩阵 G , 画出 $\mathbb{R}^2$ 中的单位圆及其在 G 下的像 (椭圆)。在图上标注左/右奇异向量的方向和奇异值的数值。
4. **实现 Newton-Schulz 的 Muon 版**: 对随机矩阵 M , 实现 Muon 中使用的 5 次 Newton-Schulz 迭代 (含归一化和转置步骤)。与 SVD 计算的 $\text{sgn}(M)$ 比较精度。

参考文献与进一步阅读

- 张贤科, 《高等线性代数》, 清华大学出版社。国内线性代数高级教材的标杆, 涵盖 Jordan 标准形、矩阵函数、广义逆等。
- Golub & Van Loan, *Matrix Computations*, 4th ed., Johns Hopkins, 2013. 数值线性代数的圣经, SVD 和 QR 迭代的权威来源。
- Horn & Johnson, *Matrix Analysis*, 2nd ed., Cambridge, 2013. 矩阵分析的标准参考书, 涵盖所有范数、Loewner 序、矩阵函数。
- Horn & Johnson, *Topics in Matrix Analysis*, Cambridge, 1991. 续卷, 深入 Kronecker 积、Hadamard 积等专题。
- Bhatia, *Matrix Analysis*, Springer, 1997. 以算子单调函数和矩阵不等式为核心, 适合理论深化。

- **Higham**, *Functions of Matrices: Theory and Computation*, SIAM, 2008. 矩阵函数的专门著作，包括 Newton-Schulz 和极分解的数值算法。
- **Boyd & Vandenberghe**, *Convex Optimization*, Cambridge, 2004. §A.5（矩阵范数）、§A.6（矩阵函数）、§A.7（矩阵微积分）的附录。